

Polymarket 数据获取、处理与信号构造

中国商品期货关联研究 · 精炼版（数据与方法为主体）

Alpha-Data 项目

2026 年 7 月（样本冻结于 2026-07-18）

摘要

本文是完整研究报告（151 页）的精炼版，写作原则是**宁少勿糊**：凡写入的条目都给出可复现的构造方法与严格定义，展开性论证一律指向完整版。第 3-4 节（数据获取与处理）是主体；第 5-6 节给出 40 个信号的公式、取值统计与 IC 全表；第 7 节把全部实验压缩为结论卡片。

数据资产：链上逐笔成交 855,614,453 笔（\$26.53B，2022-11-21 至 2026-07-14），与 88 个品种的中国期货 1 分钟数据（3,496,950 根 K 线）在 125 个重叠交易日（2026-01-05 至 07-13）上对齐。

核心结论：Polymarket 的信息含量真实存在，以**闭市时段的同期吸收**进入中国期货开盘价格，并在开盘后数分钟内耗尽。在分钟频率上，只用 Polymarket 数据构造的 23 个信号、798 个检验中**无一通过多重检验门槛**（ $\max |t| = 3.24 < 4.15$ ）；全部 13 个通过门槛的信号格**无一例外含有期货侧量价腿**（且无一为离散事件信号），其增量经双腿分解归因于期货自身的短期反转。据此，本研究不含已验证的可交易 alpha，实盘配置为零仓位。

目录

1 数据资产总览	3
2 概念白话解释（零基础导读，熟悉者可跳过）	3
2.1 一、预测市场是什么	3
2.2 二、“链上”和“链下”，以及抓数据用到的技术词	4
2.3 三、一笔成交里都记了什么	5
2.4 四、为什么有些成交要扔掉	6
2.5 五、怎么把很多市场并成一个“主题信号”	6
2.6 六、怎么把“每一笔”压成“每分钟一个数”	6
2.7 七、中国期货那边的行话	7
2.8 八、信号是怎么造出来的（四族）	8
2.9 九、怎么判断一个信号到底有没有用	8
2.10 十、公式符号速查表	10
3 Polymarket 数据获取	11
3.1 什么在链上，什么不在	11
3.2 两段数据与拼接	12

3.3	一行是什么：行级定义与主键	12
3.4	时间戳：精度、时区与语义	12
3.5	采集机制与延迟	13
3.6	主动买入与卖出的定义	13
3.7	机械成交的处理	14
3.8	清洗漏斗（自采段可逐级实测）	15
3.9	结算事件	15
4	数据处理	15
4.1	事件视角统一： p_{event} 与方向 D	15
4.2	主题注册与时点化准入	15
4.3	分钟聚合：从逐笔到主题信念创新 $N1$	16
4.4	中国期货 1 分钟数据：来源与口径	17
4.5	时段、休市与换月：逐条处理	17
4.6	时差与窗口切分	18
4.7	防前视协议（清单）	19
5	信号定义	19
5.1	设计原则与数值化的合理性	19
5.2	N 族：数值信号（只用 Polymarket 数据）	20
5.3	C 族：与标的量价数据组合的信号	21
5.4	K 族：基于原始离散事件的复杂统计指标	22
5.5	X 族：条件与状态交互信号	22
5.6	另行登记的事件跳因子（J 族）	23
6	指标口径与统计结果	23
6.1	IC 的数学定义	23
6.2	全信号登记表	23
6.3	连续信号：IC 期限结构	23
6.4	离散信号：频率与事件研究	23
6.5	多重检验下的族级结论	23
6.6	检出力与最小可检测效应	28
6.7	规定格式登记表	29
7	关键结果（模块化摘要）	30
7.1	吸收结构（A 级，全文最强结论）	30
7.2	中东增量（A 级）	30
7.3	反转 = SC-USO 相对收益回归（A 级）	30
7.4	否定结果（C/D 级，占结论的大多数）	30
7.5	数据层新发现：钱包技能真实且持续	30
7.6	结论与投资定位	30

1 数据资产总览3

8 复现31

8.1 已登记的限制项 31

1 数据资产总览

表 1: 数据资产一览

数据层	规模	时间范围	来源
Polymarket 逐笔成交	855,614,453 笔 / \$26.53B	2022-11-21..2026-07-14	链上（两段拼接）
公开数据集段	601,934,424 笔 / \$19.62B	..2026-04-28	HuggingFace 快照
自建爬虫段	253,680,029 笔 / \$6.91B	2026-04-28..	自爬 Polygon 链
市场元数据与结算	1,208,594 个市场（并集）	同上	链上 ConditionResolution
登记主题市场	8 主题 / 492 市场	事前注册	cn_registry_v3.parquet
中国期货分钟线	88 品种 / 3,496,950 根	2026-01-05..07-13	本地交付 CSV
国际基准	USO/GLD 等 12 ETF 分钟	同重叠期	美股分钟库
补充数据腿	Brent/USDCNH 日频; 逐合约日结算 见 §8		免费公开接口

必须首先声明的样本不对称。Polymarket 侧有 3 年 8 个月的历史，中国期货分钟数据只有 125 个交易日（2026-01-05 至 07-13）。因此：主题事件的到达率可以给出 2023-09 以来的全历史统计（表 5），而任何涉及期货价格的统计量（IC、事件后收益）只能在 125 天的重叠窗口上计算。本文所有“每月次数”按 125 交易日 / 21 折算为 5.95 个月，不是 3 年的均值。

2 概念白话解释（零基础导读，熟悉者可跳过）

一句话搭骨架：Polymarket 是一个押注”未来某件事会不会发生”的网站；本研究把它上面所有成交记录（谁、什么时候、什么价、押多少钱、押哪一边）全部抓下来，压成”每分钟市场对某件事的看法变了多少”，再检验这个变化和中国商品期货的价格有没有关系。下面按正文出现的顺序，用大白话把每个名词讲一遍，能打比方的都打个比方。已熟悉预测市场与链上数据的读者可直接跳到第 3 节。

2.1 一、预测市场是什么

预测市场

一个可以拿钱押”未来某事成不成”的市场。例：押”美联储 9 月降息”。押对的人事后按 1 元/份拿钱，押错的归零。

价格就是概率

每个结果做成一种”份额”，价格在 0 到 1 元之间。某份额卖 0.62 元，就等于市场认为这件事有 62% 的概率发生；价格涨到 0.70，就是市场把概率上调到了 70%。这是全文的出发点：价格 = 市场此刻认为的概率。

Yes 份额 / No 份额

一个二元问题有两种份额：押”会发生”的 Yes 份额、押”不会发生”的 No 份额。两者价格永

远加起来等于 1 元，否则有人能无风险套利。

市场、condition_id

一道题就是一个”市场”，系统给它一个唯一编号 `condition_id`，相当于这道题的身份证号。

2.2 二、“链上”和“链下”，以及抓数据用到的技术词

区块链、Polygon

一个公开、人人可查、不能篡改的公共账本。Polygon 是 Polymarket 所用的那一条链。

链上 / 链下

”链上” = 写进了公共账本、永久可查；”链下” = 只在公司自己服务器里、外人看不到也追不回。Polymarket 的关键设计：**谁挂了什么单在链下（查不到），但两张单一旦成交、钱货两清写进账本在链上（查得到）**。所以我们能重建每一笔成交，却永远拿不到历史挂单与盘口。

订单簿、挂单、吃单

订单簿就是一堆”我愿意用某价买/卖”的挂单排队。挂单方（maker，做市方）先把单子摆着等；吃单方（taker，主动方）看到合适的价直接成交。**吃单方是主动的一方**，这点在判断买卖方向时是关键。

区块、区块时间戳

链上记录按”区块”一批批打包，每个区块盖一个时间戳。同一区块里的所有成交共用同一个时间；实测约每 1.6 秒出一个区块，所以时间精度只到秒级，且同一秒内谁先谁后无法区分。

撮合合约（CTF Exchange）

链上负责”把买方卖方配对、钱货两清”的那段程序。它像一个自动清算中心，站在每一笔成交的中间。

结算、乐观预言机（UMA）

事件有了结果（降息了 / 没降），需要有人把”正确答案”写上链，这一步叫结算（ConditionResolution）。

裁定答案的机制叫预言机；UMA 是”乐观”型：先假定有人提交的答案是对的，留一段时间让别人质疑，没人质疑就生效。结算后 Yes/No 份额价格锁死在 1 或 0。

代币标准 ERC-1155、asset_id

每种份额（某市场的 Yes 或 No）在链上都是一枚”代币”，ERC-1155 是这类代币的通用规格（好比集装箱的标准尺寸，规定它怎么装、怎么转），每枚有唯一编号 `asset_id`。

事件类型标签 topic

链上每条记录开头都有一个”这是什么类型”的标签（topic）。想找所有”成交”记录，就按”成交”这个 topic 去扫，不用逐条翻。好比图书馆按书脊标签找书。

字段说明书 ABI（v1 / v2）

一条记录里各个位置分别是什么意思，由合约的”字段说明书”（ABI）规定。Polymarket 的撮合合约升级过一次，旧版 v1、新版 v2 的说明书不同，所以同一种”成交”在两版里字段摆放不一样，解码时要分别对照。

取数命令 eth_getLogs

向区块链节点要数据的标准问法之一：”把某段区块里带某个标签的记录都给我”。我们的自建爬虫就靠它按 topic 批量取回成交。

终局 finalized、区块重组

刚出的区块理论上极小概率被回滚重排（叫”重组”）；一旦达到”终局”状态就永不改变。我

们只抓已终局的区块，数据一次成型、不会因链上回滚变脏。端点不支持终局标签时，退而只信 256 个区块以前的记录。

幂等

同一段数据抓两遍，结果完全一样、不会重复。因为每条记录有唯一编号，重复的会被自动去掉。好比同一份名单核对两遍不会把人数算多。

2.3 三、一笔成交里都记了什么

outcome_seq（第几个结果）

标记这枚代币是这个市场的第 1 个结果（Yes）还是第 2 个（No）。它是代币出生就定死的属性，永不改变。

USDC、名义额、vwap

USDC 是一种与美元 1:1 的数字货币，Polymarket 用它计价。一笔成交的名义额 = 价格 × 份数。一分钟内多笔成交，按各自名义额加权算出的平均价叫 vwap（成交量加权均价），比简单平均更能代表这一分钟的真实价位。

p_event（事件概率）

把“这枚代币值多少钱”统一换算成“这件事发生的概率”。买的是 Yes 币，概率就是它的价；买的是 No 币，概率就是 1 减它的价。这样不管成交发生在哪一侧，都能读成同一个“事件概率”。

主动方向 taker_direction

这笔成交里，主动的一方（吃单方）是在买还是在卖。由“谁付了 USDC、谁收了代币”这个链上事实直接判定，不靠猜。

为什么“直接判定”值得强调：tick rule 与 Lee-Ready

普通股票 / 期货行情只报“成交价和量”，不写明这笔是主动买还是主动卖。学界只能用规则去猜。**tick rule**（逐笔规则）看这笔比上一笔价高（猜买）还是低（猜卖）。**Lee-Ready**（1991 年 Lee 与 Ready 两位作者提出的方法，微观结构里的标配）更细，分两步：先看成交价落在“中间价”（=（买一价 + 卖一价）/2）的哪一边——高于中间价判买、低于判卖（直觉：急着买的人会够上去吃卖一、急着卖的人会砸向买一，中间价就是分界）；若成交价正好落在中间价上分不清，再退回用 tick rule。举例：买一 10.00、卖一 10.02、中间价 10.01，成交在 10.02 判买、在 10.00 判卖、正好在 10.01 就看上一笔谁高谁低。**这两种都是估计、会出错**（快市、报价过时、恰在中间价成交时最容易判错）。而 Polymarket 的链上账本白纸黑字记了资产转移，我们**不需要这类推断**，方向是事实、没有判错的隐患。

方向 D（这笔在押哪边）

把“主动买还是卖”与“买的是 Yes 还是 No”相乘，得到“这笔主动成交是在押事件会发生、还是不会发生”：主动买 Yes 或主动卖 No = 押会发生（+1）；主动卖 Yes 或主动买 No = 押不会发生（-1）。两个乘数都在成交时点确定，**不看成交之后价格怎么走，不是未来信息**（详见第 3.6 节）。

成分腿、腿（leg）

一笔大单常被拆成对好几个对手方的小成交，每条小成交叫一条“腿”。下面的“中继腿”就是其中那条特殊的汇总腿。

2.4 四、为什么有些成交要扔掉

中继腿

撮合合约站在每笔成交中间，于是账本里一笔真实成交常被记成两条：一条”用户对撮合合约”、一条”撮合合约对另一用户”。全加起来会把成交量算成两倍。判据很简单：只要一条记录的对手方是撮合合约本身，它就是”中继腿”，扔掉。

铸造 / 合并 (mint / merge)

Polymarket 允许把 1 个 USDC 拆成”1 份 Yes + 1 份 No”（铸造），或把一对合并回 1 USDC（合并）。这是系统内部的拆分组合动作，没有”从别人手里接货”的对手方，不代表任何人看多看空。它们在账本里是**另一类记录、另一个类型标签**，本来就不在我们用的成交流里，谈不上剔除。

negRisk

一类特殊的多选市场（如”下任总统是谁”），机制不同，本数据两段都统一排除，代价是 2024 美国大选等大市场不在样本里。

2.5 五、怎么把很多市场并成一个”主题信号”

主题、事前注册

把 Polymarket 上和某个中国资产相关的一批市场（如所有”中东冲突”相关问题）事先框成一个”主题”。规则在看结果之前就定死、之后不再增删（事前注册），避免事后专挑对自己有利的市场。

方向系数 orientation 与 σ

麻烦在于不同市场的”Yes”含义常相反：一个市场 Yes = 冲突升级，另一个 Yes = 停火。所以先给每个市场标一个 orientation，把它们统一到同一根”主题轴”上（都朝”冲突升级”为正）； σ 再把”主题轴”翻译成”对这个期货品种应偏涨还是偏跌”的先验。好比一堆温度计有的用摄氏有的用华氏，先统一刻度再一起读。

时点化准入

一个市场要等它累计成交额攒够 10 万美元、有了足够流动性，才被放进样本；而且”攒够”的时刻按时间往前推着判断，不能用它整段历史的总额提前放行，否则等于让 1 月的样本偷看 4 月才发生的事。

加权聚合

同一主题下有很多市场，成交额大的更可信、权重更高（权重用 $\sqrt{\text{时点化累计成交额}}$ ）。把各市场的看法变化按权重平均，得到这个主题这一分钟的总看法变化。

2.6 六、怎么把”每一笔”压成”每分钟一个数”

信念创新 $N1$

全文最核心的自造量。意思是”这一分钟里，市场对某个主题的看法比上一分钟变了多少”。它是一个数：正表示概率被推高，负表示被推低。后面几乎所有信号都由它衍生。

截断、logit 变换

概率被卡在 0 到 1 之间，靠近两端时”从 0.98 到 0.99”其实是很大的信息，数值却只差 0.01。先把概率截到 [0.02, 0.98] 防止贴边发散，再用 logit（一个把 0 到 1 拉伸成正负无穷的数学变换）

让两端的变化不被压扁。

买卖跳动

同一时刻成交价会在”买家愿付价”和”卖家愿收价”之间来回跳，这种跳动不代表概率真变了。本文两条管道的处理方式不同，须分清：分钟面板（40 个信号所用）只取**成交额加权平均**（VWAP），靠”一分钟内多笔成交平均一下”隐含地压住跳动；而 15 分钟窗口级的吸收分析用的是**按买卖方向分堆、各取成交额加权中位数再平均**的显式去跳动（取中位数是因为它比平均值更抗个别异常成交）。两者不可混为一谈。

过时报价（p_age）

某个冷门市场可能几小时没成交，它上一次的价格已经”傻了”。规则：沿用最后一次成交价，但超过 120 分钟没更新就当缺失，不拿陈旧价冒充新信息。

分钟桶、右端标签

把连续成交按每分钟归拢成一格（一个”桶”）。给这一格贴的时间标签取**分钟结束那一刻**，且这一格**只装该时刻之前的成交**。这样信号永远早于它要解释的价格，杜绝偷看未来。

时序归一化（z-score）

同一个量在不同品种、不同时期数值大小不可比。z-score 的做法是：减掉最近一段时间的平均值，再除以这段时间的波动大小，换算成”比平常高 / 低几个身位”。”最近一段”只回看过去、不含未来。

稳健阈值、MAD

判断”这一分钟的变化算不算一次事件”要有一条线。这条线用 MAD（一种抗极端值干扰的波动度量）乘系数得到，比用普通标准差更不容易被个别异常值带偏。

测量模型、Kalman、参数冻结

Kalman 滤波是”从带噪声的观测里估计背后真实状态”的经典方法，这里用它从嘈杂成交里估”市场真实信念”。它的参数在样本前半段估好后**就锁死**，后半段只用不改，避免用全样本调参造成的偷看。

2.7 七、中国期货那边的行话

主力连续、换月

同一品种（如原油）同时挂着好几个到期月份的合约，交易最活跃的那个叫”主力”。主力会随时间换到下一个月份，叫”换月”。把历次主力接成一条不断的价格序列，就是”主力连续”。

日盘 / 夜盘

中国商品期货一天分两段交易：白天的日盘、晚上的夜盘。夜盘常跨过午夜，因此**某天晚上的夜盘算作下一个交易日**。

四段窗口

把一个交易日按期货作息切成四段：傍晚闭市、夜盘、凌晨闭市、日盘。因为国内闭市时段恰好对着美东活跃时段，分段才能看清”闭市期间积累的信息在开盘怎么被定价”，这正是全文识别设计的基础。

涨跌停（locked）

一天价格最多涨 / 跌一个固定幅度，到顶就”封板”，全天价格钉住不动。本数据没有涨跌停价表，只能用”这一分钟最高价 = 最低价”近似判断是否封板，且只用于监控、不参与计算。

连续分钟段

期货有午休、日夜盘之间的休市。规则：只要相邻两根 K 线时间差不是正好 1 分钟，就断成两段。任何“未来收益”都不许跨过一个断点，避免把一夜或一个午休的跳空错算成 1 分钟的涨跌。

前向收益 fwd

“信号发出后，价格在接下来 1、2、3、5、10、15 分钟涨跌了多少”，这是我们要预测的目标。

基点 bp

万分之一。10bp = 千分之一 = 0.1%。期货分钟级涨跌很小，用 bp 计更清楚。

2.8 八、信号是怎么造出来的（四族）

N / C / K / X 四族

信号按“用了什么数据”分四类。**N 族**只用 Polymarket（信念创新、成交流强度）；**C 族**把 Polymarket 和期货的量价乘在一起（如“事件发生但价格没动”）；**K 族**把“发生了没发生”的离散事件加工成统计量（计数、连发、到达率）；**X 族**只在特定状态下（夜盘、放量）才触发。分族的好处：哪一族显著，就知道信息来自哪一侧数据。

签名值、签名离散型

离散信号不用“是/否”（0/1），而用带正负号的 $-1/0/+1$ ：-1 表示看跌方向触发、+1 看涨方向触发、0 没触发。这样它既能直接进相关性计算，也能相加。

游程（连发长度）

连续同方向发生了几次。比如连续 5 分钟都是“上行事件”，游程就是 5。连发往往比单次更有信息。

到达率

事件多久来一次的频密程度：间隔越短、到达率越高。用最近几次事件间隔的倒数估计（统计上的泊松强度）。

截面统计

不看单个品种随时间怎么走，而是在同一时刻横着比一排品种谁高谁低。好处是同一天所有品种共同的涨跌（大盘、宏观）被自动减掉，剩下的是品种之间的相对差异。全文最强的正结果就来自这里。

残差化 / 正交化

想知道 Polymarket 信号里“不能被期货动量解释的那部分”，就用回归把动量成分减掉，剩下的残差就是“正交（不重叠）”的独立信息。好比两人说的话有重叠，划掉重叠，看第二人还剩多少新东西。

2.9 九、怎么判断一个信号到底有没有用

防前视、未来函数

“未来函数”指计算时不小心用到了当时还不知道的信息，会造出虚假的准确度、实盘一分钱赚不到。全文反复强调的“防前视”就是层层堵死这种偷看。

RankIC（秩相关）、pooled

衡量“信号大的时候、之后收益是不是也偏大”的相关系数，范围 -1 到 1，0 表示没关系；用“排名”而非原值计算，抗极端值。pooled 指把所有交易日的所有分钟混在一起算一个总系数。分钟级上 0.01 到 0.03 就已经算有一点点关系。

ICIR

把”每天的 RankIC”都求出来，再看它**是否稳定为正**：平均值除以波动。数值高说明信号不是靠某几天的运气，而是天天都灵。

事件研究、基准

对”发出 / 没发出”的离散信号，看它触发之后价格平均怎么走，并和”这个品种平时的平均走势（基准）”比。只有明显好过基准才算有信息。

聚类稳健 t 、HAC

信号触发常在时间上扎堆（一件大事连着触发很多次），普通统计会把它们当成互相独立的证据、高估显著性。”按交易日聚类”的 t 值、以及 HAC (Newey–West) 方法，都是把这种前后相关、成簇效应扣掉的更保守算法。

双侧检验与符号一致率

事先没有登记”该信号应该正相关还是负相关”时，只能做**双侧检验**（只问有没有关系、不问方向），门槛按 $|t|$ 设定；若事后按看到的方向改成单侧，就是放松门槛、会造假阳性。代价是 $|t|$ **丢掉了方向信息**：一个信号在 1 分钟为正、15 分钟为负，仍可能报出不小的 $|t|$ ，但这种符号乱跳多半是噪声。所以另报**符号一致率**：跨品种与视界的诸格中，占多数的那个符号占多大比例。纯噪声约 57%，真信号趋近 100%。本文纯 Polymarket 信号的一致率中位 60%、其最强格更低至 53%，而 C8 为 100%。

多重检验、Bonferroni 门槛

我们试了上千个”信号 $\times$ 视界”的组合。试得越多，纯靠运气蒙出一个”看着显著”的就越容易。Bonferroni 是一条按试验次数抬高的及格线（本文约 $|t| > 4$ ），只有跨过它才当真。**这正是全文最关键结论所在**：只用 Polymarket 数据的信号，没有一个跨过这条线。

置换检验、wild bootstrap、FDR

都是判断”这个结果是不是碰巧”的手段。置换检验把信号和收益的对应关系随机打乱很多次，看真实结果在打乱分布里排得多极端；wild bootstrap 是另一种反复扰动重算的版本；FDR 则控制”被判显著的里面平均有多少其实是假阳性”。它们都不依赖正态假设，更稳。

工具变量、LP-IV、第一阶段 F

想估”A 影响 B”却担心有第三个因素同时搅动 A 和 B 时，借一个”只通过 A 起作用”的外部变量（工具）来干净地估。第一阶段 F 衡量这个工具够不够强（ $F > 10$ 算合格，本文为 42，很强）。

五分位、载荷 / 暴露度

按某个指标把品种从低到高分成五档（五分位），比最高档和最低档的差。”载荷 / 暴露度”是”某品种对某主题有多敏感”的系数。

冻结、预注册、SHA256

把全部定义和阈值在检验之前锁死、算一个指纹（SHA256 哈希）存档，并预约将来某个日期用”没碰过的新数据”检验一次，杜绝反复试到显著为止。

第二类错误、检出力

”第一类错误”是本来没有却说有（假阳性）；**第二类错误**是本来有却没看出来（漏报）。**检出力**就是”真有信号时能被我们抓到的概率”，本文取常用的 80%。样本越短、噪声越大，检出力越低、越容易漏报。

最小可检测效应 (MDE)

在既有样本量和既定门槛下，**多大的效应才会被我们以 80% 把握检出**。它是”没检出”这句话的刻度尺：大于 MDE 的效应可以说已被排除，小于 MDE 的只能说无法分辨，不能说它是零。没有 MDE，”我们没发现 alpha”就等于什么都没说。

标准误的反解

本文不另做假设去估 MDE，而是把已算出的 t 值反过来解出标准误：既然 $t = \text{效应} / \text{标准误}$ ，那么标准误 = 效应 / t 。这样 MDE 与正文其余数字同源、不引入新口径。

2.10 十、公式符号速查表

下表把全文公式里出现的记号一次列清。凡在正文遇到不认识的符号，回此处查。

(甲) 时间与下标

符号	含义
t	当前这一分钟（时刻）
h	前向视界，往后第几分钟；取 1, 2, 3, 5, 10, 15
u	求和用的分钟下标，在某个窗口内遍历
m	市场下标（一个主题下第 m 个市场）
d	交易日下标
θ	主题下标（8 个主题之一）
W	滚动窗口长度（交易分钟数，本文归一化用 $W = 4800$ ）
t^-	读作”t 减”，指该市场上一次有成交的那一分钟

(乙) 期货价量

符号	含义
C_t	这一分钟的收盘价 ($C = \text{close}$)； $O/H/L$ 为开 / 高 / 低价
H_t, L_t	这一分钟的最高价、最低价（涨跌停代理 $\text{locked} = \mathbf{1}\{H = L\}$ 用）
V_u, A_u	这一分钟的成交量 (volume)、成交额 (money / amount)
$r1_t$	期货 1 分钟对数收益 = $\ln C_t - \ln C_{t-1}$
$\text{fwd}_{h,t}$	前向收益：信号发出后 h 分钟的对数收益（段内，跨休市置缺失）
seg_t	连续分钟段编号；相邻 K 线时间差 $\neq 1$ 分钟即换段
Δts_u	相邻两根 K 线的时间差

(丙) Polymarket 侧

符号	含义
$p_{m,t}$	市场 m 这一分钟的事件概率
$\ell(p)$	logit 变换 $= \ln \frac{p}{1-p}$; $\Delta\ell$ 为其变化量
D	单笔主动方向 $\in \{-1, +1\}$, 押事件不发生 / 发生 (详见第 3.6 节)
orientation_m	市场方向系数 ± 1 , 把各市场 Yes 含义统一到主题轴
σ	品种方向先验 ± 1 , 主题轴到期货涨跌的先验 (勿与标准差混淆)
w_m	市场权重 $= \text{orientation}_m \sqrt{\text{时点化累计成交额}_m}$
$N1_t$	主题信念创新: 这一分钟主题看法的加权平均变化 (全文核心量)
f_t, U_t, n_t, M_t	15 分钟签名流、成交额、笔数、活跃市场数

(丁) 归一化与信号

符号	含义
$z_W(x)$	时序 z 分数 $= (x - \mu_W) / \sigma_W$, μ_W, σ_W 为窗口 W 的滚动均值 / 标准差
m_t, v_t, u_t, a_t	前 15 分钟涨幅 / 波动 / 成交量 / 成交额的 z_{4800} 归一化值
κ_t	稳健事件阈值 $= \max(3 \times 1.4826 \times \text{MAD}_{4800}(N1), 0.05)$
MAD	中位数绝对偏差 (抗极端值的波动度量); 1.4826 把它折成正态标准差
e_t	签名事件指示 $= \mathbf{1}\{N1_t > \kappa_t\} - \mathbf{1}\{N1_t < -\kappa_t\} \in \{-1, 0, 1\}$
$C8_t$	未兑现缺口信号 (PM 累积腿减期货反转腿, 见第 5 节)

(戊) 统计与通用记号

符号	含义
$\mathbf{1}\{\cdot\}$	指示函数: 括号内条件成立取 1、否则取 0
$\text{sign}(\cdot)$	取符号: 正数 +1、负数 -1、零 0
$\ln, \sqrt{\cdot}, \sum, \cdot $	自然对数、平方根、求和、绝对值
ρ_S	Spearman 秩相关系数 (RankIC 用的相关)
RankIC_h	信号与 h 分钟前向收益的 pooled 秩相关
$\text{IC}_h^{(d)}$	第 d 个交易日的日内 RankIC
ICIR_h	$= \overline{\text{IC}_h^{(d)}} / \text{sd}(\text{IC}_h^{(d)})$, 逐日 IC 的均值除标准差
t_h	t 统计量 $= \text{ICIR}_h \sqrt{D}$, 此处 D 为有效交易日数 (与方向 D 同字不同义)
bp	基点, 万分之一; $10 \text{ bp} = 0.1\%$
z_α	显著性门槛对应的分位; 本文取全族 Bonferroni 门槛 4.15
z_β	检出力对应的分位; 80% 检出力对应 0.84
MDE	最小可检测效应 $= (z_\alpha + z_\beta) \times \text{SE}$ (见第 6.6 节)
SE	标准误; 由 t 值反解, 不引入新假设

3 Polymarket 数据获取

3.1 什么在链上, 什么不在

Polymarket 的撮合是**链下订单簿** (挂单为链下签名消息, 免 gas、可撤销、不落链), **清算在链上** (Polygon)。由此确定了本数据的结构性边界:

- **可完整重建**：成交（OrderFilled 事件）、结算（ConditionResolution 事件）、仓位铸造与合并（PositionSplit / PositionsMerge 事件）。
- **任何人都无法获取**：历史盘口、挂单深度、撤单、未成交订单。点差只能用同分钟买卖两向成交的中位价差代理。

3.2 两段数据与拼接

- **公开数据集段**（HuggingFace Polymarket-v1, CC-BY-4.0）：2022-11-21 至 2026-04-28。终点不是停更：旧交易所合约在 2026-04-28 11:00:40 UTC（区块 86,126,998）产生最后一笔成交后被 v2 合约取代。该段为下载所得，**非自采**。
- **自建爬虫段**：从区块 86,126,998 之后起，按 topic 扫描新旧两版 OrderFilled 事件重建同构数据，两段按区块号天然不重叠。
- **同质性检验**：v2 合约在 4 月 3 日已上线、与旧合约并行 25 天。抽样六个 3,000 区块窗口实测，并行期 v2 流量占比 $< 0.04\%$ ，拼接处无流量断层。
- **复现性检验**：自建解码器对同一区块的重建结果与公开数据集逐字段比对（13 个共有列、 10^{-9} 浮点容差），跨 2022-12 至 2026-04 的六个区块共 163 行全部精确一致。

3.3 一行是什么：行级定义与主键

一行 = 一条 OrderFilled 日志 = 一个挂单方的一次成交。不是一个订单，也不是经济意义上的一“笔”交易。主键为日志坐标：

$$\text{id} \triangleq \text{链 ID_ 区块号_ 日志序号} \quad (\text{Polygon 链 ID} = 137),$$

因此重复爬取天然幂等。一个吃单方订单吃掉 N 个挂单 $\Rightarrow N$ 条成分腿行，外加 1 条中继腿行（见 §3.7）。实测腿数分布（2026-05-01 全天、按交易哈希分组、已剔中继腿）：单腿 1,428,757、双腿 346,321、三腿 115,373、四腿 53,221、五腿 29,458，尾部延伸至 12 腿以上。

须声明的口径损失。分析层（daily_aligned 与扩展 tape，共 24 列）**不保留** id、block_number、log_index。因此 8.56 亿行的统一 tape 只能按（block_timestamp, asset_id, maker, taker, price, usdc_amount）识别，行级回溯到区块浏览器只在原始层成立。

3.4 时间戳：精度、时区与语义

- **字段与单位**：block_timestamp, **整数 Unix 秒, UTC**。数据中不存在毫秒或更细的时间字段。
- **语义**：它是**区块头时间**，即包含该日志的 Polygon 区块的出块时刻，**不是撮合时刻**。由于撮合在链下、只有清算上链，该时间戳**系统性滞后于真实成交**。该滞后在本数据中**不可测量**，属于已声明的结构限制。
- **分辨率上限**：同一区块内的所有成交共享同一时间戳。实测爬取区间（区块 86,127,122–90,226,886）的平均出块间隔为 **1.6272 秒**，故有效时间分辨率约 1.6 秒，**区块内先后顺序不可恢复**。
- **同秒并发密度**：公开数据集段 601,934,424 行落在 19,489,226 个不同的秒上（**30.9 行/秒**）；扩展段 253,680,029 行落在 4,076,023 个秒上（**62.2 行/秒**）。爬取区间内 99.5% 的区块至少含一条成交，平均 116.9 条原始行/区块。

表 2: 逐笔成交字段 (分析层)

字段	定义
maker / taker	挂单方 / 吃单方钱包地址
taker_direction	由资产转移事实判定 (见 §3.6), 非推断
price	成交价 $\in (0, 1)$, USDC/份, = 该结果代币的隐含概率
token_amount / usdc_amount	份数与名义额, $usdc = price \times token$
token_asset_id	ERC-1155 positionId (关联市场元数据的外键; 同市场 Yes/No 是两个不同 id)
condition_id	市场标识 (一个市场一个条件)
block_timestamp	秒级 Unix 时间, UTC (语义见 §3.4)

对建模的直接约束: 链上时间非均匀且高度并发, 任何时间归并必须**重采样**, 不能假设”每分钟一行”或”每秒一行”。本文的分钟聚合 (§4.3) 即据此设计。

3.5 采集机制与延迟

自建段经公共 Polygon JSON-RPC 的 `eth_getLogs` 按 `topic0` 扫描, 不按地址过滤 (避免漏掉未登记的交易所合约)。

- **重组保护:** 扫描上界取 `finalized` 区块标签; 端点不支持时退化为”当前高度 - 256 区块”。已终局的区块不可回滚, 因此分片一经写出即不可变, 管道内无重组处理逻辑。
- **延迟的结构下界:** Polygon 的检查点终局性, 量级为数分钟。端到端延迟未做埋点测量, 本文不给具体秒数。
- **吞吐:** 8 并发在免费公共端点上实测 6,168,870 行 / 601 秒 (约 83 区块/秒); 按此推算一个自然日的增量 (约 41,000 区块) 约需 8 分钟。实际一次补历史运行: 470,732,037 行、78 个日分区、25,286 秒。

因此在工程上可支持”当日收盘后数分钟内可得”的更新节奏; 但本研究的实证部分一律使用批量重建的冻结样本, 不依赖低延迟。

3.6 主动买入与卖出的定义

方向来自资产转移事实, 管道中不存在 `tick rule`, 也不存在 **Lee-Ready 式推断**。判据按协议版本分列:

- **v1(旧 ABI):** `makerAssetId = 0` 即挂单方付出的是抵押品 USDC, 故挂单方为买入 (`maker_buys = true`)。
- **v2 (新 ABI):** 事件显式带 `side` 字段, `side = 0` 即挂单方买入; 注意 `makerAmountFilled` 与 `takerAmountFilled` 的币种含义随 `side` 互换。

随后无条件取镜像:

$$maker_direction = \begin{cases} \text{BUY}, & \text{maker_buys} \\ \text{SELL}, & \text{否则} \end{cases} \quad taker_direction = \text{与 maker 相反.}$$

定义严谨，但 `taker_direction` 本身不可直接当作主动买卖比。实测全量 `daily_aligned: SELL 519,655,280 行 ($15.81B)` 对 `BUY 82,279,144 行 ($3.81B)`，`SELL` 占 **86.3%**。这不是市场情绪，而是挂单方约 87% 在买方的机械结果。真正平衡且可用的方向量是 D ：

$$D \triangleq \text{sign}(\text{taker_direction}) \times \text{sign}(\text{outcome_seq}),$$

即这笔主动成交本身的方向：主动买 Yes 或主动卖 No 记为”押事件会发生” (+1)，主动卖 Yes 或主动买 No 记为”押事件不会发生” (-1)。两个乘数（主动方向、Yes/No 侧）都在**成交时点即完全确定，不含成交之后的任何价格信息，不是未来函数**——它是这笔成交自身携带的方向（微观结构里的带方向成交流），不是它引发的后果。扩展段全量 253,680,029 行实测真值表与定义完全一致，且分布平衡：

表 3: 方向 D 的真值表与实测行数（扩展段全量）

taker_direction	outcome_seq	D	行数
BUY	1 (Yes 侧)	+1	12,645,179
BUY	2 (No 侧)	-1	12,689,651
SELL	1 (Yes 侧)	-1	113,825,747
SELL	2 (No 侧)	+1	114,519,452
$D = +1$ 合计			127,164,631 (50.13%)
$D = -1$ 合计			126,515,398 (49.87%)

3.7 机械成交的处理

(一) 中继腿 (relay leg) ——有显式判据，已剔除。撮合合约 (CTF Exchange) 是中央对手方：一笔用户订单在 `OrderFilled` 中拆成”吃单方对撮合合约”的一条**总量记录**（中继腿）与”撮合合约对各挂单方”的多条成分腿。判据：

$$\text{is_relay} \triangleq [\text{taker} = \text{撮合合约地址}].$$

保留会使成交量**恰好翻倍**。真实例证（市场”特朗普 6 月 30 日前宣布美伊停火结束”，2026-06-27 10:29:14 UTC）：三条成分腿 $2,196.87 + 26.51 + 4,966.93 = 7,190.31$ 份，与中继腿总量 7,190.31 相等——同一笔卖单从 0.974 吃到 0.973 两档。实测中继腿占自采段原始行的 **36.62%**。

(二) 铸造与合并 (mint / merge) ——结构性不在 `tape` 内。结果代币基于条件代币框架 (CTF)：互补买单由撮合合约把 1 USDC 拆成一对代币 (`PositionSplit`)，互补卖单把一对代币合并回 USDC (`PositionsMerge`)。这两类是**独立的事件类型、独立的 topic**，而成交 `tape` 只扫描 `OrderFilled` 的两个 topic，故它们**从未进入 `tape`**，无需也不存在”剔除”步骤。它们被单独采集到 CTF 生命周期层（拆分 594,406,549、合并 54,835,728、赎回 186,685,966、准备 1,447,649、结算 1,313,030，合计 838,688,922 条），供市场生命周期与洗量识别使用。

已声明的残余限制。撮合方为匹配两个同向吃单而铸造完整份额时，产生的 `OrderFilled` 行**未被单独标记**。该类行是否被中继腿判据完全覆盖，本仓库**未做证明**，登记为限制项。

3.8 清洗漏斗（自采段可逐级实测）

表 4: 自采段清洗漏斗（公开数据集段的逐级口径不可得，仅有单日对账）

阶段	行数	成交额
原始 <code>OrderFilled</code> （两版 ABI、全部合约）	476,900,809	\$19.92B
– 中继腿（174,646,150，占 36.62%）	302,254,659	–
– 非 Polymarket / 未识别合约（790,034）	301,464,625	\$10.04B
– <code>negRisk</code> 、非二元、元数据内连接	253,680,029	\$6.91B

两段合并前的原始规模为 1,678,481,799 行（公开段 `OrderFilled` 原始 1,201,580,990 + 自采段 476,900,809）。**negRisk 市场在两段中都被排除**（公开段作者如此构建，自采段刻意复制同一排除以保持同构），代价是 2024 年美国大选等旗舰市场不在样本内——这是已登记的覆盖限制。

3.9 结算事件

结算时刻取链上 `ConditionResolution` 首次事件（UMA 乐观预言机裁决上链的时点），覆盖 492 个登记市场中的 **455** 个；公开数据集自带的 `resolved_at` 元数据稀疏（**56/425**），不能作为结算依据。极少数争议市场多次重报，一律取首次事件。结算后价格恒为 0 或 1，结算时刻之后的窗口一律记缺失。

4 数据处理

4.1 事件视角统一： p_{event} 与方向 D

链上行只记录”某种代币值多少钱”；研究需要”事件发生的概率”。二元市场 Yes+No 价恒等于 1（由 mint/merge 套利钉住），换算唯一：

$$p_{\text{event}} = \begin{cases} \text{price}, & \text{outcome_seq} = 1 \text{ (Yes 侧)}, \\ 1 - \text{price}, & \text{outcome_seq} = 2 \text{ (No 侧)}, \end{cases}$$

非二元市场记缺失。方向 D 见 §3.6。

4.2 主题注册与时点化准入

以**事前注册**的关键词规则圈定与中国资产相关的市场：中东冲突、油价阈值、金属价格、美联储政策、俄乌冲突、中美贸易、台海风险、美政府停摆，共 8 主题 492 市场；注册后不增删。每个市场注册两个方向系数： $\text{orientation} \in \{\pm 1\}$ （市场结果轴 $\rightarrow$ 主题轴）与 $\sigma \in \{\pm 1\}$ （主题轴 $\rightarrow$ 品种方向先验）；已验证 $\sigma \times \text{orientation}$ 在每个（主题，品种）对内为常数。

时点化准入：市场只有在累计成交额首次达到 10 万美元之后才进入面板。用全窗口流动性筛选会让 1 月的样本构成依赖 4 月才实现的成交，属于用未来信息选样。

表 5: 登记主题的全历史事件到达率 (2023-09..2026-07, 35 个月)。事件 = 分钟创新超稳健阈值 κ ; 这是唯一可给出多年口径的频率统计, 期货侧只有 125 天

主题	覆盖月份	月数	市场	事件数	次/月	成交额 (M\$)
mideast_conflict	2023-10..2026-07	25	116	168,471	6,739	1,767.4
ruussia_ukraine	2024-08..2026-07	24	117	102,249	4,260	311.6
us_china_trade	2024-11..2026-07	21	114	53,351	2,541	71.4
oil_price	2025-12..2026-07	8	93	51,640	6,455	131.2
metal_price	2025-12..2026-07	8	78	27,455	3,432	20.0
us_shutdown	2023-09..2026-07	28	31	15,842	566	164.9
fed_policy	2023-12..2026-07	32	21	14,453	452	36.1
taiwan_risk	2023-10..2026-07	34	8	10,171	299	46.2
合计	2023-09..2026-07	35	-	443,632	12,675	2,548.8

4.3 分钟聚合：从逐笔到主题信念创新 $N1$

处理链五步, 每一步都对应一个具体的数据缺陷:

1. **截断与变换** (防端点发散): p 截断到 $[0.02, 0.98]$ 后取 $\ell(p) = \ln \frac{p}{1-p}$ 。临近结算时概率贴近 0/1, 未截断的 logit 会发散; 消融显示结论对截断位置不敏感。
2. **桶内定价** (防单笔极端值主导): 分钟桶内取**成交额加权平均** (VWAP), $\bar{p}_{m,t} = \sum_i p_i u_i / \sum_i u_i$ (u_i 为该笔名义额)。须如实声明口径差异: 本文分钟面板 (即全部 40 个信号所用的 $N1$) 走的是此 VWAP 口径, **不做按 taker 方向分堆的显式去跳动**; 桶内多笔成交的加权平均只是隐含地平抑了买卖跳动。按方向分堆取加权中位数再平均的显式去跳动, 实现于**另一条管道** (`cn_features.aggregate_price`, 15 分钟桶), 仅用于第 7 节的闭市吸收分析, 不用于本节的分钟信号库。
3. **过时报价** (防用陈旧价冒充新信息): 端点价取最后成交 (LOCF), 距最后成交超过 120 分钟记缺失 (`p_age` 规则)。
4. **主题聚合** (防小市场噪声主导): 市场层创新 $\Delta \ell_m$ 按 $w_m = \text{orientation}_m \sqrt{\text{cumUSDC}_m}$ 加权, 其中累计成交额为**时点化累计** (仅用 $\leq t$ 的成交):

$$N1_t \triangleq \frac{\sum_m w_m [\ell(p_{m,t}) - \ell(p_{m,t-})]}{\sum_m |w_m|}.$$

符号: m 为主题下第 m 个市场; $p_{m,t}$ 为市场 m 这一分钟的事件概率, $p_{m,t-}$ 为它上一次有成交那一分钟的概率; $\ell(\cdot)$ 为上一步的 logit 变换; w_m 为该市场权重 (方向系数 $\times \sqrt{\text{累计成交额}}$); 分母 $\sum_m |w_m|$ 把加权求和化为加权平均。算例: 某主题两市场, A ($w = 2$) 概率 $0.50 \rightarrow 0.60$ (logit 变化 $+0.41$), B ($w = 1$) $0.40 \rightarrow 0.42 (+0.08)$, 则 $N1 = (2 \times 0.41 + 1 \times 0.08) / (2 + 1) = +0.30$, 正值表示这一分钟主题概率整体被上调, 且主要由成交更大的 A 推动。

5. **桶标签取右端** (防前视): 分钟桶 $[T - 60s, T)$ 只含 **严格早于** T 的成交, 标签为 T 。

4.4 中国期货 1 分钟数据：来源与口径

- **来源与格式**：本地交付的主力连续 1 分钟 CSV，按自然日一个文件，GBK 编码，代码列形如 XX9999。交易所，另有列给出当时的实际合约。共 88 品种、3,496,950 根 K 线。
- **时间戳口径**：**bar 收盘戳（右端）**。21:01 表示区间 21:00–21:01。已实测：每个交易日日盘首根为 09:01、末根为 15:00。
- **时区**：北京时（UTC+8，无夏令时），存储为无时区标注。Polymarket 侧统一由 UTC 转 Asia/Shanghai 后去时区标注再连接。
- **量的口径**：volume 与 money 为分钟增量，open_interest 为分钟末的存量。
- **质量核验**：五个主用品种的重复时间戳 0、OHLC 违例 0；零成交量 K 线 SC 301 根、AG 70 根，其余为 0。

4.5 时段、休市与换月：逐条处理

（一）交易时段的确切分钟。 日盘每日 225 根，分三段连续：09:01--10:15 (75 根)、10:31--11:30 (60 根)、13:31--15:00 (90 根)。夜盘自 21:01 起单段连续，收盘时刻**由数据实测而非硬编码**（取每日夜盘末根的众数）：SC/AU/AG 为 02:30 (330 根)、CU 为 01:00 (240 根)、M 为 23:00 (120 根)。

（二）夜盘归属。 夜盘 K 线存放在次一自然日的文件中（故周一文件从不含夜盘）。按时间戳重新归属： T 日夜盘归属 $T+1$ 交易日，即夜盘在一个交易日内先于日盘。测试断言周一交易日含上周五 21:01 至周六 02:30。交易日全集由”存在日盘 K 线的自然日”实测得到，不依赖假日表。

（三）休市与前向收益：连续分钟段规则。 不枚举休市时刻，而用一条统一规则：相邻 K 线时间差 $\neq 1$ 分钟即断段，

$$\text{seg}_t \triangleq \sum_{u \leq t} \mathbf{1}\{\Delta ts_u \neq 1\text{min}\}, \quad \text{fwd}_{h,t} \triangleq (\ln C_{t+h} - \ln C_t) \cdot \mathbf{1}\{\text{seg}_{t+h} = \text{seg}_t\}.$$

其中 C_t 为期货这一分钟的收盘价 ($C = \text{close}$)， h 为前向分钟数（取 1/2/3/5/10/15）， Δts_u 为相邻两根 K 线的时间差， $\mathbf{1}\{\cdot\}$ 是**指示函数**（括号内条件成立取 1、否则取 0）， seg_t 为连续段编号。读法：只有当 t 与 $t+h$ 落在同一连续段（seg 相等）时才计算前向收益，否则乘以 0 记为缺失。该规则对上午小节休息（10:15→10:30）、午间休市（11:30→13:30）、日盘收至夜盘开（15:00→21:00）、夜盘收至次日开盘、周末与假日**一视同仁**，跨段一律置缺失而非跨越。**任何前向收益都不跨越休市，也不跨日。**

实测结果与该规则严格自治：每个品种 125 天共 **495 个连续段**（日盘 3 段 $\times$ 125 + 夜盘 120 段；5 个无夜盘日均为长假后首日）。 fwd_{15} 的有效占比恰等于 $1 - 15 \times 495/N$ ：SC/AU/AG 为 89.04%、CU 86.96%、M 82.54%——即**段尾截断是标签缺失的唯一来源**。

（四）涨跌停。 主力连续序列不带涨跌停价表，故以 $\text{locked}_t \triangleq \mathbf{1}\{H_t = L_t\}$ 作代理。实测占比：SC 2.43%、AG 0.77%、M 0.29%、CU 0.24%、AU 0.03%。已知极端例：2026-03-09 SC 日盘 225 根全部锁死（一字涨停）。**须诚实声明**：该代理无法区分”清淡无成交”与”封板”，且**当前分析中它只作监控，未作为过滤条件参与任何 IC 或事件研究**。封板期收益被截断，方向上使结果偏保守（低估可实现收益的同时也低估了不可成交性）。

(五) 换月。主力序列由数据方给出（其判定规则未公开，登记为未核实项）。实测切换全部发生在 21:01，即交易日边界，故一个交易日内合约唯一（多合约日数 = 0）；样本内切换次数 SC 6 次、CU 6 次、AU 3 次、AG 2 次、M 1 次，段中切换 0 次。分钟层因此无需额外换月掩码——切换点必为夜盘段首根，其 r_1 本已缺失，且无任何前向窗口可跨越它。日频层另行显式剔除换月日。

4.6 时差与窗口切分

北京与美东相差 12–13 小时（夏令时切换由时区库处理），国内凌晨闭市段恰对应美东主活跃时段，这是识别设计的基础。图 1(a) 给出实测证据：登记市场的成交笔数在北京时 21:00–06:00 显著高于日盘时段，而这正是国内期货休市或夜盘时段。




图 1: (a) Polymarket 登记市场成交笔数与 SC 成交量的日内分布（北京时，125 天均值；灰底为 SC 交易时段，休市处期货曲线断开）。(b) 防前视的时间关系：分钟桶右端标签使信号严格早于被解释的收益。

表 6: 交易日四段窗口（SC；其余品种按各自夜盘收盘时刻定义）

窗口	北京时间	对应美东	窗口收益定义
傍晚闭市 gap_pm	前日 15:00→21:00	凌晨 → 上午	$\ln(\text{夜盘开}/\text{前日收})$
夜盘 night	21:00→02:30	上午 → 下午	$\ln(\text{夜盘收}/\text{夜盘开})$
凌晨闭市 gap_am	02:30→09:00	下午 → 晚间	$\ln(\text{日盘开}/\text{夜盘收})$
日盘 day	09:00→15:00	美国深夜	$\ln(\text{日盘收}/\text{日盘开})$

4.7 防前视协议 (清单)

1. 分钟桶标签取右端, 信号桶严格早于期货 K 线收盘戳 (图 1b);
2. 市场准入时点化, 聚合权重用时点化累计成交额;
3. 全部滚动 / 展开统计量只用 $\leq t$ 的观测 (z 分数、MAD 阈值、展开分位数一律 `shift(1)` 或严格 $< t$ 估计);
4. 测量模型参数在样本前段 (2026-05-15 前) 估计后冻结, 其后因果应用;
5. 结算后价格、超时报价、换月日一律记缺失而非填充;
6. 全部定义与阈值已冻结并哈希登记 (`freeze/manifest.json`), 2026-07-18 之后为未触碰样本。

5 信号定义

5.1 设计原则与数值化的合理性

信号库共 40 个分钟级信号, 分四族各 10 个。设计遵循四条原则:

1. **一律数值化、且默认有大小顺序。** 离散事件不以布尔量入库, 而以签名值 $\{-1, 0, +1\}$ 或强度值 (计数、衰减和、一致率) 表示, 使得秩相关有意义、可直接进入线性组合。
2. **一律时序归一化。** 所有与量纲相关的量取滚动 z 分数

$$z_W(x_t) \triangleq \frac{x_t - \mu_W(x_t)}{\sigma_W(x_t)}, \quad W = 4800 \text{ 交易分钟 (约 10 个 SC 交易日)}, \text{ 最少 960 个观测,}$$

滚动窗只用 $\leq t$ 的观测。这既使跨品种可比, 也吸收了波动与成交量的日内与月度水平漂移。

3. **有界化优先。** 凡能构造为比值的 ($N5$ 流不平衡比、 $K8$ 方向一致率) 取有界形式, 避免极端值主导秩统计以外的用法。
4. **一族一机制。** N 族只用 Polymarket 数据, C 族引入期货量价, K 族把离散事件转为统计量, X 族做状态条件化。这样任何显著性都能归因到具体的数据来源 (见 §6.5 的族级结论)。

记号: $N1_t$ 为主题信念创新 (§4.3), $r1_t$ 为期货 1 分钟对数收益; m_t, v_t, u_t, a_t 分别为**此前 15 分钟**的涨幅、已实现波动、成交量、成交额经 z_{4800} 归一化后的值:

$$m_t = z_{4800} \left(\sum_{u=t-14}^t r1_u \right), \quad v_t = z_{4800} \left(\sqrt{\sum_{u=t-14}^t r1_u^2} \right),$$

$$u_t = z_{4800} \left(\sum_{u=t-14}^t V_u \right), \quad a_t = z_{4800} \left(\sum_{u=t-14}^t A_u \right);$$

f_t, U_t, n_t, M_t 为 15 分钟签名流、成交额、笔数与活跃市场数; κ_t 为稳健事件阈值,

$$\kappa_t = \max(3 \times 1.4826 \times \text{MAD}_{4800}(N1 \neq 0), 0.05), \quad e_t = \mathbf{1}\{N1_t > \kappa_t\} - \mathbf{1}\{N1_t < -\kappa_t\}.$$

5.2 N 族：数值信号（只用 Polymarket 数据）

表 7: N 族 10 个数值信号

信号	名称	公式	构造意图
N1	主题信念创新	$N1_t$	分钟级 logit 概率变化的加权聚合，全库基元
N2	15 分钟累积创新	$\sum_{u=t-14}^t N1_u$	单分钟创新噪声大，短窗求和提高信噪比
N3	签名流强度	$z_{4800}\left(\sum_{u=t-14}^t f_u\right)$	以美元计的方向性成交流，与价格变化互补
N4	创新标准分	$z_{4800}(N2_t)$	把量纲不可比的 logit 变化化为可跨品种比较的数值
N5	流不平衡比	$\left(\sum_{u=t-14}^t f_u\right) / \left(\sum_{u=t-14}^t U_u\right)$	方向性占比，剔除总量水平的影响，取值天然有界
N6	成交强度	$z_{4800}\left(\ln(1 + \sum_{u=t-14}^t n_u)\right)$	笔数强度衡量关注度，对数化压缩长尾
N7	多主题复合创新	$z_{4800}\left(\sum_{\theta} \sum_{u=t-14}^t N1_u^{\theta}\right)$	跨主题等权合成，捕捉宏观级共同冲击
N8	市场广度	$z_{4800}\left(\frac{1}{15} \sum_{u=t-14}^t M_u\right)$	参与市场数衡量信息是集中于个别市场还是普遍
N9	信念波动	$z_{4800}(\text{sd}_{60}(N1))$	二阶量：信念本身的不稳定程度（分歧度代理）
N10	信念不确定度	$z_{4800}\left(\sum_{u=t-14}^t N1_u \right)$	无向活跃度，与 N2 的有向量配对识别方向性 vs 纯噪声

5.3 C 族：与标的量价数据组合的信号

表 8: C 族 10 个量价组合信号 (m, v, u, a 均为前 15 分钟量价统计量的 z_{4800} 归一化值)

信号	名称	公式	构造意图
C1	创新 $\times$ 涨幅 (确认)	$N4_t \cdot m_t$	事件与价格同向时放大: 信息被确认
C2	创新 $\times$ 价未动	$N4_t \cdot \mathbf{1}\{ m_t < 0.5\}$	事件已发生而价格未反应, 滞后反应假说的直接检验
C3	波动折减创新	$N4_t / (1 + \max(v_t, 0))$	高波动期同样的创新信息含量更低, 按波动折减
C4	创新 $\times$ 放量	$N4_t \cdot u_t$	成交量确认: 有量的事件更可能推动价格
C5	流价同向	$N3_t \cdot \mathbf{1}\{\text{sign}(N3_t m_t) > 0\}$	只在预测市场资金流与期货价格同向时取值
C6	创新 $\times$ 波动状态	$N4_t \cdot v_t$	波动状态交互, 检验信息传导是否依赖市场状态
C7	正交化创新	$N4_t - \hat{\beta}_t m_t, \quad \hat{\beta}_t = \frac{E_{4800}[N4_t m_t]}{E_{4800}[m_t^2]}$	滚动回归剔除动量分量, 留下 Polymarket 的正交信息
C8	未兑现缺口	$z_{4800}\left(\sum_{u=t-119}^t N1_u\right) - z_{4800}\left(\sum_{u=t-119}^t r1_u\right)$	信念已动而价格未动的累积差; 注意第二腿本身是反转因子
C9	不平衡 $\times$ 成交额	$N5_t \cdot a_t$	以期货成交额加权方向性占比, 量价双重确认
C10	信念波动 - 实现波动	$N9_t - v_t$	两个市场的波动预期之差, 跨市场相对不确定度

5.4 K 族：基于原始离散事件的复杂统计指标

表 9: K 族 10 个复杂统计指标（时序分桶、频率、游程、到达率、截面计数）

信号	名称	公式	构造意图
K1	净事件计数	$\sum_{u=t-59}^t e_u$	1 小时窗内上行减下行事件数，最直接的频率统计
K2	分时频率异常	$(c_t - \mu_{h(t)}) / \sigma_{h(t)}, \quad c_t = \sum_{u=t-59}^t \mathbf{1}\{ N1_u > \kappa_u\}$	时序分桶：按小时分桶后标准化，剔除事件到达的日内季节性
K3	跨主题事件计数	$\sum_{u=t-59}^t \sum_{\theta} \mathbf{1}\{ N1_u^\theta > \kappa_u\}$	截面统计：同一宏观冲击在多主题同时触发的计数
K4	指数衰减强度	$K4_t = \lambda K4_{t-1} + e_t, \quad \lambda = e^{-1/30}$	半衰期约 21 分钟的加权累计，近期事件权重更高
K5	同向连发长度	$\max_{u \in [t-29, t]} L_u, \quad L_u = \text{连续同向事件游程长}$	游程统计：连续同向触发是趋势性信息的标志
K6	近因得分	$e^{-g_t/60} \cdot \text{sign}(e_{\tau(t)}), \quad g_t = t - \tau(t)$ (上次事件)	距上次事件越近权重越高，把离散事件转为连续衰减值
K7	尾部幅度和	$z_{4800} \left(\sum_{u=t-59}^t N1_u \mathbf{1}\{ N1_u > \kappa_u\} \right)$	只累计超阈值部分的幅度，区分「多次小跳」与「一次大跳」
K8	方向一致率	$\frac{U_{120} - D_{120}}{U_{120} + D_{120}}, \quad U_{120} = \sum_{u=t-119}^t \mathbf{1}\{N1_u > \kappa_u\}$	2 小时窗内方向纯度，取值有界于 $[-1, 1]$
K9	到达率热度	$(1 + \text{med}_5(\Delta\tau))^{-1}$	最近 5 次事件间隔中位数的倒数，泊松强度的稳健估计
K10	跨主题共振	$\mathbf{1}\left\{ \sum_{\theta} \max_{u \in [t-14, t]} \mathbf{1}\{ N1_u^\theta > \kappa_u\} \geq 2 \right\} \cdot \text{sign}(N2_t)$	至少两个主题在 15 分钟内同时触发，签名化为 $\{-1, 0, 1\}$

5.5 X 族：条件与状态交互信号

表 10: X 族 10 个条件信号（签名离散型，取值 $\{-1, 0, +1\}$ ）

信号	名称	公式	构造意图
X1	共振 + 期货确认	$K10_t \cdot \mathbf{1}\{\text{sign}(K10_t m_t) > 0\}$	共振且期货同向，最强确认态
X2	共振但价未动	$K10_t \cdot \mathbf{1}\{ m_t < 0.5\}$	共振而期货无反应，未兑现共振
X3	事件 × 高波动	$e_t \cdot \mathbf{1}\{v_t > 1\}$	状态交互：波动放大期的事件
X4	事件 × 放量	$e_t \cdot \mathbf{1}\{u_t > 1\}$	状态交互：成交放大期的事件
X5	一小时内同向二击	$\mathbf{1}\{N1_t > \kappa_t, U_{60} \geq 2\} - \mathbf{1}\{N1_t < -\kappa_t, D_{60} \geq 2\}$	同向重复触发，过滤单次噪声
X6	大额 + 价未动	$\text{sign}(f_t) \cdot \mathbf{1}\{U_t > q_{0.99}\} \cdot \mathbf{1}\{ m_t < 0.5\}$	分钟成交额超展开 99 分位而期货未动
X7	事件 × 夜盘	$e_t \cdot \mathbf{1}\{\text{夜盘}\}$	时段交互：夜盘与美东活跃时段重叠
X8	事件 × 开盘 30 分钟	$e_t \cdot \mathbf{1}\{\text{日盘前 30 分钟}\}$	时段交互：隔夜信息集中释放的窗口
X9	延迟反应	$e_{t-3} \cdot \mathbf{1}\{ r_{t-2 \rightarrow t} < 0.3 \text{rv}15_t\}$	3 分钟前有事件而价格仍未动，滞后交易的直接构造
X10	多尺度同向	$e_t \cdot \mathbf{1}\{\text{sign}(N1_t (N2_t - N1_t)) > 0\}$	当刻跳与此前 14 分钟累积同向，多尺度一致性确认

5.6 另行登记的事件跳因子 (J 族)

15 分钟桶 $|\Delta\ell|$ 超过 $3 \times 1.4826 \times \text{MAD}_{48\text{桶}}$ 且桶内成交 $\geq \$10,000$ ；同主题同时戳折叠为一个事件， $J_{\text{evt}} = \sqrt{\text{usdc}}$ 加权的 $\text{orientation} \times \Delta\ell$ 。两个冻结登记单元：SC 盘中日盘跳（映射到期货分钟网格延迟 ≤ 2 分钟且落在日盘）；M 孤立跳（同桶无其他市场共跳， $n_{\text{cojump}} = 0$ ）。公式与推断见完整版 § 三-5b。

6 指标口径与统计结果

6.1 IC 的数学定义

对信号 s 与视界 $h \in \{1, 2, 3, 5, 10, 15\}$ 分钟：

$$\text{pooled RankIC}_h \triangleq \rho_S(s_t, \text{fwd}_{h,t}) \quad (\text{全部有效分钟行的 Spearman 秩相关}), \quad (1)$$

$$\text{IC}_h^{(d)} \triangleq \rho_S(s_t, \text{fwd}_{h,t} \mid t \in \text{交易日}d) \quad (\text{日内有效行} \geq 30、\text{且 } s \text{ 非常数}), \quad (2)$$

$$\text{ICIR}_h \triangleq \frac{\overline{\text{IC}_h^{(d)}}}{\text{sd}(\text{IC}_h^{(d)})}, \quad t_h \triangleq \text{ICIR}_h \sqrt{D}, \quad (3)$$

D 为有效交易日数。Pearson IC 同式以线性相关代入，全表已算但因分钟收益的厚尾而以 RankIC 为主口径。

离散信号的事件研究口径。 对签名离散信号，取 $s_t = +1$ （上行触发）的全部时点，报告：

- 频率：触发次数 / 5.95 个月（125 交易日 / 21）；
- 条件收益：各视界 $\overline{\text{fwd}_h}$ ，单位 bp；
- 终止条件视界：从触发到下一次触发前一分钟的收益（同段内，上限 60 分钟），并报告平均持有分钟数；
- 显著变动比例： $P(|\text{fwd}_h| > 10\text{bp})$ （即价格变动超过千分之一的比例）；
- 基准：同品种全样本无条件的 $\overline{\text{fwd}_h}$ 与 $P(|\text{fwd}_h| > 10\text{bp})$ 。须声明：因期货分钟数据只有 125 天，无法构造“过去一年”的基准，故用全样本无条件量代替；
- 检验： $H_0: \mathbb{E}[\text{fwd}_h \mid s = +1] = \text{基准均值}$ ， t 统计量按交易日聚类稳健估计（触发在时间上高度成簇，普通 t 会严重高估显著性）。

6.2 全信号登记表

6.3 连续信号：IC 期限结构

6.4 离散信号：频率与事件研究

6.5 多重检验下的族级结论

这是本节最重要的结果。

表 11: 40 个信号的登记全表: 类型、频率、取值统计与跨品种 RankIC。”最大 $|t|$ ”取该信号在 5 个品种 $\times 6$ 视界共 30 个格上的最大绝对 t , 括号内为对应品种

信号	类型	月频 (均)	取值统计 (跨品种均)	RankIC $\times 100$ (1'/5'/15')	最大 $ t $	符号一致率
N1	连续	4,612 分钟	$\mu-0.00, \sigma 0.03, \text{kurt} +23.4$	-0.10 / -0.08 / +0.08	2.58 (SC)	60%
N2	连续	6,841 分钟	$\mu-0.00, \sigma 0.10, \text{kurt} +18.2$	-0.07 / +0.04 / +0.55	1.81 (CU)	53%
N3	连续	9,386 分钟	$\mu+0.01, \sigma 1.32, \text{kurt} +178.0$	-0.05 / -0.17 / -0.29	1.95 (AG)	53%
N4	连续	9,254 分钟	$\mu+0.00, \sigma 1.10, \text{kurt} +138.2$	+0.03 / +0.12 / +0.56	1.55 (M)	57%
N5	连续	7,540 分钟	$\mu+0.02, \sigma 0.60, \text{kurt} -1.5$	+0.07 / +0.08 / +0.24	2.43 (AG)	53%
N6	连续	9,386 分钟	$\mu+0.00, \sigma 1.15, \text{kurt} +104.4$	+0.16 / +0.20 / +0.39	1.80 (M)	73%
N7	连续	9,530 分钟	$\mu+0.00, \sigma 1.10, \text{kurt} +67.5$	+0.04 / -0.01 / +0.90	1.55 (M)	53%
N8	连续	9,385 分钟	$\mu+0.03, \sigma 1.22, \text{kurt} +100.0$	+0.16 / +0.21 / +0.39	1.88 (M)	80%
N9	连续	9,255 分钟	$\mu+0.06, \sigma 1.20, \text{kurt} +101.8$	+0.01 / +0.03 / +0.19	1.80 (M)	60%
N10	连续	9,254 分钟	$\mu+0.03, \sigma 1.16, \text{kurt} +128.9$	-0.03 / -0.02 / +0.15	2.69 (M)	53%
C1	连续	8,879 分钟	$\mu+0.02, \sigma 1.38, \text{kurt} +545.9$	-0.66 / -0.55 / +0.22	4.39* (CU)	67%
C2	连续	4,888 分钟	$\mu+0.00, \sigma 0.80, \text{kurt} +212.0$	-0.08 / -0.26 / +0.02	2.89 (CU)	60%
C3	连续	9,254 分钟	$\mu+0.00, \sigma 0.96, \text{kurt} +188.4$	+0.01 / +0.04 / +0.49	1.76 (CU)	53%
C4	连续	8,954 分钟	$\mu-0.01, \sigma 1.48, \text{kurt} +393.0$	-0.04 / +0.16 / +0.18	2.00 (M)	60%
C5	连续	4,519 分钟	$\mu+0.01, \sigma 0.96, \text{kurt} +151.4$	-2.03 / -1.43 / -0.72	10.42* (M)	97%
C6	连续	8,879 分钟	$\mu-0.02, \sigma 1.53, \text{kurt} +545.1$	-0.03 / +0.11 / +0.36	2.19 (CU)	57%
C7	连续	9,416 分钟	$\mu+0.00, \sigma 1.10, \text{kurt} +139.2$	+0.32 / +0.15 / +0.30	3.99 (AG)	60%
C8	连续	10,002 分钟	$\mu+0.00, \sigma 1.51, \text{kurt} +56.3$	+1.37 / +1.68 / +1.64	12.85* (M)	100%
C9	连续	7,235 分钟	$\mu+0.01, \sigma 0.66, \text{kurt} +26.1$	-0.24 / -0.46 / -0.81	2.29 (SC)	63%
C10	连续	9,965 分钟	$\mu+0.08, \sigma 1.57, \text{kurt} +55.8$	-0.51 / -0.85 / -0.76	4.81* (AU)	83%
K1	计数	4,536 分钟	$\mu-0.05, \sigma 1.18, \text{kurt} +0.6$	-0.08 / -0.19 / -0.49	2.18 (AG)	73%
K2	连续	8,822 分钟	$\mu+0.07, \sigma 1.28, \text{kurt} +7.2$	-0.09 / -0.27 / -0.05	2.67 (M)	57%
K3	计数	7,422 分钟	$\mu+4.22, \sigma 4.41, \text{kurt} +3.7$	+0.08 / +0.38 / +0.85	1.50 (SC)	93%
K4	连续	9,680 分钟	$\mu-0.02, \sigma 0.61, \text{kurt} +7.4$	+0.04 / +0.28 / +0.28	2.66 (AG)	60%
K5	离散	2,837 次	{0, 1, 2, 3, 4}, 非零 26.70%	+0.12 / +0.06 / +0.51	2.01 (CU)	53%
K6	连续	9,680 分钟	$\mu-0.00, \sigma 0.59, \text{kurt} -0.9$	-0.02 / +0.30 / +0.58	2.26 (M)	73%
K7	连续	9,254 分钟	$\mu+0.08, \sigma 1.25, \text{kurt} +90.4$	+0.06 / +0.24 / +0.56	3.24 (M)	53%
K8	连续	5,621 分钟	$\mu-0.02, \sigma 0.46, \text{kurt} -0.8$	+0.09 / +0.27 / +0.23	2.34 (AG)	63%
K9	连续	9,677 分钟	$\mu+0.10, \sigma 0.11, \text{kurt} +3.8$	-0.29 / -0.52 / -0.97	1.76 (M)	77%
K10	离散	916 次	{-1, 0, 1}, 非零 8.29%	-0.14 / +0.02 / -0.12	1.29 (SC)	67%
X1	离散	452 次	{-1, 0, 1}, 非零 4.08%	-0.75 / -0.70 / -0.68	1.81 (CU)	67%
X2	离散	483 次	{-1, 0, 1}, 非零 4.36%	-0.14 / -0.33 / -0.71	2.48 (CU)	83%
X3	离散	55 次	{-1, 0, 1}, 非零 0.54%	+0.05 / -0.09 / -0.06	2.57 (AU)	83%
X4	离散	54 次	{-1, 0, 1}, 非零 0.52%	+0.10 / -0.29 / -0.16	2.20 (AU)	67%
X5	离散	323 次	{-1, 0, 1}, 非零 3.05%	-0.11 / -0.04 / -0.00	2.91 (AU)	60%
X6	离散	30 次	{-1, 0, 1}, 非零 0.27%	+0.32 / +0.31 / +0.22	2.65 (AU)	72%
X7	离散	215 次	{-1, 0, 1}, 非零 2.01%	-0.10 / -0.12 / +0.07	2.56 (AU)	77%
X8	离散	24 次	{-1, 0, 1}, 非零 0.23%	-0.37 / -0.16 / +0.13	3.04 (M)	60%
X9	离散	199 次	{-1, 0, 1}, 非零 1.90%	-0.07 / +0.07 / -0.06	2.15 (AU)	57%
X10	离散	144 次	{-1, 0, 1}, 非零 1.35%	-0.31 / -0.03 / -0.20	2.68 (CU)	57%

表 12: $|t|$ 最大的 14 个连续信号格的六视界 RankIC ($\times 100$)

信号 · 品种	1'	2'	3'	5'	10'	15'	ICIR ₁₅	t_{15}
C8·M	+1.59	+1.40	+1.24	+1.09	+0.93	+0.48	+0.73	+8.06
C8·CU	+1.41	+1.64	+1.78	+1.85	+1.97	+1.96	+0.61	+6.77
C5·M	-3.31	-3.10	-2.71	-2.36	-2.04	-1.43	-0.21	-2.09
C8·AG	+1.25	+1.26	+1.33	+1.33	+0.60	+0.31	+0.43	+4.72
C8·SC	+1.61	+1.96	+2.30	+2.60	+2.98	+3.28	+0.61	+6.81
C8·AU	+0.97	+1.18	+1.19	+1.54	+1.87	+2.19	+0.77	+8.48
C5·AG	-2.11	-1.82	-1.62	-1.44	-0.86	-1.38	-0.25	-2.60
C5·CU	-1.80	-1.34	-1.41	-0.94	-0.29	+0.12	-0.07	-0.74
C5·SC	-1.69	-1.52	-1.32	-1.00	-0.30	-0.09	-0.23	-2.51
C5·AU	-1.22	-1.39	-1.28	-1.39	-0.79	-0.82	-0.22	-2.44
C10·AU	-0.87	-1.30	-1.42	-1.77	-2.49	-3.15	-0.36	-3.95
C1·CU	-1.11	-0.94	-0.63	-0.18	+1.28	+2.01	+0.02	+0.21
C1·AG	-1.34	-1.38	-1.68	-1.75	-1.32	-1.06	-0.20	-2.08
C7·AG	+0.99	+0.89	+0.66	+0.19	-0.38	-0.68	-0.02	-0.22




图 2: (a) RankIC 的期限结构热图; (b) 15 分钟视界的 ICIR。注意入选的 14 个格全部来自 C 族——即全部含期货侧量价腿。

每类信号按其适当口径检验。连续与计数信号用 IC 的 t ; 离散信号用事件研究的 t , 不用 IC。理由是离散信号取值只有 $\{-1, 0, +1\}$ 且九成以上为 0, 在其上算秩相关会因海量并列而退化, “触发之后是否真的动了”才是它的适当判据 (§6 的事件研究口径)。合计 1,476 个检验 (连续 IC 840

表 13: 离散信号事件研究 (取 $s > 0$ 触发; $n \geq 100$ 的格中 $\max |t|$ 前 14)。1' 至 15' 六列一律为超额收益, 即”触发后条件均值 - 同品种无条件基准”, 与右端 $\max |t|$ 所检验的量**完全一致** (H_0 : 超额为零); 毛收益与基准分量见图 3。”至下次”为终止条件视界收益, 因持有分钟数逐次不同、无单一基准可减, 故为**毛值** (括号内为平均持有分钟数)。末两列是另一口径: $P_{10'}$ 为 10 分钟内价格变动超 10bp 的比例 (非收益), ”基准”为同品种无条件同口径比例

		超额收益 (bp): 条件均值 - 同品种无条件基准						至下次 $P_{10'}$ 超 10bp 比例			
信号 · 品种	次/月	1'	2'	3'	5'	10'	15'	毛值	触发后	基准	$\max t $
X6-AU	37	+0.93	+1.32	+0.33	-0.21	-1.06	+0.26	-3.48 (32')	39.0%	40.6%	2.65
X2-CU	182	-0.26	-0.47	-0.63	-1.07	-1.71	-1.32	+0.54 (24')	36.9%	38.1%	2.48
X10-AU	125	+0.46	+0.62	+0.53	+0.63	+0.88	+1.32	-0.86 (27')	36.8%	40.6%	2.36
X7-AU	177	+0.37	+0.44	-0.02	+0.15	+0.78	+1.27	-0.15 (20')	37.0%	40.6%	2.27
X5-CU	46	+0.24	+0.94	+0.83	+1.02	+1.80	+1.60	+0.96 (28')	34.3%	38.1%	2.19
X9-AU	162	-0.10	-0.25	-0.48	-0.42	+0.23	+0.39	-0.61 (26')	37.4%	40.6%	2.15
K5-CU	1401	+0.10	+0.19	+0.30	+0.51	+0.84	+1.17	+0.58 (36')	38.9%	38.1%	2.01
X8-AU	18	-1.27	-1.13	-1.61	-1.66	-0.49	-1.64	-3.96 (36')	52.8%	40.6%	1.96
X9-AG	65	+0.39	+0.43	-0.00	+0.42	+4.31	+3.03	-2.66 (35')	73.1%	69.0%	1.88
X5-AU	290	+0.18	+0.14	-0.05	-0.09	+0.08	+0.56	-0.56 (16')	36.7%	40.6%	1.84
X10-AG	44	-1.64	-4.10	-3.86	-4.69	-6.80	-7.21	-9.97 (30')	76.9%	69.0%	1.83
X1-CU	163	-0.31	-0.43	-0.45	-0.37	+0.20	+1.41	-1.44 (25')	37.3%	38.1%	1.81
X9-M	54	+0.12	+0.22	+0.84	+0.55	-0.28	-0.55	-0.78 (23')	38.8%	36.2%	1.78
X4-AU	43	+0.90	+1.74	+0.87	+1.61	+3.61	+3.66	-3.04 (29')	63.6%	40.6%	1.75

离散信号触发后的收益路径 ($|t|$ 最大的 6 个格): 两线之间的填色即超额收益 (表 13 所印、也是 t 检验的量)。全部 636 个事件检验 $\max |t| = 3.04 < \text{Bonferroni 门槛 } 3.95$, 无一通过




图 3: 离散信号触发后的收益路径 ($|t|$ 最大的 6 个格)。**实线**为触发后条件均值 (毛值), **虚线**为同品种无条件基准, **两线之间的填色即超额收益** (蓝 = 正、红 = 负), 也就是表 13 六列所印、以及 $\max |t|$ 所检验的那个量。本图与表 13 的关系: 本图给两个分量, 表给二者之差。

个 + 离散事件 636 个), 统一 Bonferroni 门槛 $|t| > 4.15$ 。按族分解:

两句话读法:

1. 只用 Polymarket 数据构造的 23 个信号 (N 族 10 个、K 族 10 个、以及 X 族中不含期

表 14: 族级多重检验结论 (各族按适当口径: 连续用 IC、离散用事件研究; 统一门槛 $|t| > 4.15$ 。数据由 `make_concise_table.py` 从 `signal_grid.parquet` 计算)

族	数据来源	检验数	$\max t $	通过门槛
N	仅 Polymarket	300	2.69	0
K	仅 Polymarket	318	3.24	0
X	Polymarket + 期货状态	558	3.04	0
C	Polymarket $\times$ 期货量价	300	12.85	49
仅用 Polymarket 数据的 23 个信号		798	3.24	0

货腿的 X5/X7/X10), 在 798 个检验中 $\max |t| = 3.24$, 无一通过门槛。

- 全部 13 个通过门槛的信号格 (C1、C5、C8、C10 各若干品种) 无一例外来自 C 族, 即无一例外含有期货侧量价腿; 没有任何一个纯 Polymarket 信号格、也没有任何一个离散事件信号格通过。C8 经双腿分解与严格增量检验, 其强度由期货自身的短期反转承载, Polymarket 腿的分钟级增量已被否定 (五品种全部未通过预设确认门槛)。

一处必须交代的口径修正。 若对离散信号误用 IC 口径, X1·SC 与 X6·AG 会显示 $|t| = 4.80$ 与 5.20、看似通过门槛; 但改用适当的事件研究口径后二者分别只有 1.10 与 2.46, 均不通过。其中 X6·AG 的上行触发仅 6 次, 属退化格。这说明在 $\{-1, 0, +1\}$ 上算秩相关确实会产生假阳性, 报告采用事件研究口径后, 离散侧通过门槛的格数为零。

为什么用 $|t|$, 以及 $|t|$ 丢掉了什么。 本文 40 个信号中绝大多数是探索性的、事先未登记方向先验, 故只能做双侧检验 (H_0 : 无关系; 备择: 有关系、方向不限), 门槛按 $|t|$ 设定。若改用单侧, 等于事后按看到的方向选检验方向, 属放松门槛、会制造假阳性。

但 $|t|$ 有一个信息损失: 它不告诉你方向是否连贯。一个信号在 $h = 1$ 为正、 $h = 15$ 为负, 仍可能报出较大的 $\max |t|$, 而这种符号乱跳多半是噪声而非信号。故补报符号一致率——跨 5 品种 $\times$ 6 视界共 30 个格中, 占多数的那个符号的占比 (离散信号按事件研究超额取符号)。纯噪声下 30 个独立格的期望值为 57%, 真信号趋近 100%。

这一维度给出的结论与 $|t|$ 一致, 且更锋利:

- 纯 Polymarket 侧最强的那个格, 方向完全不连贯。 $\max |t| = 3.24$ 出自 K7, 而 K7 的符号一致率只有 53%——比纯噪声的期望 57% 还低。其逐品种符号为 SC -++++、AU -++++、AG +++++、CU -++++、M +++++ (3.24 正出在 M, 而 M 自己在 $h = 1$ 与 $h = 2$ 之间就已反号)。纯 PM 全部 23 个信号的一致率中位为 60%, 同样落在噪声区间。

• 对照旗舰信号 C8: 30 个格全部同号, 一致率 100%。方向连贯性在此是真实存在的——但须重复本节已确立的归因: C8 的强度由期货自身的短期反转腿承载, 不是 Polymarket 腿。因此分钟频率上的结论是干净的, 且经两个相互独立的维度互证: 按 $|t|$ 无一通过门槛; 按方向一致性, 纯 Polymarket 信号连一个连贯方向都没有。显著性全部来自期货侧, 没有一点来自 Polymarket 侧。表 13 中离散信号的 $P_{10'}$ 与基准比例也几乎处处相当, 与此一致。

6.6 检出力与最小可检测效应

必须回答的一问：这是真的没有，还是 125 天太短看不出来？只报“未通过门槛”是不够的：Bonferroni 是往保守方向的修正，用一个更难拒绝零假设的门槛去支撑“没有信号”，形式上恰好是反的。因此本节给出 **最小可检测效应**（MDE）：在既有样本与既定门槛下，多大的效应会被我们以 80% 的把握检出。凡大于 MDE 的效应，本样本**已经排除**；凡小于 MDE 的，本样本**无法分辨**，只能留待未触碰样本裁决。

标准误由已有量精确反解，不引入任何新假设：连续侧 $SE = \text{sd}(\text{IC}^{(d)})/\sqrt{D}$ （即 $t = \text{ICIR}\sqrt{D}$ 的反解）；离散侧 $SE = |\text{条件超额}|/|t|$ （日聚类 t 的反解，限 $n_+ \geq 100$ ）。则

$$\text{MDE} = (z_\alpha + z_\beta) \times SE, \quad z_\alpha = 4.15 \text{ (全族门槛)}, \quad z_\beta = 0.84 \text{ (检出力80\%)}.$$

表 15：最小可检测效应（各格取中位数；离散侧另给 p90 以示分布。数据由 `make_concise_table.py` 从 `signal_grid.parquet` 计算）

h	连续侧（RankIC 单位）		离散侧（bp）		
	SE 中位	MDE	SE 中位	MDE 中位	MDE p90
1	0.00385	0.0192	0.32	1.6	4.8
2	0.00531	0.0265	0.45	2.2	7.7
3	0.00642	0.0320	0.53	2.7	8.4
5	0.00830	0.0414	0.84	4.2	10.2
10	0.01183	0.0590	1.39	6.9	18.8
15	0.01404	0.0700	1.82	9.1	23.3

三点读法：

- 连续侧：**可检出的 RankIC 下限从 $h = 1$ 的 0.019 升到 $h = 15$ 的 0.070。与实测对照——六个视界无一例外，纯 Polymarket 信号实测的最大 $|\text{RankIC}|$ 都低于该视界的 MDE，且大致只有其一半（ $h = 1$ ：0.0102 对 0.0192； $h = 5$ ：0.0207 对 0.0414； $h = 15$ ：0.0392 对 0.0700）。即这些信号的效应量本就落在本样本可分辨的下限以下，“没检出”与“效应确实小于可分辨下限”两种解释在此是一致的。
- 离散侧与成本门槛的对照：** $h = 10$ 时中位格的 MDE 为 **6.9 bp**，低于完整换手成本门槛 16 bp。也就是说，任何在中位格上具备经济可交易性的效应（超过成本），都会被本样本检出——既然没有检出，就可以排除。但必须同时诚实报告：p90 格的 MDE 为 **18.8 bp**，高于成本门槛，故正确表述是“中位格可排除”，而非“全部格可排除”；检出力最弱的那部分格仍存在未被排除的空间。
- 有效天数不是 125：**逐日 IC 的有效交易日中位为 **109 天**（日内取值恒定或有效行不足 30 的交易日被剔除），正文一律不按 125 天计算检出力。

据此，本文的否定结论应读作：在中位检出力格的格上，成本门槛之上的整个效应区间已被排除；低于 MDE 的效应本样本不可分辨，不主张其为零，留待 2026-12 / 2027-01 的未触碰样本一次性裁决 (§7)。

6.7 规定格式登记表

机器可读源: docs/signal_summary.json (纯数字模式: 全部量化字段为 number、不适用为 null、单位在字段名或 meta.units)。

表 16: 登记信号主表 (IC / ICIR / 取 1 收益 / 符号 IC, 均为 1/3/10 分钟三元组)

品种	信号	类型	月频	RankIC	ICIR	取 1 收益 (bp)	符号 IC
SC	C8	连续	11.2k 分钟	+0.0161 / +0.0230 / +0.0298	+0.85 / +0.79 / +0.64	-	-
AU	C8	连续	11.2k 分钟	+0.0097 / +0.0119 / +0.0187	+0.79 / +0.80 / +0.78	-	-
AG	C8	连续	11.2k 分钟	+0.0125 / +0.0133 / +0.0060	+0.89 / +0.72 / +0.48	-	-
CU	C8	连续	9.4k 分钟	+0.0141 / +0.0178 / +0.0197	+0.97 / +0.83 / +0.68	-	-
M	C8	连续	7.0k 分钟	+0.0159 / +0.0124 / +0.0093	+1.16 / +0.95 / +0.79	-	-
SC	E1_up	离散	328 次	-	-	+0.01 / -0.36 / -0.74	+0.0027 / +0.0020 / -0.0007
SC	JUMP_SC_day	离散	24 次	-	-	+1.39 / +2.76 / +10.63	+0.0038 / +0.0070 / +0.0057
M	JUMP_M_isolated	离散	5 次	-	-	+0.13 / +0.45 / +3.36	+0.0040 / +0.0062 / +0.0044

表 17: 取值统计量 (连续: 矩统计; 离散: valuecount) 与非零频率

品种	信号	统计量 / valuecount	非零频率
SC	C8	$\mu=-0.013$, med=-0.010, $\sigma=1.356$, skew=-0.04, kurt=+1.53	98.54%
AU	C8	$\mu=+0.020$, med=+0.007, $\sigma=1.606$, skew=+0.33, kurt=+4.28	98.54%
AG	C8	$\mu=-0.003$, med=+0.052, $\sigma=1.461$, skew=-2.15, kurt=+204.41	98.54%
CU	C8	$\mu=-0.015$, med=+0.072, $\sigma=1.649$, skew=+0.98, kurt=+61.45	98.26%
M	C8	$\mu=+0.018$, med=+0.038, $\sigma=1.544$, skew=+0.87, kurt=+9.69	97.68%
SC	E1_up	-1: 2,015; 0: 63,759; 1: 1,951	5.86%
SC	JUMP_SC_day	-1: 134; 1: 143	0.41%
M	JUMP_M_isolated	-1: 25; 1: 28	0.12%

表 18: 品种全区间基准 (离散信号条件均值的对照; 剔除月日)

品种	收对收累计	无条件 1' (bp)	3' (bp)	10' (bp)
SC	+8.8%	+0.009	+0.006	-0.126
AU	-14.8%	-0.024	-0.077	-0.298
AG	-22.4%	-0.010	-0.066	-0.339
CU	+2.9%	-0.002	-0.015	-0.024
M	+5.7%	-0.004	-0.027	-0.134

读法示例: SC 盘中事件跳后 10 分钟条件均值 +10.63 bp, 应对照 SC 无条件 10 分钟均值 -0.13 bp 解读; 该格为置换单方法支持的探索候选、毛收益低于两倍成本门槛 (16 bp 完整换手)。

7 关键结果（模块化摘要）

以下每个模块：一句结论 + 关键数字 + 完整版出处（记法 $\S N =$ 完整版第 N 节， $\S$ 三- $N =$ 完整版附录三）。

7.1 吸收结构（A 级，全文最强结论）

国内闭市期间积累的事件概率变化在开盘跳空与夜盘被系统性定价。油价主题 $\times$ SC 傍晚细窗相关 0.86 ($n = 37$)、合并缺口 0.743 ($n = 74$)；中东 $\times$ 凌晨闭市段 0.70；循环置换 $p < 0.0005$ ；冲突高峰期内 / 外同号且期外更强 (0.35 / 0.68)。截面识别：88 品种按暴露度逐日排序（差分掉当日共同因子），截面 RankIC 0.185（经济先验载荷，HAC $t = 4.0$ ）与 0.261（估计载荷， $t = 5.0$ ），最高与最低五分位开盘前收益差约 100 bp/日，承载品种恰为能源链与贵金属。（§6、§12.12）

7.2 中东增量（A 级）

控制同窗国际基准（USO 等 12 资产）后，唯一稳定显著的配对：中东冲突概率对 SC，严格同窗 $t = 4.94$ ($n = 114$)；经济量级约 96 bp/ σ ；机制指向 INE 交割篮子的中东油种集中。LP-IV（第一阶段 $F = 42$ ）：事件驱动的油价变动传导系数 $\delta = 1.13$ 高于一般变动的 0.89。（§11、§12.8、§12.14）

7.3 反转 = SC-USO 相对收益回归（A 级）

事件日吸收 (+507 bp/ σ) 的 84% 来自 USO 分量；次日反转 (-226 bp) 的 81% 来自 SC 相对 USO 的收益分量，冲突高峰时累计相对偏离一度达 18% 后回归。该分量未经汇率 / 期限 / 油种调整，不等同于严格基差。（§11.3、§12.14）

7.4 否定结果（C/D 级，占结论的大多数）

7.5 数据层新发现：钱包技能真实且持续

对全部逐笔按 taker 钱包核算持有到结算盈亏 (5,831 万钱包 $\times$ 市场组合)：前后半段单位成交盈亏秩相关随活跃度单调升——散户层 0.026、 ≥ 100 市场 0.113、 ≥ 100 万美元 0.158 ($n = 35.8$ 万钱包)。技能存在，但其信息在窗口尺度已被价格聚合。（§12.13）

7.6 结论与投资定位

Polymarket 对中国商品期货的价值形态是**事件风险的实时测量**（开盘前风险敞口、品种排序、尾部旗标——旗标冻结样本初值 lift 3.28、Fisher $p = 0.007$ 、overlay 使 SC 持有回撤 -53% $\rightarrow$ -31%，2027 年初未触碰样本裁决），**不是方向 alpha**。实盘配置为零仓位；全部候选已冻结 (freeze/manifest.json)，裁决时点：SC 跳格 2026-12-31 或新增 95 个交易日先到者，R1-R4 与旗标 2027-01-31，各候选仅一次预约定检验。（§12.15-12.16）

表 19: 否定结果汇总（每行都是登记在案的完整检验）

命题	证据
分钟级无纯 PM 信号	23 个纯 Polymarket 信号 $\times$ 798 检验, $\max t = 3.24 <$ 门槛 4.15 (本文 §6.5, 新算)
日频方向不可预测	68 项预测检验 FDR 后全负; OOS 增量不为正; 截面预测 $IC \approx 0$ (三层互证)
波动水平预测无 OOS 增量	$\Delta R^2 \approx 0$, Clark–West $t \approx 0$
组合不放大信息	中东 $\times$ 油价交互 $t = -2.88$ (冗余); 共现无超额; 确认型组合跨品种一致为负
C8 的 PM 腿无分钟增量	五品种严格增量检验全部未通过 (逐日日内 partial t 0.6–1.8; 安慰剂 p 0.26–0.61; OOS $\Delta R^2 \approx 0$), 退出 alpha 候选
J 族仅单方法探索	SC 盘中跳: 置换 $p < 0.008$ 支持、HAC 一致 wild bootstrap $p = 0.17$ 不支持; 毛收益低于 $2\times$ 成本门槛; M 孤立跳 51 响应不显著 (t 1.41 / 0.87)
聪明钱窗口流无增量	技能钱包仅占主题成交额 2–5%; 锚配对预测全零; 吸收增量 $t \approx 1.0$ –1.3

8 复现

补充数据腿（零成本, `data/intl/`): Brent 与 USDCNH 日频经免费接口; 交易所逐合约日结算经公开端点 (`.../dailydata/kxYYYYMMDD.dat`, INE/SHFE 已核实可用)。

8.1 已登记的限制项

- 1. 期货分钟样本仅 125 个交易日, 且由单一事件 (中东冲突) 主导, 全部结论为探索性; 无法构造”过去一年”基准。
- 2. 分析层不保留链上日志主键, 行级回溯只在原始层成立 (§3.3)。
- 3. 撮合时刻不可观测, 时间戳为区块时间, 滞后量未测 (§3.4)。
- 4. 铸造匹配型成交未单独标记, 是否被中继腿判据完全覆盖未经证明 (§3.7)。
- 5. `negRisk` 市场在两段中均被排除, 2024 年美国大选等旗舰市场不在样本内。
- 6. `locked` 仅为 $H = L$ 代理, 且未参与任何过滤 (§4.5)。
- 7. 主力连续的换月判定规则由数据方决定, 未公开、未核实。
- 8. 分钟面板不做显式的买卖跳动去除: 桶内定价为成交额加权平均 (VWAP), 按方向分堆取加权中位数的显式去跳动只用于 15 分钟窗口级的吸收分析 (§4.3)。故分钟级 $N1$ 中残留的微观结构噪声大于窗口级, 方向上使分钟级信号的信噪比偏低、否定结论偏保守。

完整版 (151 页): `docs/` 下的 `cn_futures_polymarket_report.html` 与同名 PDF。
本文对应分支 `feat/cn-futures-polymarket`。

表 20: 复现命令链（全部数字构建时从产物计算，不手抄）

步骤	命令 / 产物
链上采集与统一 tape	<code>crawl_polymarket_chain.py</code> → <code>v3_build_tape.py</code>
期货分钟库	<code>build_cn_futures_db.py</code> (88 品种)
主题注册	<code>select_polymarket_markets.py</code> → <code>cn_registry_v3.parquet</code>
分钟面板与信号库	<code>v3_defense_build.py</code> (40 信号 + 前向收益)
全信号统计网格	<code>v3_signal_grid.py</code> → <code>defense/signal_grid.parquet</code> (200 格 × 129 列)
跳变因子	<code>v3_jump_factors.py</code> / <code>v3_jump_inference.py</code>
截面与钱包	<code>v3_cross_section.py</code> / <code>v3_wallet_skill.py</code>
规定格式登记表	<code>export_signal_summary.py</code> → <code>docs/signal_summary.json</code>
本文图	<code>v3_concise_figures.py</code> → <code>docs/concise/fig/</code>
本文表体	<code>make_concise_table.py</code> → <code>docs/concise/t*.tex</code>
本文编译	<code>xelatex main.tex</code> (两遍)
影子记录	<code>shadow_daily.py</code> → <code>shadow/records.jsonl</code> (追加不回改)
冻结对账	<code>freeze/manifest.json</code> (SHA256 + 终检日期)