

Polymarket 数据获取、处理与信号登记

中国商品期货关联研究 · 精炼版（数据方法为主体）

Alpha-Data 项目

2026 年 7 月（样本冻结于 2026-07-18）

摘要

本文是完整研究报告（cn_futures_polymarket_report.html, 151 页）的精炼版：以 **Polymarket 数据的获取与处理** 为主体逐条给出严格定义与构造方法，实验结果只保留模块化的关键结论。数据资产：链上逐笔成交 855,614,453 笔（约 265 亿美元、约 69 万个市场、2022-11-21 至 2026-07-14），与 88 个品种的中国期货 1 分钟数据（3,496,950 根 K 线）在 125 个重叠交易日（2026-01-05 至 07-13）上对齐。核心结论一句话：Polymarket 的信息含量真实存在，以**闭市时段的同期吸收**进入中国期货开盘价格并在开盘后数分钟内耗尽；经五轮复核（含两轮外部审计）与证伪型检验，**本研究不含已验证的可交易 alpha**，实盘配置为零仓位。

目录

1	数据资产总览与本文定位	1
2	Polymarket 数据获取	2
2.1	什么在链上，什么不在	2
2.2	两段数据与拼接	2
2.3	行级定义	2
2.4	机械成交剔除（两类，严格判据）	2
2.5	结算事件	3
3	数据处理	3
3.1	事件视角统一： p_{event} 与方向 D	3
3.2	主题注册与时点化准入	3
3.3	分钟聚合：从逐笔到主题信念创新 $N1$	3
3.4	期货侧：三个必须处理的事实	4
3.5	窗口切分与时差	4
3.6	防前视协议（清单）	4
4	信号定义与规定格式登记	5
4.1	信号库与 IC 口径	5
4.2	登记信号的严格定义	5
4.3	规定格式登记表	6

1 数据资产总览与本文定位2

5 关键结果（模块化摘要）6

5.1 吸收结构（A 级，全文最强结论）7

5.2 中东增量（A 级）7

5.3 反转 = SC-USO 相对收益回归（A 级）7

5.4 否定结果（C/D 级，占结论的大多数）7

5.5 数据层新发现：钱包技能真实且持续7

5.6 结论与投资定位7

6 复现8

1 数据资产总览与本文定位

表 1: 数据资产一览

数据层	规模	时间范围	来源
Polymarket 逐笔成交	855,614,453 笔 / \$26.5B	2022-11-21..2026-07-14	链上（两段拼接）
市场元数据与结算	约 69 万市场；结算 455/492	同上	链上 ConditionResolution
登记主题市场	8 主题 / 492 市场	事前注册	cn_registry_v3.parquet
中国期货分钟线	88 品种 / 3.50M 根	2026-01-05..07-13	本地交付 CSV
国际基准	USO/GLD 等 12 ETF 分钟	同重叠期	美股分钟库
补充数据腿	Brent/USDCNH 日频；逐合约日结算	见 §6	免费公开接口

本文写作原则：宁少勿糊。第 2-3 节（数据获取与处理）是主体，每个定义可直接据此复现；第 4 节给出登记信号的严格定义与规定格式登记表；第 5 节把全部实验压缩为模块化结论卡片，展开论证一律指向完整版对应章节（记法 §N = 完整版附录第 N 节，§ 三-N = 完整版附录三）。

2 Polymarket 数据获取

2.1 什么在链上，什么不在

Polymarket 的撮合是链下订单簿（挂单为链下签名消息，免 gas、可撤销、不可回溯），清算在链上（Polygon，出块约 2 秒）。因此：成交（OrderFilled 事件）与结算（ConditionResolution 事件）可完整、不可篡改地重建；历史盘口与挂单深度任何人都无法获取，点差只能用同分钟买卖两向成交的中位价差代理。这是本数据的结构性边界。

2.2 两段数据与拼接

- 公开数据集段（HuggingFace Polymarket-v1）：2022-11-21 至 2026-04-28。终点不是停更：旧交易所合约在 2026-04-28 11:00:40 UTC（区块 86,126,998）产生最后一笔成交后被 v2 合约取代。

- **自建爬虫段**：从区块 86,127,000 起，按 topic 扫描新旧两版 `OrderFilled` 事件重建同构数据，两段按区块号天然不重叠。
- **同质性检验**：v2 合约在 4 月 3 日已上线、与旧合约并行 25 天。抽样六个 3,000 区块窗口实测，并行期 v2 流量占比 $< 0.04\%$ ，拼接处无流量断层。

2.3 行级定义

每笔成交的主键与字段（幂等：重复爬取天然去重）：

$id \triangleq \text{链 ID_ 区块号_ 日志序号}$ (Polygon 链 ID = 137).

表 2: 逐笔成交字段（清洗层）

字段	定义
<code>maker / taker</code>	挂单方 / 吃单方钱包地址
<code>taker_direction</code>	由「谁付出哪种资产」判定（资产 0 = USDC；taker 付 USDC 即 taker 买入），来自资产转移事实、非推断
<code>price</code>	成交价 $\in (0, 1)$ ，USDC/份，= 该结果代币的隐含概率
<code>token_amount / usdc_amount</code>	份数与名义额， $usdc = price \times token$
<code>token_asset_id</code>	ERC-1155 positionId（关联市场元数据的外键；同市场 Yes/No 是两个不同 id）
<code>block_timestamp</code>	秒级 Unix 时间（UTC；链上区块时间非均匀，一切时间归并须重采样而非假设逐秒有行）

2.4 机械成交剔除（两类，严格判据）

链上原始记录含两类不代表方向性观点的行，直接累加会系统性歪曲成交量：

(一) 中继腿 (relay leg)。撮合合约 (CTF Exchange) 是中央对手方：一笔用户订单在 `OrderFilled` 中拆成「吃单方对撮合合约」的一条**总量记录** (中继腿) 与「撮合合约对各挂单方」的多条成分腿。判据：`taker = 撮合合约地址` $\Rightarrow$ 中继腿，剔除。保留会使成交量**恰好翻倍**。真实例证 (市场「特朗普 6 月 30 日前宣布美伊停火结束」, 2026-06-27 10:29:14 UTC)：三条成分腿 $2,196.87 + 26.51 + 4,966.93 = 7,190.31$ 份，与中继腿总量 7,190.31 恰等——同一笔卖单从 0.974 吃到 0.973 两档。

(二) 铸造与合并 (mint / merge)。结果代币基于条件代币框架 (CTF)：两侧互补买单 (买 Yes 与买 No) 由撮合合约把 1 USDC 拆分成一对代币分别交割 (mint, 合约方法 `splitPosition`)；互补卖单把一对代币合并回 USDC (`merge, mergePositions`)。这类记录是撮合的结构性操作，**不存在从既有持仓者手中承接观点的交易方**，计入方向性成交流会污染信号，剔除。

2.5 结算事件

结算时刻取链上 `ConditionResolution` 首次事件（UMA 乐观预言机裁决上链的时点），覆盖 492 个登记市场中的 455 个；公开数据集自带的 `resolved_at` 元数据稀疏（56/425），不能作为结算依据。极少数争议市场多次重报，一律取首次事件。结算后市场价格恒为 0 或 1，结算时刻之后的窗口一律记缺失。

3 数据处理

3.1 事件视角统一： p_{event} 与方向 D

链上行只记录「某种代币值多少钱」；研究需要「事件发生的概率」。二元市场 Yes+No 价恒等于 1（由 mint/merge 套利钉住），换算唯一：

$$p_{\text{event}} = \begin{cases} \text{price}, & \text{outcome_seq} = 1 \text{ (Yes 侧)}, \\ 1 - \text{price}, & \text{outcome_seq} = 2 \text{ (No 侧)}. \end{cases}$$

主动方向 $D \in \{+1, -1\}$ 定义为「taker 这笔成交把 p_{event} 往哪推」：taker 买 Yes 或卖 No $\Rightarrow D = +1$ ；taker 卖 Yes 或买 No $\Rightarrow D = -1$ 。两层都来自资产转移事实，非 Lee-Ready 式推断。

3.2 主题注册与时点化准入

以**事前注册**的关键词规则圈定与中国资产相关的市场：中东冲突、油价阈值、金属价格、美联储政策、俄乌冲突、中美贸易、台海风险、美政府停摆，共 8 主题 492 市场；注册后不增删。每个市场注册两个方向系数： $\text{orientation} \in \{\pm 1\}$ （市场结果轴 $\rightarrow$ 主题轴，如「停火结束」对中东升级轴为 +1）与 $\sigma \in \{\pm 1\}$ （主题轴 $\rightarrow$ 品种方向先验）；已验证 $\sigma \times \text{orientation}$ 在每个（主题，品种）对内为常数。**时点化准入**：市场只有在累计成交额首次达到 10 万美元之后才进入面板——用全窗口流动性筛选会让 1 月的样本构成依赖 4 月才实现的成交，属于用未来信息选择。

3.3 分钟聚合：从逐笔到主题信念创新 $N1$

处理链（每一步都有明确目的）：

1. **截断与变换**： p 截断到 $[0.02, 0.98]$ 后取 $\ell(p) = \ln \frac{p}{1-p}$ （logit；防临近结算的端点发散，消融显示对截断位置不敏感）。
2. **买卖跳动去除**：分钟桶内按 taker 方向分堆取加权中位数再平均（逐笔价在买一与卖一之间跳动不代表概率变化）。
3. **过时报价**：端点价取最后成交（LOCF），距最后成交超过 120 分钟记缺失（`p_age` 规则）。
4. **主题聚合**：市场层创新 $\Delta \ell_m$ 按 $w_m = \text{orientation}_m \sqrt{\text{cumUSDC}_m}$ 加权（累计成交额为**时点化**累计，仅用 $\leq t$ 的成交）：

$$N1_t \triangleq \frac{\sum_m w_m [\ell(p_{m,t}) - \ell(p_{m,t-})]}{\sum_m |w_m|}.$$

5. **桶标签取右端**：分钟桶只含严格早于该分钟收盘的成交，与期货 K 线收盘戳对齐后，信号严格先于被解释的价格。

3.4 期货侧：三个必须处理的事实

88 品种主力连续 1 分钟数据 (3,496,950 根) 有三个源数据陷阱：

- 1. **夜盘归属**：夜盘 K 线存放在次一自然日的文件中（周一文件从不含夜盘）。按时间戳重新归属「夜盘归下一交易日」，测试断言周一交易日含上周五 21:01 至周六 02:30。
- 2. **换月拼接**：主力切换发生在交易日边界 21:01，换月日的跨合约收益是拼接伪影。全部检验剔除换月日 (roll 标记)。
- 3. **涨跌停**：主力连续无涨跌停价表，以「收尾 15 分钟 high=low 锁死占比」作代理监控。已知极端例：2026-03-09 SC 日盘全程一字涨停 (225 根全锁, $r_{\text{day}} = 0$)，吸收检验不受影响、策略可成交性受限。

3.5 窗口切分与时差

北京与美东相差 12–13 小时 (2026-03-08 夏令时切换由时区库自动处理)，国内凌晨闭市段恰对应美东主活跃时段，这是识别设计的基础。以 SC 为例（日盘 09:00–15:00，夜盘 21:00–次日 02:30）：

表 3: 交易日四段窗口 (SC; 其余品种按各自夜盘收盘时刻定义)

窗口	北京时间	对应美东	窗口收益定义
傍晚闭市 gap_pm	前日 15:00→21:00	凌晨 → 上午	ln(夜盘开/前日收)
夜盘 night	21:00→02:30	上午 → 下午	ln(夜盘收/夜盘开)
凌晨闭市 gap_am	02:30→09:00	下午 → 晚间	ln(日盘开/夜盘收)
日盘 day	09:00→15:00	美国深夜	ln(日盘收/日盘开)

开盘前信号 s_{pre} = 前日 15:00 至当日 09:00 的主题信念累积（跨品种一致，已核实同主题逐日相同）。

3.6 防前视协议（清单）

- 1. 分钟桶标签取右端，信号桶严格早于期货 K 线收盘戳；
- 2. 市场准入时点化 (§3.2)，聚合权重时点化累计；
- 3. 全部滚动 / 展开统计量只用 $\leq t$ 的观测 (z 分数、MAD 阈值、展开分位数一律 `shift(1)` 或严格 $< t$ 估计)；
- 4. 测量模型参数 (Kalman 等) 在样本前段 (2026-05-15 前) 估计后冻结，其后因果应用；
- 5. 结算后价格、超时报价、换月日一律记缺失而非填充；
- 6. 全部定义与阈值已冻结并哈希登记 (`freeze/manifest.json`)，2026-07-18 之后为未触碰样本。

4 信号定义与规定格式登记

4.1 信号库与 IC 口径

分钟级信号库共 47 个：N 族（数值：信念创新与主动流）、C 族（量价组合）、K 族（离散事件复杂统计）、X 族（条件组合，签名型）各 10 个，J 族（跳变因子）7 个；每个信号的显式公式、机制、窗口与归一化登记见完整版附录三 §3 与 §5b，统计量全表见 `signal_stats(_ext).parquet`（47 信号 × 5 品种）。

IC 口径（规定登记表使用）：

$$\text{RankIC}_h \triangleq \rho_S(s_t, r_{t \rightarrow t+h}) \quad (\text{pooled, 全部分钟行}), \quad \text{ICIR}_h \triangleq \frac{\overline{\text{IC}_h^{(d)}}}{\text{sd}(\text{IC}_h^{(d)})},$$

其中 $\text{IC}_h^{(d)}$ 为第 d 个交易日的日内 RankIC。离散信号另给符号 **RankIC**：signed 指示变量 (+1/0/-1) 与前向收益的 pooled 秩相关（与 X 族同口径）。pooled 口径按分钟行计数、推断意义有限（完整版 §12.14–12.15 的降格结论适用），本表为描述性登记。

4.2 登记信号的严格定义

C8（未兑现缺口，连续）。

$$C8_t \triangleq z_{4800} \left(\sum_{u=t-119}^t N1_u \right) - z_{4800} \left(\sum_{u=t-119}^t r1_u \right),$$

z_{4800} 为 4,800 交易分钟滚动 z (min 960)， $r1$ 为期货 1 分钟收益。**必须声明**：第二腿本身是短期价格反转因子；经双腿分解与严格增量检验（五品种全部未通过预设确认门槛），C8 的强度主要由反转腿承载，**Polymarket 腿的分钟级增量已否定**，本表仅作复合信号的描述性登记。

E1（价格跳，离散）。

$$E_t^{up} \triangleq \mathbf{1}\{N1_t > \kappa_t\}, \quad \kappa_t = \max(3 \times 1.4826 \times \text{MAD}_{30\text{日}}(N1 \neq 0), 0.05).$$

事件跳（离散）。15 分钟桶 $|\Delta\ell|$ 超过 $3 \times 1.4826 \times \text{MAD}_{48\text{桶}}$ 且桶内成交 $\geq \$10,000$ ；同主题同时戳折叠为一个事件， $J_{\text{evt}} = \sqrt{\text{usdc}}$ 加权的 $\text{orientation} \times \Delta\ell$ 。两个登记单元：SC 盘中日盘跳（映射到期货分钟网格延迟 ≤ 2 分钟且落在日盘）；M 孤立跳（同桶无其他市场共跳， $n_{\text{cojump}} = 0$ ）。

4.3 规定格式登记表

机器可读源：`docs/signal_summary.json`（纯数字模式：全部量化字段为 number、不适用为 null、单位在字段名或 `meta.units`）。重算命令：

```
python scripts/export_signal_summary.py
```

读法示例：SC 盘中事件跳后 10 分钟条件均值 +10.63 bp，应对照 SC 无条件 10 分钟均值 -0.13 bp 解读；该格为置换单方法支持的探索候选、毛收益低于两倍成本门槛（16 bp 完整换手）。

表 4: 登记信号主表 (IC / ICIR / 取 1 收益 / 符号 IC, 均为 1/3/10 分钟三元组; 数据由 make_concise_table.py 从 JSON 生成)

品种	信号	类型	月频	RankIC	ICIR (日度)	取 1 收益 (bp)
SC	C8	连续	11,212 分钟/月	+0.0163 / +0.0232 / +0.0300	+0.60 / +0.57 / +0.54	-
AU	C8	连续	11,212 分钟/月	+0.0097 / +0.0120 / +0.0188	+0.67 / +0.70 / +0.70	-
AG	C8	连续	11,212 分钟/月	+0.0127 / +0.0135 / +0.0062	+0.39 / +0.38 / +0.29	-
CU	C8	连续	9,397 分钟/月	+0.0145 / +0.0182 / +0.0202	+0.70 / +0.62 / +0.54	-
M	C8	连续	6,978 分钟/月	+0.0161 / +0.0125 / +0.0092	+0.98 / +0.80 / +0.72	-
SC	E1_up	离散	327.8 次/月	-	-	+0.01 / -0.36 / -0.74
SC	JUMP_SC_day	离散	24.0 次/月	-	-	+1.39 / +2.76 / +10.63
M	JUMP_M_isolated	离散	4.7 次/月	-	-	+0.13 / +0.45 / +3.36

表 5: 取值统计量 (连续: 矩统计; 离散: valuecount) 与非零频率

品种	信号	统计量 / valuecount	非零频率
SC	C8	$\mu=-0.013$, med=-0.010, $\sigma=1.356$, skew=-0.04, kurt=+1.53	98.54%
AU	C8	$\mu=+0.020$, med=+0.007, $\sigma=1.606$, skew=+0.33, kurt=+4.28	98.54%
AG	C8	$\mu=-0.003$, med=+0.052, $\sigma=1.461$, skew=-2.15, kurt=+204.41	98.54%
CU	C8	$\mu=-0.015$, med=+0.072, $\sigma=1.649$, skew=+0.98, kurt=+61.45	98.26%
M	C8	$\mu=+0.018$, med=+0.038, $\sigma=1.544$, skew=+0.87, kurt=+9.69	97.68%
SC	E1_up	-1: 2,015; 0: 63,759; 1: 1,951	5.86%
SC	JUMP_SC_day	-1: 134; 1: 143	0.41%
M	JUMP_M_isolated	-1: 25; 1: 28	0.12%

表 6: 品种全区间基准 (离散信号条件均值的对照; 剔除月日)

品种	收对收累计	无条件 1' (bp)	3' (bp)	10' (bp)
SC	+8.8%	+0.009	+0.006	-0.126
AU	-14.8%	-0.024	-0.077	-0.298
AG	-22.4%	-0.010	-0.066	-0.339
CU	+2.9%	-0.002	-0.015	-0.024
M	+5.7%	-0.004	-0.027	-0.134

5 关键结果（模块化摘要）

以下每个模块：一句结论 + 关键数字 + 完整版出处。展开论证、稳健性与全部反例见完整版对应章节。

5.1 吸收结构（A 级，全文最强结论）

国内闭市期间积累的事件概率变化在开盘跳空与夜盘被系统性定价。油价主题 × SC 傍晚细窗相关 0.86 ($n = 37$)、合并缺口 0.743 ($n = 74$)；中东 × 凌晨闭市段 0.70；循环置换 $p < 0.0005$ ；冲突高峰期内 / 外同号且期外更强 (0.35 / 0.68)。**截面识别**：88 品种按暴露度逐日排序（差分掉当日共同因子），截面 RankIC 0.185（经济先验载荷，HAC $t = 4.0$ ）与 0.261（估计载荷， $t = 5.0$ ），最高与最低五分位开盘前收益差约 100 bp/日，承载品种恰为能源链与贵金属。（完整版 §6、§12.12）

5.2 中东增量（A 级）

控制同窗国际基准（USO 等 12 资产）后，唯一稳定显著的配对：中东冲突概率对 SC，严格同窗 $t = 4.94$ ($n = 114$)；经济量级约 96 bp/ σ （未控制 196，独立增量约一半）；机制指向 INE 交割篮子的中东油种集中。LP-IV（第一阶段 $F = 42$ ）：事件驱动的油价变动传导系数 $\delta = 1.13$ 高于一般变动的 0.89。（§11、§12.8、§12.14）

5.3 反转 = SC-USO 相对收益回归（A 级）

事件日吸收（+507 bp/ σ ）的 84% 来自 USO 分量；次日反转（−226 bp）的 81% 来自 SC 相对 USO 的收益分量，冲突高峰时累计相对偏离一度达 18% 后回归。该分量未经汇率 / 期限 / 油种调整，不等同于严格基差。（§11.3、§12.14）

5.4 否定结果（C/D 级，占结论的大多数）

表 7：否定结果汇总（每行都是登记在案的完整检验）

命题	证据
日频方向不可预测	68 项预测检验 FDR 后全负；OOS 增量不为正；截面预测 IC ≈ 0 （三层互证）
波动水平预测无 OOS 增量	$\Delta R^2 \approx 0$ ，Clark–West $t \approx 0$
组合不放大信息	中东 × 油价交互 $t = -2.88$ （冗余）；共现无超额；确认型组合跨品种一致为负
C8 的 PM 腿无分钟增量	五品种严格增量检验全部未通过（逐日日内 partial t 0.6–1.8；安慰剂 p 0.26–0.61；OOS $\Delta R^2 \approx 0$ ），退出 alpha 候选
J 族仅单方法探索	SC 盘中跳：置换 $p < 0.008$ 支持、HAC 一致 wild bootstrap $p = 0.17$ 不支持；毛收益低于 2× 成本门槛；M 孤立跳 51 响应不显著 (t 1.41 / 0.87)
聪明钱窗口流无增量	技能钱包仅占主题成交额 2–5%；锚配对预测全零；吸收增量 $t \approx 1.0$ –1.3

5.5 数据层新发现：钱包技能真实且持续

对全部逐笔按 taker 钱包核算持有到结算盈亏 (5,831 万钱包 × 市场组合)：前后半段单位成交盈亏秩相关随活跃度单调升——散户层 0.026、≥100 市场 0.113、≥100 万美元 0.158 ($n = 35.8$ 万钱包)。技能存在，但其信息在窗口尺度已被价格聚合。(§12.13)

5.6 结论与投资定位

Polymarket 对中国商品期货的价值形态是**事件风险的实时测量**（开盘前风险敞口、品种排序、尾部旗标——旗标冻结样本初值 lift 3.28、Fisher $p = 0.007$ 、overlay 使 SC 持有回撤 $-53\% \rightarrow -31\%$ ，2027 年初未触碰样本裁决），**不是方向 alpha**。实盘配置为零仓位；全部候选已冻结 (freeze/manifest.json)，裁决时点：SC 跳格 2026-12-31 或新增 95 个交易日先到者，R1-R4 与旗标 2027-01-31，各候选仅一次预约定检验。(§12.15–12.16)

6 复现

表 8: 复现命令链（全部数字构建时从产物计算，不手抄）

步骤	命令 / 产物
链上采集与统一 tape	crawl_polymarket_chain.py → v3_build_tape.py
期货分钟库	build_cn_futures_db.py (88 品种)
主题注册	select_polymarket_markets.py → cn_registry_v3.parquet
分钟面板与信号库	v3_defense_build.py (40 信号 + 前向收益)
跳变因子	v3_jump_factors.py / v3_jump_inference.py
截面与钱包	v3_cross_section.py / v3_wallet_skill.py
规定格式登记表	export_signal_summary.py → docs/signal_summary.json
本文表格	make_concise_table.py → docs/concise/
本文编译	xelatex main.tex (两遍)
影子记录	shadow_daily.py → shadow/records.jsonl (追加不回改)
冻结对账	freeze/manifest.json (SHA256 + 终检日期)

补充数据腿（零成本，data/intl/）：Brent 与 USDCNH 日频经免费接口；交易所逐合约日结算经公开端点 (.../dailydata/kxYYYYMMDD.dat, INE/SHFE 已核实可用)。

完整版:docs/cn_futures_polymarket_report.html (151 页 PDF 同名)。本文对应分支 `feat/cn-futures-polymarket`; 样本短且由单一事件主导, 全部结论为探索性。