

Polymarket 数据获取、处理与信号构造

中国商品期货关联研究 · 精炼版（数据与方法为主体）

Alpha-Data 项目

2026 年 7 月（样本冻结于 2026-07-18）

摘要

本文是完整研究报告（151 页）的精炼版，写作原则是**宁少勿糊**：凡写入的条目都给出可复现的构造方法与严格定义，展开性论证一律指向完整版。第 3-4 节（数据获取与处理）是主体；第 5-6 节给出 40 个信号的公式、取值统计与 IC 全表；第 7 节把全部实验压缩为结论卡片。

数据资产：链上逐笔成交 855,614,453 笔（\$26.53B，2022-11-21 至 2026-07-14），与 88 个品种的中国期货 1 分钟数据（3,496,950 根 K 线）在 125 个重叠交易日（2026-01-05 至 07-13）上对齐。

核心结论：Polymarket 的信息含量真实存在，以**闭市时段的同期吸收**进入中国期货开盘价格，并在开盘后数分钟内耗尽。在分钟频率上，只用 Polymarket 数据构造的 23 个信号、798 个检验中**无一通过多重检验门槛**（ $\max |t| = 3.24 < 4.15$ ）；全部 13 个通过门槛的信号格**无一例外含有期货侧量价腿**（且无一为离散事件信号），其增量经双腿分解归因于期货自身的短期反转。据此，本研究不含已验证的可交易 alpha，实盘配置为零仓位。

目录

1 数据资产总览	3
2 概念白话解释（零基础导读，熟悉者可跳过）	3
2.1 一、预测市场是什么	3
2.2 二、“链上”和“链下”，以及抓数据用到的技术词	4
2.3 三、一笔成交里都记了什么	5
2.4 四、为什么有些成交要扔掉	6
2.5 五、怎么把很多市场并成一个“主题信号”	6
2.6 六、怎么把“每一笔”压成“每分钟一个数”	6
2.7 七、中国期货那边的行话	7
2.8 八、信号是怎么造出来的（四族）	8
2.9 九、怎么判断一个信号到底有没有用	8
2.10 十、公式符号速查表	9
3 Polymarket 数据获取	11
3.1 什么在链上，什么不在	11
3.2 两段数据与拼接	11

3.3	一行是什么：行级定义与主键	12
3.4	时间戳：精度、时区与语义	12
3.5	采集机制与延迟	13
3.6	主动买入与卖出的定义	13
3.7	机械成交的处理	13
3.8	清洗漏斗（自采段可逐级实测）	14
3.9	结算事件	15
4	数据处理	15
4.1	事件视角统一： p_{event} 与方向 D	15
4.2	主题注册与时点化准入	15
4.3	分钟聚合：从逐笔到主题信念创新 $N1$	16
4.4	中国期货 1 分钟数据：来源与口径	16
4.5	时段、休市与换月：逐条处理	16
4.6	时差与窗口切分	17
4.7	防前视协议（清单）	17
5	信号定义	18
5.1	设计原则与数值化的合理性	18
5.2	N 族：数值信号（只用 Polymarket 数据）	19
5.3	C 族：与标的量价数据组合的信号	20
5.4	K 族：基于原始离散事件的复杂统计指标	21
5.5	X 族：条件与状态交互信号	21
5.6	另行登记的事件跳因子（J 族）	22
6	指标口径与统计结果	22
6.1	IC 的数学定义	22
6.2	全信号登记表	22
6.3	连续信号：IC 期限结构	22
6.4	离散信号：频率与事件研究	22
6.5	多重检验下的族级结论	22
6.6	检出力与最小可检测效应	26
6.7	规定格式登记表	27
7	关键结果（模块化摘要）	27
7.1	吸收结构（A 级，全文最强结论）	28
7.2	中东增量（A 级）	28
7.3	反转 = SC-USO 相对收益回归（A 级）	28
7.4	否定结果（C/D 级，占结论的大多数）	29
7.5	数据层新发现：钱包技能真实且持续	29
7.6	结论与投资定位	29

1 数据资产总览3

8 复现29

8.1 已登记的限制项30

1 数据资产总览

表 1: 数据资产一览

数据层	规模	时间范围	来源
Polymarket 逐笔成交	855,614,453 笔 / \$26.53B	2022-11-21..2026-07-14	链上（两段拼接）
公开数据集段	601,934,424 笔 / \$19.62B	..2026-04-28	HuggingFace 快照
自建爬虫段	253,680,029 笔 / \$6.91B	2026-04-28..	自爬 Polygon 链
市场元数据与结算	1,208,594 个市场（并集）	同上	链上 ConditionResolution
登记主题市场	8 主题 / 492 市场	事前注册	cn_registry_v3.parquet
中国期货分钟线	88 品种 / 3,496,950 根	2026-01-05..07-13	本地交付 CSV
国际基准	USO/GLD 等 12 ETF 分钟	同重叠期	美股分钟库
补充数据腿	Brent/USDCNH 日频; 逐合约日结算 见 §8		免费公开接口

必须首先声明的样本不对称。Polymarket 侧有 3 年 8 个月的历史，中国期货分钟数据只有 125 个交易日（2026-01-05 至 07-13）。因此：主题事件的到达率可以给出 2023-09 以来的全历史统计（表 5），而任何涉及期货价格的统计量（IC、事件后收益）只能在 125 天的重叠窗口上计算。本文所有”每月次数”按 125 交易日 / 21 折算为 5.95 个月，不是 3 年的均值。

2 概念白话解释（零基础导读，熟悉者可跳过）

一句话搭骨架：Polymarket 是一个押注”未来某件事会不会发生”的网站；本研究把它上面所有成交记录（谁、什么时候、什么价、押多少钱、押哪一边）全部抓下来，压成”每分钟市场对某件事的看法变了多少”，再检验这个变化和中国商品期货的价格有没有关系。下面按正文出现的顺序，用大白话把每个名词讲一遍，能打比方的都打个比方。已熟悉预测市场与链上数据的读者可直接跳到第 3 节。

2.1 一、预测市场是什么

预测市场

一个可以拿钱押”未来某事成不成”的市场。例：押”美联储 9 月降息”。押对的人事后按 1 元/份拿钱，押错的归零。

价格就是概率

每个结果做成一种”份额”，价格在 0 到 1 元之间。某份额卖 0.62 元，就等于市场认为这件事有 62% 的概率发生；价格涨到 0.70，就是市场把概率上调到了 70%。这是全文的出发点：价格 = 市场此刻认为的概率。

Yes 份额 / No 份额

一个二元问题有两种份额：押”会发生”的 Yes 份额、押”不会发生”的 No 份额。两者价格永

远加起来等于 1 元，否则有人能无风险套利。

市场、condition_id

一道题就是一个”市场”，系统给它一个唯一编号 `condition_id`，相当于这道题的身份证号。

2.2 二、“链上”和“链下”，以及抓数据用到的技术词

区块链、Polygon

一个公开、人人可查、不能篡改的公共账本。Polygon 是 Polymarket 所用的那一条链。

链上 / 链下

”链上” = 写进了公共账本、永久可查；”链下” = 只在公司自己服务器里、外人看不到也追不回。Polymarket 的关键设计：**谁挂了什么单在链下（查不到），但两张单一旦成交、钱货两清写进账本在链上（查得到）**。所以我们能重建每一笔成交，却永远拿不到历史挂单与盘口。

订单簿、挂单、吃单

订单簿就是一堆”我愿意用某价买/卖”的挂单排队。挂单方（maker，做市方）先把单子摆着等；吃单方（taker，主动方）看到合适的价直接成交。**吃单方是主动的一方**，这点在判断买卖方向时是关键。

区块、区块时间戳

链上记录按”区块”一批批打包，每个区块盖一个时间戳。同一区块里的所有成交共用同一个时间；实测约每 1.6 秒出一个区块，所以时间精度只到秒级，且同一秒内谁先谁后无法区分。

撮合合约（CTF Exchange）

链上负责”把买方卖方配对、钱货两清”的那段程序。它像一个自动清算中心，站在每一笔成交的中间。

结算、乐观预言机（UMA）

事件有了结果（降息了 / 没降），需要有人把”正确答案”写上链，这一步叫结算（ConditionResolution）。

裁定答案的机制叫预言机；UMA 是”乐观”型：先假定有人提交的答案是对的，留一段时间让别人质疑，没人质疑就生效。结算后 Yes/No 份额价格锁死在 1 或 0。

代币标准 ERC-1155、asset_id

每种份额（某市场的 Yes 或 No）在链上都是一枚”代币”，ERC-1155 是这类代币的通用规格（好比集装箱的标准尺寸，规定它怎么装、怎么转），每枚有唯一编号 `asset_id`。

事件类型标签 topic

链上每条记录开头都有一个”这是什么类型”的标签（topic）。想找所有”成交”记录，就按”成交”这个 topic 去扫，不用逐条翻。好比图书馆按书脊标签找书。

字段说明书 ABI（v1 / v2）

一条记录里各个位置分别是什么意思，由合约的”字段说明书”（ABI）规定。Polymarket 的撮合合约升级过一次，旧版 v1、新版 v2 的说明书不同，所以同一种”成交”在两版里字段摆放不一样，解码时要分别对照。

取数命令 eth_getLogs

向区块链节点要数据的标准问法之一：”把某段区块里带某个标签的记录都给我”。我们的自建爬虫就靠它按 topic 批量取回成交。

终局 finalized、区块重组

刚出的区块理论上极小概率被回滚重排（叫”重组”）；一旦达到”终局”状态就永不改变。我

们只抓已终局的区块，数据一次成型、不会因链上回滚变脏。端点不支持终局标签时，退而只信 256 个区块以前的记录。

幂等

同一段数据抓两遍，结果完全一样、不会重复。因为每条记录有唯一编号，重复的会被自动去掉。好比同一份名单核对两遍不会把人数算多。

2.3 三、一笔成交里都记了什么

outcome_seq（第几个结果）

标记这枚代币是这个市场的第 1 个结果（Yes）还是第 2 个（No）。它是代币出生就定死的属性，永不改变。

USDC、名义额、vwap

USDC 是一种与美元 1:1 的数字货币，Polymarket 用它计价。一笔成交的名义额 = 价格 × 份数。一分钟内多笔成交，按各自名义额加权算出的平均价叫 vwap（成交量加权均价），比简单平均更能代表这一分钟的真实价位。

p_event（事件概率）

把“这枚代币值多少钱”统一换算成“这件事发生的概率”。买的是 Yes 币，概率就是它的价；买的是 No 币，概率就是 1 减它的价。这样不管成交发生在哪一侧，都能读成同一个“事件概率”。

主动方向 taker_direction

这笔成交里，主动的一方（吃单方）是在买还是在卖。由“谁付了 USDC、谁收了代币”这个链上事实直接判定，不靠猜。

为什么“直接判定”值得强调：tick rule 与 Lee-Ready

普通股票 / 期货行情只报“成交价和量”，不写明这笔是主动买还是主动卖。学界只能用规则去猜。**tick rule**（逐笔规则）看这笔比上一笔价高（猜买）还是低（猜卖）。**Lee-Ready**（1991 年 Lee 与 Ready 两位作者提出的方法，微观结构里的标配）更细，分两步：先看成交价落在“中间价”（=（买一价 + 卖一价）/2）的哪一边——高于中间价判买、低于判卖（直觉：急着买的人会够上去吃卖一、急着卖的人会砸向买一，中间价就是分界）；若成交价正好落在中间价上分不清，再退回用 tick rule。举例：买一 10.00、卖一 10.02、中间价 10.01，成交在 10.02 判买、在 10.00 判卖、正好在 10.01 就看上一笔谁高谁低。**这两种都是估计、会出错**（快市、报价过时、恰在中间价成交时最容易判错）。而 Polymarket 的链上账本白纸黑字记了资产转移，我们**不需要这类推断**，方向是事实、没有判错的隐患。

方向 D（这笔在押哪边）

把“主动买还是卖”与“买的是 Yes 还是 No”相乘，得到“这笔主动成交是在押事件会发生、还是不会发生”：主动买 Yes 或主动卖 No = 押会发生（+1）；主动卖 Yes 或主动买 No = 押不会发生（-1）。两个乘数都在成交时点确定，**不看成交之后价格怎么走，不是未来信息**（详见第 3.6 节）。

成分腿、腿（leg）

一笔大单常被拆成对好几个对手方的小成交，每条小成交叫一条“腿”。下面的“中继腿”就是其中那条特殊的汇总腿。

2.4 四、为什么有些成交要扔掉

中继腿

撮合合约站在每笔成交中间，于是账本里一笔真实成交常被记成两条：一条”用户对撮合合约”、一条”撮合合约对另一用户”。全加起来会把成交量算成两倍。判据很简单：只要一条记录的对手方是撮合合约本身，它就是”中继腿”，扔掉。

铸造 / 合并 (mint / merge)

Polymarket 允许把 1 个 USDC 拆成”1 份 Yes + 1 份 No”（铸造），或把一对合并回 1 USDC（合并）。这是系统内部的拆分组合动作，没有”从别人手里接货”的对手方，不代表任何人看多看空。它们在账本里是**另一类记录、另一个类型标签**，本来就不在我们用的成交流里，谈不上剔除。

negRisk

一类特殊的多选市场（如”下任总统是谁”），机制不同，本数据两段都统一排除，代价是 2024 美国大选等大市场不在样本里。

2.5 五、怎么把很多市场并成一个”主题信号”

主题、事前注册

把 Polymarket 上和某个中国资产相关的一批市场（如所有”中东冲突”相关问题）事先框成一个”主题”。规则在看结果之前就定死、之后不再增删（事前注册），避免事后专挑对自己有利的市场。

方向系数 orientation 与 σ

麻烦在于不同市场的”Yes”含义常相反：一个市场 Yes = 冲突升级，另一个 Yes = 停火。所以先给每个市场标一个 orientation，把它们统一到同一根”主题轴”上（都朝”冲突升级”为正）； σ 再把”主题轴”翻译成”对这个期货品种应偏涨还是偏跌”的先验。好比一堆温度计有的用摄氏有的用华氏，先统一刻度再一起读。

时点化准入

一个市场要等它累计成交额攒够 10 万美元、有了足够流动性，才被放进样本；而且”攒够”的时刻按时间往前推着判断，不能用它整段历史的总额提前放行，否则等于让 1 月的样本偷看 4 月才发生的事。

加权聚合

同一主题下有很多市场，成交额大的更可信、权重更高（权重用 $\sqrt{\text{时点化累计成交额}}$ ）。把各市场的看法变化按权重平均，得到这个主题这一分钟的总看法变化。

2.6 六、怎么把”每一笔”压成”每分钟一个数”

信念创新 $N1$

全文最核心的自造量。意思是”这一分钟里，市场对某个主题的看法比上一分钟变了多少”。它是一个数：正表示概率被推高，负表示被推低。后面几乎所有信号都由它衍生。

截断、logit 变换

概率被卡在 0 到 1 之间，靠近两端时”从 0.98 到 0.99”其实是很大的信息，数值却只差 0.01。先把概率截到 [0.02, 0.98] 防止贴边发散，再用 logit（一个把 0 到 1 拉伸成正负无穷的数学变换）

让两端的变化不被压扁。

买卖跳动、加权中位数

同一时刻成交价会在“买家愿付价”和“卖家愿收价”之间来回跳，这种跳动不代表概率真变了。处理办法是分钟内按买卖方向分别取（成交额加权的）中位数再平均，把来回跳抹平。取中位数是因为它比平均值更抗个别异常成交。

过时报价（p_age）

某个冷门市场可能几小时没成交，它上一次的价格已经“傻了”。规则：沿用最后一次成交价，但超过 120 分钟没更新就当缺失，不拿陈旧价冒充新信息。

分钟桶、右端标签

把连续成交按每分钟归拢成一格（一个“桶”）。给这一格贴的时间标签取**分钟结束那一刻**，且这一格**只装该时刻之前的成交**。这样信号永远早于它要解释的价格，杜绝偷看未来。

时序归一化（z-score）

同一个量在不同品种、不同时期数值大小不可比。z-score 的做法是：减掉最近一段时间的平均值，再除以这段时间的波动大小，换算成“比平常高 / 低几个身位”。“最近一段”只回看过去、不含未来。

稳健阈值、MAD

判断“这一分钟的变化算不算一次事件”要有一条线。这条线用 MAD（一种抗极端值干扰的波动度量）乘系数得到，比普通标准差更不容易被个别异常值带偏。

测量模型、Kalman、参数冻结

Kalman 滤波是“从带噪声的观测里估计背后真实状态”的经典方法，这里用它从嘈杂成交里估“市场真实信念”。它的参数在样本前半段估好后**就锁死**，后半段只用不改，避免用全样本调参造成的偷看。

2.7 七、中国期货那边的行话

主力连续、换月

同一品种（如原油）同时挂着好几个到期月份的合约，交易最活跃的那个叫“主力”。主力会随时间换到下一个月份，叫“换月”。把历次主力接成一条不断的价格序列，就是“主力连续”。

日盘 / 夜盘

中国商品期货一天分两段交易：白天的日盘、晚上的夜盘。夜盘常跨过午夜，因此**某天晚上的夜盘算作下一个交易日**。

四段窗口

把一个交易日按期货作息切成四段：傍晚闭市、夜盘、凌晨闭市、日盘。因为国内闭市时段恰好对着美东活跃时段，分段才能看清“闭市期间积累的信息在开盘怎么被定价”，这正是全文识别设计的基础。

涨跌停（locked）

一天价格最多涨 / 跌一个固定幅度，到顶就“封板”，全天价格钉住不动。本数据没有涨跌停价表，只能用“这一分钟最高价 = 最低价”近似判断是否封板，且只用于监控、不参与计算。

连续分钟段

期货有午休、日夜盘之间的休市。规则：只要相邻两根 K 线时间差不是正好 1 分钟，就断成两段。任何“未来收益”都不许跨过一个断点，避免把一夜或一个午休的跳空错算成 1 分钟的涨跌。

前向收益 fwd

”信号发出后，价格在接下来 1、2、3、5、10、15 分钟涨跌了多少”，这是我们要预测的目标。

基点 bp

万分之一。10bp = 千分之一 = 0.1%。期货分钟级涨跌很小，用 bp 计更清楚。

2.8 八、信号是怎么造出来的（四族）

N / C / K / X 四族

信号按”用了什么数据”分四类。**N 族**只用 Polymarket（信念创新、成交流强度）；**C 族**把 Polymarket 和期货的量价乘在一起（如”事件发生但价格没动”）；**K 族**把”发生了没发生”的离散事件加工成统计量（计数、连发、到达率）；**X 族**只在特定状态下（夜盘、放量）才触发。分族的好处：哪一族显著，就知道信息来自哪一侧数据。

签名值、签名离散型

离散信号不用”是/否” (0/1)，而用带正负号的 $-1/0/+1$ ：-1 表示看跌方向触发、+1 看涨方向触发、0 没触发。这样它既能直接进相关性计算，也能相加。

游程（连发长度）

连续同方向发生了几次。比如连续 5 分钟都是”上行事件”，游程就是 5。连发往往比单次更有信息。

到达率

事件多久来一次的频密程度：间隔越短、到达率越高。用最近几次事件间隔的倒数估计（统计上的泊松强度）。

截面统计

不看单个品种随时间怎么走，而是在**同一时刻横着比一排品种**谁高谁低。好处是同一天所有品种共同的涨跌（大盘、宏观）被自动减掉，剩下的是品种之间的相对差异。全文最强的正结果就来自这里。

残差化 / 正交化

想知道 Polymarket 信号里”不能被期货动量解释的那部分”，就用回归把动量成分减掉，剩下的残差就是”正交（不重叠）”的独立信息。好比两人说的话有重叠，划掉重叠，看第二人还剩多少新东西。

2.9 九、怎么判断一个信号到底有没有用

防前视、未来函数

”未来函数”指计算时不小心用到了当时还不知道的信息，会造出虚假的准确度、实盘一分钱赚不到。全文反复强调的”防前视”就是层层堵死这种偷看。

RankIC（秩相关）、pooled

衡量”信号大的时候、之后收益是不是也偏大”的相关系数，范围 -1 到 1，0 表示没关系；用”排名”而非原值计算，抗极端值。pooled 指把所有交易日的所有分钟混在一起算一个总系数。分钟级上 0.01 到 0.03 就已经算有一点点关系。

ICIR

把”每天的 RankIC”都求出来，再看它**是否稳定为正**：平均值除以波动。数值高说明信号不是靠某几天的运气，而是天天都灵。

事件研究、基准

对”发出 / 没发出”的离散信号，看它触发之后价格平均怎么走，并和”这个品种平时的平均走势（基准）”比。只有明显好过基准才算有信息。

聚类稳健 t 、HAC

信号触发常在时间上扎堆（一件大事连着触发很多次），普通统计会把它们当成互相独立的证据、高估显著性。”按交易日聚类”的 t 值、以及 HAC (Newey–West) 方法，都是把这种前后相关、成簇效应扣掉的更保守算法。

多重检验、Bonferroni 门槛

我们试了上千个”信号 $\times$ 视界”的组合。试得越多，纯靠运气蒙出一个”看着显著”的就越容易。Bonferroni 是一条按试验次数抬高的及格线（本文约 $|t| > 4$ ），只有跨过它才当真。**这正是全文最关键结论所在**：只用 Polymarket 数据的信号，没有一个跨过这条线。

置换检验、wild bootstrap、FDR

都是判断”这个结果是不是碰巧”的手段。置换检验把信号和收益的对应关系随机打乱很多次，看真实结果在打乱分布里排得多极端；wild bootstrap 是另一种反复扰动重算的版本；FDR 则控制”被判显著的里面平均有多少其实是假阳性”。它们都不依赖正态假设，更稳。

工具变量、LP-IV、第一阶段 F

想估”A 影响 B”却担心有第三个因素同时搅动 A 和 B 时，借一个”只通过 A 起作用”的外部变量（工具）来干净地估。第一阶段 F 衡量这个工具够不够强（ $F > 10$ 算合格，本文为 42，很强）。

五分位、载荷 / 暴露度

按某个指标把品种从低到高分成五档（五分位），比最高档和最低档的差。”载荷 / 暴露度”是”某品种对某主题有多敏感”的系数。

冻结、预注册、SHA256

把全部定义和阈值在检验之前锁死、算一个指纹（SHA256 哈希）存档，并预约将来某个日期用”没碰过的新数据”检验一次，杜绝反复试到显著为止。

第二类错误、检出力

”第一类错误”是本来没有却说有（假阳性）；**第二类错误**是本来有却没看出来（漏报）。**检出力**就是”真有信号时能被我们抓到的概率”，本文取常用的 80%。样本越短、噪声越大，检出力越低、越容易漏报。

最小可检测效应（MDE）

在既有样本量和既定门槛下，**多大的效应才会被我们以 80% 把握检出**。它是”没检出”这句话的刻度尺：大于 MDE 的效应可以说已被排除，小于 MDE 的只能说无法分辨，不能说它是零。没有 MDE，”我们没发现 alpha”就等于什么都没发现。

标准误的反解

本文不另做假设去估 MDE，而是把已算出的 t 值反过来解出标准误：既然 $t = \text{效应} / \text{标准误}$ ，那么标准误 = 效应 / t 。这样 MDE 与正文其余数字同源、不引入新口径。

2.10 十、公式符号速查表

下表把全文公式里出现的记号一次列清。凡在正文遇到不认识的符号，回此处查。

（甲）时间与下标

符号	含义
t	当前这一分钟（时刻）
h	前向视界，往后第几分钟；取 1, 2, 3, 5, 10, 15
u	求和用的分钟下标，在某个窗口内遍历
m	市场下标（一个主题下第 m 个市场）
d	交易日下标
θ	主题下标（8 个主题之一）
W	滚动窗口长度（交易分钟数，本文归一化用 $W = 4800$ ）
t^-	读作“t 减”，指该市场上一次有成交的那一分钟

（乙）期货价量

符号	含义
C_t	这一分钟的收盘价（ $C = \text{close}$ ）； $O/H/L$ 为开 / 高 / 低价
H_t, L_t	这一分钟的最高价、最低价（涨跌停代理 $\text{locked} = \mathbf{1}\{H = L\}$ 用）
V_u, A_u	这一分钟的成交量（volume）、成交额（money / amount）
$r1_t$	期货 1 分钟对数收益 $= \ln C_t - \ln C_{t-1}$
$\text{fwd}_{h,t}$	前向收益：信号发出后 h 分钟的对数收益（段内，跨休市置缺失）
seg_t	连续分钟段编号；相邻 K 线时间差 $\neq 1$ 分钟即换段
Δts_u	相邻两根 K 线的时间差

（丙）Polymarket 侧

符号	含义
$p_{m,t}$	市场 m 这一分钟的事件概率
$\ell(p)$	logit 变换 $= \ln \frac{p}{1-p}$ ； $\Delta \ell$ 为其变化量
D	单笔主动方向 $\in \{-1, +1\}$ ，押事件不发生 / 发生（详见第 3.6 节）
orientation_m	市场方向系数 ± 1 ，把各市场 Yes 含义统一到主题轴
σ	品种方向先验 ± 1 ，主题轴到期货涨跌的先验（勿与标准差混淆）
w_m	市场权重 $= \text{orientation}_m \sqrt{\text{时点化累计成交额}_m}$
$N1_t$	主题信念创新：这一分钟主题看法的加权平均变化（全文核心量）
f_t, U_t, n_t, M_t	15 分钟签名流、成交额、笔数、活跃市场数

（丁）归一化与信号

符号	含义
$z_W(x)$	时序 z 分数 $= (x - \mu_W) / \sigma_W$ ， μ_W, σ_W 为窗口 W 的滚动均值 / 标准差
m_t, v_t, u_t, a_t	前 15 分钟涨幅 / 波动 / 成交量 / 成交额的 z_{4800} 归一化值
κ_t	稳健事件阈值 $= \max(3 \times 1.4826 \times \text{MAD}_{4800}(N1), 0.05)$
MAD	中位数绝对偏差（抗极端值的波动度量）；1.4826 把它折成正态标准差
e_t	签名事件指示 $= \mathbf{1}\{N1_t > \kappa_t\} - \mathbf{1}\{N1_t < -\kappa_t\} \in \{-1, 0, 1\}$
$C8_t$	未兑现缺口信号（PM 累积腿减期货反转腿，见第 5 节）

(戊) 统计与通用记号

符号	含义
$1\{\cdot\}$	指示函数：括号内条件成立取 1、否则取 0
$\text{sign}(\cdot)$	取符号：正数 +1、负数 -1、零 0
$\ln, \sqrt{\cdot}, \sum, \cdot $	自然对数、平方根、求和、绝对值
ρ_S	Spearman 秩相关系数 (RankIC 用的相关)
RankIC_h	信号与 h 分钟前向收益的 pooled 秩相关
$\text{IC}_h^{(d)}$	第 d 个交易日的日内 RankIC
ICIR_h	$= \overline{\text{IC}_h^{(d)}} / \text{sd}(\text{IC}_h^{(d)})$, 逐日 IC 的均值除标准差
t_h	t 统计量 $= \text{ICIR}_h \sqrt{D}$, 此处 D 为有效交易日数 (与方向 D 同字不同义)
bp	基点, 万分之一; $10 \text{ bp} = 0.1\%$
z_α	显著性门槛对应的分位; 本文取全族 Bonferroni 门槛 4.15
z_β	检出力对应的分位; 80% 检出力对应 0.84
MDE	最小可检测效应 $= (z_\alpha + z_\beta) \times \text{SE}$ (见第 6.6 节)
SE	标准误; 由 t 值反解, 不引入新假设

3 Polymarket 数据获取

3.1 什么在链上, 什么不在

Polymarket 的撮合是**链下订单簿** (挂单为链下签名消息, 免 gas、可撤销、不落链), **清算在链上** (Polygon)。由此确定了本数据的结构性边界:

- **可完整重建**: 成交 (OrderFilled 事件)、结算 (ConditionResolution 事件)、仓位铸造与合并 (PositionSplit / PositionsMerge 事件)。
- **任何人都无法获取**: 历史盘口、挂单深度、撤单、未成交订单。点差只能用同分钟买卖两向成交的中位价差代理。

3.2 两段数据与拼接

- **公开数据集段** (HuggingFace Polymarket-v1, CC-BY-4.0): 2022-11-21 至 2026-04-28。终点不是停更: 旧交易所合约在 2026-04-28 11:00:40 UTC (区块 86,126,998) 产生最后一笔成交后被 v2 合约取代。该段为下载所得, **非自采**。
- **自建爬虫段**: 从区块 86,126,998 之后起, 按 topic 扫描新旧两版 OrderFilled 事件重建同构数据, 两段按区块号天然不重叠。
- **同质性检验**: v2 合约在 4 月 3 日已上线、与旧合约并行 25 天。抽样六个 3,000 区块窗口实测, 并行期 v2 流量占比 $< 0.04\%$, 拼接处无流量断层。
- **复现性检验**: 自建解码器对同一区块的重建结果与公开数据集逐字段比对 (13 个共有列、 10^{-9} 浮点容差), 跨 2022-12 至 2026-04 的六个区块共 163 行全部精确一致。

3.3 一行是什么：行级定义与主键

一行 = 一条 OrderFilled 日志 = 一个挂单方的一次成交。不是一个订单，也不是经济意义上的一“笔”交易。主键为日志坐标：

$$\text{id} \triangleq \text{链 ID_ 区块号_ 日志序号} \quad (\text{Polygon 链 ID} = 137),$$

因此重复爬取天然幂等。一个吃单方订单吃掉 N 个挂单 $\Rightarrow N$ 条成分腿行，外加 1 条中继腿行（见 §3.7）。实测腿数分布（2026-05-01 全天、按交易哈希分组、已剔中继腿）：单腿 1,428,757、双腿 346,321、三腿 115,373、四腿 53,221、五腿 29,458，尾部延伸至 12 腿以上。

须声明的口径损失。分析层（daily_aligned 与扩展 tape，共 24 列）**不保留** id、block_number、log_index。因此 8.56 亿行的统一 tape 只能按（block_timestamp, asset_id, maker, taker, price, usdc_amount）识别，行级回溯到区块浏览器只在原始层成立。

表 2: 逐笔成交字段（分析层）

字段	定义
maker / taker	挂单方 / 吃单方钱包地址
taker_direction	由资产转移事实判定（见 §3.6），非推断
price	成交价 $\in (0, 1)$ ，USDC/份，= 该结果代币的隐含概率
token_amount / usdc_amount	份数与名义额， $\text{usdc} = \text{price} \times \text{token}$
token_asset_id	ERC-1155 positionId（关联市场元数据的外键；同市场 Yes/No 是两个不同 id）
condition_id	市场标识（一个市场一个条件）
block_timestamp	秒级 Unix 时间，UTC（语义见 §3.4）

3.4 时间戳：精度、时区与语义

- **字段与单位**：block_timestamp，**整数 Unix 秒，UTC**。数据中不存在毫秒或更细的时间字段。
- **语义**：它是**区块头时间**，即包含该日志的 Polygon 区块的出块时刻，**不是撮合时刻**。由于撮合在链下、只有清算上链，该时间戳**系统性滞后于真实成交**。该滞后在本数据中**不可测量**，属于已声明的结构性限制。
- **分辨率上限**：同一区块内的所有成交共享同一时间戳。实测爬取区间（区块 86,127,122–90,226,886）的平均出块间隔为 **1.6272 秒**，故有效时间分辨率约 1.6 秒，**区块内先后顺序不可恢复**。
- **同秒并发密度**：公开数据集段 601,934,424 行落在 19,489,226 个不同的秒上（**30.9 行/秒**）；扩展段 253,680,029 行落在 4,076,023 个秒上（**62.2 行/秒**）。爬取区间内 99.5% 的区块至少含一条成交，平均 116.9 条原始行/区块。

对建模的直接约束：链上时间非均匀且高度并发，任何时间归并必须**重采样**，不能假设“每分钟一行”或“每秒一行”。本文的分钟聚合（§4.3）即据此设计。

3.5 采集机制与延迟

自建段经公共 Polygon JSON-RPC 的 `eth_getLogs` 按 `topic0` 扫描，不按地址过滤（避免漏掉未登记的交易所合约）。

- **重组保护**：扫描上界取 `finalized` 区块标签；端点不支持时退化为“当前高度 - 256 区块”。已终局的区块不可回滚，因此分片一经写出即不可变，管道内无重组处理逻辑。
- **延迟的结构下界**：Polygon 的检查点终局性，量级为数分钟。端到端延迟未做埋点测量，本文不给具体秒数。
- **吞吐**：8 并发在免费公共端点上实测 6,168,870 行 / 601 秒（约 83 区块/秒）；按此推算一个自然日的增量（约 41,000 区块）约需 8 分钟。实际一次补历史运行：470,732,037 行、78 个日分区、25,286 秒。

因此在工程上可支持“当日收盘后数分钟内可得”的更新节奏；但本研究的实证部分一律使用批量重建的冻结样本，不依赖低延迟。

3.6 主动买入与卖出的定义

方向来自资产转移事实，管道中不存在 `tick rule`，也不存在 `Lee-Ready` 式推断。判据按协议版本分列：

- **v1(旧 ABI)**：`makerAssetId = 0` 即挂单方付出的是抵押品 `USDC`，故挂单方为买入 (`maker_buys = true`)。
- **v2(新 ABI)**：事件显式带 `side` 字段，`side = 0` 即挂单方买入；注意 `makerAmountFilled` 与 `takerAmountFilled` 的币种含义随 `side` 互换。

随后无条件取镜像：

$$\text{maker_direction} = \begin{cases} \text{BUY}, & \text{maker_buys} \\ \text{SELL}, & \text{否则} \end{cases} \quad \text{taker_direction} = \text{与 maker 相反.}$$

定义严谨，但 `taker_direction` 本身不可直接当作主动买卖比。实测全量 `daily_aligned`: **SELL 519,655,280 行 (\$15.81B)** 对 **BUY 82,279,144 行 (\$3.81B)**，**SELL 占 86.3%**。这不是市场情绪，而是挂单方约 87% 在买方的机械结果。真正平衡且可用的方向量是 D ：

$$D \triangleq \text{sign}(\text{taker_direction}) \times \text{sign}(\text{outcome_seq}),$$

即这笔主动成交本身的方向：主动买 Yes 或主动卖 No 记为“押事件会发生” (+1)，主动卖 Yes 或主动买 No 记为“押事件不会发生” (-1)。两个乘数（主动方向、Yes/No 侧）都在**成交时点即完全确定，不含成交之后的任何价格信息，不是未来函数**——它是这笔成交自身携带的方向（微观结构里的带方向成交流），不是它引发的后果。扩展段全量 253,680,029 行实测真值表与定义完全一致，且分布平衡：

3.7 机械成交的处理

(一) 中继腿 (relay leg) ——有显式判据，已剔除。撮合合约 (CTF Exchange) 是中央对手方：一笔用户订单在 `OrderFilled` 中拆成“吃单方对撮合合约”的一条**总量记录**（中继腿）与“撮合合

表 3: 方向 D 的真值表与实测行数 (扩展段全量)

taker_direction	outcome_seq	D	行数
BUY	1 (Yes 侧)	+1	12,645,179
BUY	2 (No 侧)	-1	12,689,651
SELL	1 (Yes 侧)	-1	113,825,747
SELL	2 (No 侧)	+1	114,519,452
$D = +1$ 合计			127,164,631 (50.13%)
$D = -1$ 合计			126,515,398 (49.87%)

约对各挂单方”的多条成分腿。判据:

$$\text{is_relay} \triangleq [\text{taker} = \text{撮合合约地址}].$$

保留会使成交量恰好翻倍。真实例证 (市场” 特朗普 6 月 30 日前宣布美伊停火结束”, 2026-06-27 10:29:14 UTC): 三条成分腿 $2,196.87 + 26.51 + 4,966.93 = 7,190.31$ 份, 与中继腿总量 7,190.31 恰等——同一笔卖单从 0.974 吃到 0.973 两档。实测中继腿占自采段原始行的 **36.62%**。

(二) 铸造与合并 (mint / merge) ——结构性不在 tape 内。 结果代币基于条件代币框架 (CTF): 互补买单由撮合合约把 1 USDC 拆成一对代币 (PositionSplit), 互补卖单把一对代币合并回 USDC (PositionsMerge)。这两类是独立的事件类型、独立的 topic, 而成交 tape 只扫描 OrderFilled 的两个 topic, 故它们从未进入 tape, 无需也不存在”剔除”步骤。它们被单独采集到 CTF 生命周期层 (拆分 594,406,549、合并 54,835,728、赎回 186,685,966、准备 1,447,649、结算 1,313,030, 合计 838,688,922 条), 供市场生命周期与洗量识别使用。

已声明的残余限制。 撮合方为匹配两个同向吃单而铸造完整份额时, 产生的 OrderFilled 行未被单独标记。该类行是否被中继腿判据完全覆盖, 本仓库未做证明, 登记为限制项。

3.8 清洗漏斗 (自采段可逐级实测)

表 4: 自采段清洗漏斗 (公开数据集段的逐级口径不可得, 仅有单日对账)

阶段	行数	成交额
原始 OrderFilled (两版 ABI、全部合约)	476,900,809	\$19.92B
– 中继腿 (174,646,150, 占 36.62%)	302,254,659	–
– 非 Polymarket / 未识别合约 (790,034)	301,464,625	\$10.04B
– negRisk、非二元、元数据内连接	253,680,029	\$6.91B

两段合并前的原始规模为 1,678,481,799 行 (公开段 OrderFilled 原始 1,201,580,990 + 自采段 476,900,809)。negRisk 市场在两段中都被排除 (公开段作者如此构建, 自采段刻意复制同一排除以保持同构), 代价是 2024 年美国大选等旗舰市场不在样本内——这是已登记的覆盖限制。

3.9 结算事件

结算时刻取链上 `ConditionResolution` 首次事件（UMA 乐观预言机裁决上链的时点），覆盖 492 个登记市场中的 455 个；公开数据集自带的 `resolved_at` 元数据稀疏（56/425），不能作为结算依据。极少数争议市场多次重报，一律取首次事件。结算后价格恒为 0 或 1，结算时刻之后的窗口一律记缺失。

4 数据处理

4.1 事件视角统一： p_{event} 与方向 D

链上行只记录”某种代币值多少钱”；研究需要”事件发生的概率”。二元市场 Yes+No 价恒等于 1（由 mint/merge 套利钉住），换算唯一：

$$p_{\text{event}} = \begin{cases} \text{price}, & \text{outcome_seq} = 1 \text{ (Yes 侧)}, \\ 1 - \text{price}, & \text{outcome_seq} = 2 \text{ (No 侧)}, \end{cases}$$

非二元市场记缺失。方向 D 见 §3.6。

4.2 主题注册与时点化准入

以**事前注册**的关键词规则圈定与中国资产相关的市场：中东冲突、油价阈值、金属价格、美联储政策、俄乌冲突、中美贸易、台海风险、美政府停摆，共 8 主题 492 市场；注册后不增删。每个市场注册两个方向系数： $\text{orientation} \in \{\pm 1\}$ （市场结果轴 $\rightarrow$ 主题轴）与 $\sigma \in \{\pm 1\}$ （主题轴 $\rightarrow$ 品种方向先验）；已验证 $\sigma \times \text{orientation}$ 在每个（主题，品种）对内为常数。

时点化准入：市场只有在累计成交额首次达到 10 万美元之后才进入面板。用全窗口流动性筛选会让 1 月的样本构成依赖 4 月才实现的成交，属于用未来信息选样。

表 5：登记主题的全历史事件到达率（2023-09..2026-07，35 个月）。事件 = 分钟创新超稳健阈值 κ ；这是唯一可给出多年口径的频率统计，期货侧只有 125 天

主题	覆盖月份	月数	市场	事件数	次/月	成交额 (M\$)
mideast_conflict	2023-10..2026-07	25	116	168,471	6,739	1,767.4
russia_ukraine	2024-08..2026-07	24	117	102,249	4,260	311.6
us_china_trade	2024-11..2026-07	21	114	53,351	2,541	71.4
oil_price	2025-12..2026-07	8	93	51,640	6,455	131.2
metal_price	2025-12..2026-07	8	78	27,455	3,432	20.0
us_shutdown	2023-09..2026-07	28	31	15,842	566	164.9
fed_policy	2023-12..2026-07	32	21	14,453	452	36.1
taiwan_risk	2023-10..2026-07	34	8	10,171	299	46.2
合计	2023-09..2026-07	35	—	443,632	12,675	2,548.8

4.3 分钟聚合：从逐笔到主题信念创新 $N1$

处理链五步，每一步都对应一个具体的数据缺陷：

1. **截断与变换**（防端点发散）： p 截断到 $[0.02, 0.98]$ 后取 $\ell(p) = \ln \frac{p}{1-p}$ 。临近结算时概率贴近 0/1，未截断的 logit 会发散；消融显示结论对截断位置不敏感。
2. **买卖跳动去除**（防微观结构噪声）：分钟桶内按 taker 方向分堆取加权中位数再平均。逐笔价在买一与卖一之间跳动不代表概率变化。
3. **过时报价**（防用陈旧价冒充新信息）：端点价取最后成交（LOCF），距最后成交超过 120 分钟记缺失（p_age 规则）。
4. **主题聚合**（防小市场噪声主导）：市场层创新 $\Delta \ell_m$ 按 $w_m = \text{orientation}_m \sqrt{\text{cumUSDC}_m}$ 加权，其中累计成交额为**时点化累计**（仅用 $\leq t$ 的成交）：

$$N1_t \triangleq \frac{\sum_m w_m [\ell(p_{m,t}) - \ell(p_{m,t-})]}{\sum_m |w_m|}.$$

符号： m 为主题下第 m 个市场； $p_{m,t}$ 为市场 m 这一分钟的事件概率， $p_{m,t-}$ 为它上一次有成交那一分钟的概率； $\ell(\cdot)$ 为上一步的 logit 变换； w_m 为该市场权重（方向系数 $\times \sqrt{\text{累计成交额}}$ ）；分母 $\sum_m |w_m|$ 把加权求和化为加权平均。算例：某主题两市场，A ($w = 2$) 概率 $0.50 \rightarrow 0.60$ (logit 变化 $+0.41$)、B ($w = 1$) $0.40 \rightarrow 0.42 (+0.08)$ ，则 $N1 = (2 \times 0.41 + 1 \times 0.08) / (2 + 1) = +0.30$ ，正值表示这一分钟主题概率整体被上调，且主要由成交更大的 A 推动。

5. **桶标签取右端**（防前视）：分钟桶 $[T - 60s, T)$ 只含**严格早于** T 的成交，标签为 T 。

4.4 中国期货 1 分钟数据：来源与口径

- **来源与格式**：本地交付的主力连续 1 分钟 CSV，按自然日一个文件，GBK 编码，代码列形如 XX9999。交易所，另有列给出当时的实际合约。共 88 品种、3,496,950 根 K 线。
- **时间戳口径**：**bar 收盘戳（右端）**。21:01 表示区间 21:00–21:01。已实测：每个交易日日盘首根为 09:01、末根为 15:00。
- **时区**：北京时（UTC+8，无夏令时），存储为无时区标注。Polymarket 侧统一由 UTC 转 Asia/Shanghai 后去时区标注再连接。
- **量的口径**：volume 与 money 为分钟增量，open_interest 为分钟末的存量。
- **质量核验**：五个主用品种的重复时间戳 0、OHLC 违例 0；零成交量 K 线 SC 301 根、AG 70 根，其余为 0。

4.5 时段、休市与换月：逐条处理

(一) 交易时段的确切分钟。 日盘每日 225 根，分三段连续：09:01--10:15 (75 根)、10:31--11:30 (60 根)、13:31--15:00 (90 根)。夜盘自 21:01 起单段连续，收盘时刻**由数据实测而非硬编码**（取每日夜盘末根的众数）：SC/AU/AG 为 02:30 (330 根)、CU 为 01:00 (240 根)、M 为 23:00 (120 根)。

(二) 夜盘归属。 夜盘 K 线存放在次一自然日的文件中（故周一文件从不含夜盘）。按时间戳重新归属： T 日夜盘归属 $T + 1$ 交易日，即夜盘在一个交易日内先于日盘。测试断言周一交易日含上周五 21:01 至周六 02:30。交易日全集由“存在日盘 K 线的自然日”实测得到，不依赖假日表。

(三) 休市与前向收益：连续分钟段规则。 不枚举休市时刻，而用一条统一规则：相邻 K 线时间差 $\neq 1$ 分钟即断段，

$$\text{seg}_t \triangleq \sum_{u \leq t} \mathbf{1}\{\Delta ts_u \neq 1\text{min}\}, \quad \text{fwd}_{h,t} \triangleq (\ln C_{t+h} - \ln C_t) \cdot \mathbf{1}\{\text{seg}_{t+h} = \text{seg}_t\}.$$

其中 C_t 为期货这一分钟的收盘价 ($C = \text{close}$)， h 为前向分钟数 (取 1/2/3/5/10/15)， Δts_u 为相邻两根 K 线的时间差， $\mathbf{1}\{\cdot\}$ 是指示函数 (括号内条件成立取 1、否则取 0)， seg_t 为连续段编号。读法：只有当 t 与 $t+h$ 落在同一连续段 (seg 相等) 时才计算前向收益，否则乘以 0 记为缺失。该规则对上午小节休息 (10:15→10:30)、午间休市 (11:30→13:30)、日盘收至夜盘开 (15:00→21:00)、夜盘收至次日开盘、周末与假日 一视同仁，跨段一律置缺失而非跨越。任何前向收益都不跨越休市，也不跨日。

实测结果与该规则严格自治：每个品种 125 天共 **495 个连续段** (日盘 3 段 $\times$ 125 + 夜盘 120 段；5 个无夜盘日均为长假后首日)。 fwd_{15} 的有效占比恰等于 $1 - 15 \times 495/N$ ：SC/AU/AG 为 89.04%、CU 86.96%、M 82.54%——即段尾截断是标签缺失的唯一来源。

(四) 涨跌停。 主力连续序列不带涨跌停价表，故以 $\text{locked}_t \triangleq \mathbf{1}\{H_t = L_t\}$ 作代理。实测占比：SC 2.43%、AG 0.77%、M 0.29%、CU 0.24%、AU 0.03%。已知极端例：2026-03-09 SC 日盘 225 根全部锁死 (一字涨停)。须诚实声明：该代理无法区分“清淡无成交”与“封板”，且当前分析中它只作监控，未作为过滤条件参与任何 IC 或事件研究。封板期收益被截断，方向上使结果偏保守 (低估可实现收益的同时也低估了不可成交性)。

(五) 换月。 主力序列由数据方给出 (其判定规则未公开，登记为未核实项)。实测切换全部发生在 21:01，即交易日边界，故一个交易日内合约唯一 (多合约日数 = 0)；样本内切换次数 SC 6 次、CU 6 次、AU 3 次、AG 2 次、M 1 次，段中切换 0 次。分钟层因此无需额外换月掩码——切换点必为夜盘段首根，其 r_1 本已缺失，且无任何前向窗口可跨越它。日频层另行显式剔除换月日。

4.6 时差与窗口切分

北京与美东相差 12–13 小时 (夏令时切换由时区库处理)，国内凌晨闭市段恰对应美东主活跃时段，这是识别设计的基础。图 1(a) 给出实测证据：登记市场的成交笔数在北京时 21:00–06:00 显著高于日盘时段，而这正是国内期货休市或夜盘时段。

表 6：交易日四段窗口 (SC；其余品种按各自夜盘收盘时刻定义)

窗口	北京时间	对应美东	窗口收益定义
傍晚闭市 gap_pm	前日 15:00→21:00	凌晨 → 上午	$\ln(\text{夜盘开}/\text{前日收})$
夜盘 night	21:00→02:30	上午 → 下午	$\ln(\text{夜盘收}/\text{夜盘开})$
凌晨闭市 gap_am	02:30→09:00	下午 → 晚间	$\ln(\text{日盘开}/\text{夜盘收})$
日盘 day	09:00→15:00	美国深夜	$\ln(\text{日盘收}/\text{日盘开})$

4.7 防前视协议 (清单)

1. 分钟桶标签取右端，信号桶严格早于期货 K 线收盘戳 (图 1b)；




图 1: (a) Polymarket 登记市场成交笔数与 SC 成交量的日内分布（北京时，125 天均值；灰底为 SC 交易时段，休市处期货曲线断开）。(b) 防前视的时间关系：分钟桶右端标签使信号严格早于被解释的收益。

2. 市场准入时点化，聚合权重用时点化累计成交额；
3. 全部滚动 / 展开统计量只用 $\leq t$ 的观测（z 分数、MAD 阈值、展开分位数一律 `shift(1)` 或严格 $< t$ 估计）；
4. 测量模型参数在样本前段（2026-05-15 前）估计后冻结，其后因果应用；
5. 结算后价格、超时报价、换月日一律记缺失而非填充；
6. 全部定义与阈值已冻结并哈希登记（`freeze/manifest.json`），2026-07-18 之后为未触碰样本。

5 信号定义

5.1 设计原则与数值化的合理性

信号库共 40 个分钟级信号，分四族各 10 个。设计遵循四条原则：

1. **一律数值化、且默认有大小顺序。** 离散事件不以布尔量入库，而以签名值 $\{-1, 0, +1\}$ 或强度值（计数、衰减和、一致率）表示，使得秩相关有意义、可直接进入线性组合。
2. **一律时序归一化。** 所有与量纲相关的量取滚动 z 分数

$$z_W(x_t) \triangleq \frac{x_t - \mu_W(x_t)}{\sigma_W(x_t)}, \quad W = 4800 \text{ 交易分钟 (约 10 个 SC 交易日)}, \text{ 最少 960 个观测,}$$

滚动窗只用 $\leq t$ 的观测。这既使跨品种可比，也吸收了波动与成交量的日内与月度水平漂移。

3. **有界化优先。** 凡能构造为比值的（ $N5$ 流不平衡比、 $K8$ 方向一致率）取有界形式，避免极端值主导秩统计以外的用法。

4. **一族一机制**。N 族只用 Polymarket 数据，C 族引入期货量价，K 族把离散事件转为统计量，X 族做状态条件化。这样任何显著性都能归因到具体的数据来源（见 §6.5 的族级结论）。

记号： $N1_t$ 为主题信念创新 (§4.3)， $r1_t$ 为期货 1 分钟对数收益； m_t, v_t, u_t, a_t 分别为此前 15 分钟的涨幅、已实现波动、成交量、成交额经 z_{4800} 归一化后的值：

$$m_t = z_{4800} \left(\sum_{u=t-14}^t r1_u \right), \quad v_t = z_{4800} \left(\sqrt{\sum_{u=t-14}^t r1_u^2} \right),$$

$$u_t = z_{4800} \left(\sum_{u=t-14}^t V_u \right), \quad a_t = z_{4800} \left(\sum_{u=t-14}^t A_u \right);$$

f_t, U_t, n_t, M_t 为 15 分钟签名流、成交额、笔数与活跃市场数； κ_t 为稳健事件阈值，

$$\kappa_t = \max(3 \times 1.4826 \times \text{MAD}_{4800}(N1 \neq 0), 0.05), \quad e_t = \mathbf{1}\{N1_t > \kappa_t\} - \mathbf{1}\{N1_t < -\kappa_t\}.$$

5.2 N 族：数值信号（只用 Polymarket 数据）

表 7: N 族 10 个数值信号

信号	名称	公式	构造意图
N1	主题信念创新	$N1_t$	分钟级 logit 概率变化的加权聚合，全库基元
N2	15 分钟累积创新	$\sum_{u=t-14}^t N1_u$	单分钟创新噪声大，短窗求和提高信噪比
N3	签名流强度	$z_{4800} \left(\sum_{u=t-14}^t f_u \right)$	以美元计的方向性成交流，与价格变化互补
N4	创新标准分	$z_{4800}(N2_t)$	把量纲不可比的 logit 变化化为可跨品种比较的数值
N5	流不平衡比	$\left(\sum_{u=t-14}^t f_u \right) / \left(\sum_{u=t-14}^t U_u \right)$	方向性占比，剔除总量水平的影响，取值天然有界
N6	成交强度	$z_{4800}(\ln(1 + \sum_{u=t-14}^t n_u))$	笔数强度衡量关注度，对数化压缩长尾
N7	多主题复合创新	$z_{4800} \left(\sum_{\theta} \sum_{u=t-14}^t N1_u^{\theta} \right)$	跨主题等权合成，捕捉宏观级共同冲击
N8	市场广度	$z_{4800} \left(\frac{1}{15} \sum_{u=t-14}^t M_u \right)$	参与市场数衡量信息是集中于个别市场还是普遍
N9	信念波动	$z_{4800}(\text{sd}_{60}(N1))$	二阶量：信念本身的不稳定程度（分歧度代理）
N10	信念不确定度	$z_{4800} \left(\sum_{u=t-14}^t N1_u \right)$	无向活跃度，与 N2 的有向量配对识别方向性 vs 纯噪声

5.3 C 族：与标的量价数据组合的信号

表 8: C 族 10 个量价组合信号 (m, v, u, a 均为前 15 分钟量价统计量的 z_{4800} 归一化值)

信号	名称	公式	构造意图
C1	创新 $\times$ 涨幅 (确认)	$N4_t \cdot m_t$	事件与价格同向时放大: 信息被确认
C2	创新 $\times$ 价未动	$N4_t \cdot \mathbf{1}\{ m_t < 0.5\}$	事件已发生而价格未反应, 滞后反应假说的直接检验
C3	波动折减创新	$N4_t / (1 + \max(v_t, 0))$	高波动期同样的创新信息含量更低, 按波动折减
C4	创新 $\times$ 放量	$N4_t \cdot u_t$	成交量确认: 有量的事件更可能推动价格
C5	流价同向	$N3_t \cdot \mathbf{1}\{\text{sign}(N3_t m_t) > 0\}$	只在预测市场资金流与期货价格同向时取值
C6	创新 $\times$ 波动状态	$N4_t \cdot v_t$	波动状态交互, 检验信息传导是否依赖市场状态
C7	正交化创新	$N4_t - \hat{\beta}_t m_t, \quad \hat{\beta}_t = \frac{E_{4800}[N4_t m_t]}{E_{4800}[m_t^2]}$	滚动回归剔除动量分量, 留下 Polymarket 的正交信息
C8	未兑现缺口	$z_{4800}\left(\sum_{u=t-119}^t N1_u\right) - z_{4800}\left(\sum_{u=t-119}^t r1_u\right)$	信念已动而价格未动的累积差; 注意第二腿本身是反转因子
C9	不平衡 $\times$ 成交额	$N5_t \cdot a_t$	以期货成交额加权方向性占比, 量价双重确认
C10	信念波动 - 实现波动	$N9_t - v_t$	两个市场的波动预期之差, 跨市场相对不确定度

5.4 K 族：基于原始离散事件的复杂统计指标

表 9: K 族 10 个复杂统计指标（时序分桶、频率、游程、到达率、截面计数）

信号	名称	公式	构造意图
K1	净事件计数	$\sum_{u=t-59}^t e_u$	1 小时窗内上行减下行事件数，最直接的频率统计
K2	分时频率异常	$(c_t - \mu_{h(t)}) / \sigma_{h(t)}, \quad c_t = \sum_{u=t-59}^t \mathbf{1}\{ N1_u > \kappa_u\}$	时序分桶：按小时分桶后标准化，剔除事件到达的日内季节性
K3	跨主题事件计数	$\sum_{u=t-59}^t \sum_{\theta} \mathbf{1}\{ N1_u^\theta > \kappa_u\}$	截面统计：同一宏观冲击在多主题同时触发的计数
K4	指数衰减强度	$K4_t = \lambda K4_{t-1} + e_t, \quad \lambda = e^{-1/30}$	半衰期约 21 分钟的加权累计，近期事件权重更高
K5	同向连发长度	$\max_{u \in [t-29, t]} L_u, \quad L_u = \text{连续同向事件游程长}$	游程统计：连续同向触发是趋势性信息的标志
K6	近因得分	$e^{-g_t/60} \cdot \text{sign}(e_{\tau(t)}), \quad g_t = t - \tau(t)$ (上次事件)	距上次事件越近权重越高，把离散事件转为连续衰减
K7	尾部幅度和	$z_{4800} \left(\sum_{u=t-59}^t N1_u \mathbf{1}\{ N1_u > \kappa_u\} \right)$	只累计超阈值部分的幅度，区分「多次小跳」与「一次大跳」
K8	方向一致率	$\frac{U_{120} - D_{120}}{U_{120} + D_{120}}, \quad U_{120} = \sum_{u=t-119}^t \mathbf{1}\{N1_u > \kappa_u\}$	2 小时窗内方向纯度，取值有界于 $[-1, 1]$
K9	到达率热度	$(1 + \text{med}_5(\Delta\tau))^{-1}$	最近 5 次事件间隔中位数的倒数，泊松强度的稳健估计
K10	跨主题共振	$\mathbf{1}\left\{ \sum_{\theta} \max_{u \in [t-14, t]} \mathbf{1}\{ N1_u^\theta > \kappa_u\} \geq 2 \right\} \cdot \text{sign}(N2_t)$	至少两个主题在 15 分钟内同时触发，签名化为 $\{-1, 0, 1\}$

5.5 X 族：条件与状态交互信号

表 10: X 族 10 个条件信号（签名离散型，取值 $\{-1, 0, +1\}$ ）

信号	名称	公式	构造意图
X1	共振 + 期货确认	$K10_t \cdot \mathbf{1}\{\text{sign}(K10_t m_t) > 0\}$	共振且期货同向，最强确认态
X2	共振但价未动	$K10_t \cdot \mathbf{1}\{ m_t < 0.5\}$	共振而期货无反应，未兑现共振
X3	事件 × 高波动	$e_t \cdot \mathbf{1}\{v_t > 1\}$	状态交互：波动放大期的事件
X4	事件 × 放量	$e_t \cdot \mathbf{1}\{u_t > 1\}$	状态交互：成交放大期的事件
X5	一小时内同向二击	$\mathbf{1}\{N1_t > \kappa_t, U_{60} \geq 2\} - \mathbf{1}\{N1_t < -\kappa_t, D_{60} \geq 2\}$	同向重复触发，过滤单次噪声
X6	大额 + 价未动	$\text{sign}(f_t) \cdot \mathbf{1}\{U_t > q_{0.99}\} \cdot \mathbf{1}\{ m_t < 0.5\}$	分钟成交额超展开 99 分位而期货未动
X7	事件 × 夜盘	$e_t \cdot \mathbf{1}\{\text{夜盘}\}$	时段交互：夜盘与美东活跃时段重叠
X8	事件 × 开盘 30 分钟	$e_t \cdot \mathbf{1}\{\text{日盘前 30 分钟}\}$	时段交互：隔夜信息集中释放的窗口
X9	延迟反应	$e_{t-3} \cdot \mathbf{1}\{ r_{t-2 \rightarrow t} < 0.3 \text{rv}_{15t}\}$	3 分钟前有事件而价格仍未动，滞后交易的直接构造
X10	多尺度同向	$e_t \cdot \mathbf{1}\{\text{sign}(N1_t (N2_t - N1_t)) > 0\}$	当刻跳与此前 14 分钟累积同向，多尺度一致性确认

5.6 另行登记的事件跳因子 (J 族)

15 分钟桶 $|\Delta\ell|$ 超过 $3 \times 1.4826 \times \text{MAD}_{48\text{桶}}$ 且桶内成交 $\geq \$10,000$ ；同主题同时戳折叠为一个事件， $J_{\text{evt}} = \sqrt{\text{usdc}}$ 加权的 $\text{orientation} \times \Delta\ell$ 。两个冻结登记单元：SC 盘中日盘跳（映射到期货分钟网格延迟 ≤ 2 分钟且落在日盘）；M 孤立跳（同桶无其他市场共跳， $n_{\text{cojump}} = 0$ ）。公式与推断见完整版 § 三-5b。

6 指标口径与统计结果

6.1 IC 的数学定义

对信号 s 与视界 $h \in \{1, 2, 3, 5, 10, 15\}$ 分钟：

$$\text{pooled RankIC}_h \triangleq \rho_S(s_t, \text{fwd}_{h,t}) \quad (\text{全部有效分钟行的 Spearman 秩相关}), \quad (1)$$

$$\text{IC}_h^{(d)} \triangleq \rho_S(s_t, \text{fwd}_{h,t} \mid t \in \text{交易日 } d) \quad (\text{日内有效行} \geq 30 \text{、且 } s \text{ 非常数}), \quad (2)$$

$$\text{ICIR}_h \triangleq \frac{\overline{\text{IC}_h^{(d)}}}{\text{sd}(\text{IC}_h^{(d)})}, \quad t_h \triangleq \text{ICIR}_h \sqrt{D}, \quad (3)$$

D 为有效交易日数。Pearson IC 同式以线性相关代入，全表已算但因分钟收益的厚尾而以 RankIC 为主口径。

离散信号的事件研究口径。 对签名离散信号，取 $s_t = +1$ （上行触发）的全部时点，报告：

- 频率：触发次数 / 5.95 个月（125 交易日 / 21）；
- 条件收益：各视界 $\overline{\text{fwd}_h}$ ，单位 bp；
- 终止条件视界：从触发到下一次触发前一分钟的收益（同段内，上限 60 分钟），并报告平均持有分钟数；
- 显著变动比例： $P(|\text{fwd}_h| > 10\text{bp})$ （即价格变动超过千分之一的比例）；
- 基准：同品种全样本无条件的 $\overline{\text{fwd}_h}$ 与 $P(|\text{fwd}_h| > 10\text{bp})$ 。须声明：因期货分钟数据只有 125 天，无法构造“过去一年”的基准，故用全样本无条件量代替；
- 检验： $H_0: \mathbb{E}[\text{fwd}_h \mid s = +1] = \text{基准均值}$ ， t 统计量按交易日聚类稳健估计（触发在时间上高度成簇，普通 t 会严重高估显著性）。

6.2 全信号登记表

6.3 连续信号：IC 期限结构

6.4 离散信号：频率与事件研究

6.5 多重检验下的族级结论

这是本节最重要的结果。

表 11: 40 个信号的登记全表: 类型、频率、取值统计与跨品种 RankIC。”最大 $|t|$ ”取该信号在 5 个品种 $\times 6$ 视界共 30 个格上的最大绝对 t , 括号内为对应品种

信号	类型	月频 (均)	取值统计 (跨品种均)	RankIC $\times 100$ (1'/5'/15')	最大 $ t $
N1	连续	4,612 分钟	$\mu-0.00, \sigma 0.03, \text{kurt} +23.4$	-0.10 / -0.08 / +0.08	2.58 (SC)
N2	连续	6,841 分钟	$\mu-0.00, \sigma 0.10, \text{kurt} +18.2$	-0.07 / +0.04 / +0.55	1.81 (CU)
N3	连续	9,386 分钟	$\mu+0.01, \sigma 1.32, \text{kurt} +178.0$	-0.05 / -0.17 / -0.29	1.95 (AG)
N4	连续	9,254 分钟	$\mu+0.00, \sigma 1.10, \text{kurt} +138.2$	+0.03 / +0.12 / +0.56	1.55 (M)
N5	连续	7,540 分钟	$\mu+0.02, \sigma 0.60, \text{kurt} -1.5$	+0.07 / +0.08 / +0.24	2.43 (AG)
N6	连续	9,386 分钟	$\mu+0.00, \sigma 1.15, \text{kurt} +104.4$	+0.16 / +0.20 / +0.39	1.80 (M)
N7	连续	9,530 分钟	$\mu+0.00, \sigma 1.10, \text{kurt} +67.5$	+0.04 / -0.01 / +0.90	1.55 (M)
N8	连续	9,385 分钟	$\mu+0.03, \sigma 1.22, \text{kurt} +100.0$	+0.16 / +0.21 / +0.39	1.88 (M)
N9	连续	9,255 分钟	$\mu+0.06, \sigma 1.20, \text{kurt} +101.8$	+0.01 / +0.03 / +0.19	1.80 (M)
N10	连续	9,254 分钟	$\mu+0.03, \sigma 1.16, \text{kurt} +128.9$	-0.03 / -0.02 / +0.15	2.69 (M)
C1	连续	8,879 分钟	$\mu+0.02, \sigma 1.38, \text{kurt} +545.9$	-0.66 / -0.55 / +0.22	4.39* (CU)
C2	连续	4,888 分钟	$\mu+0.00, \sigma 0.80, \text{kurt} +212.0$	-0.08 / -0.26 / +0.02	2.89 (CU)
C3	连续	9,254 分钟	$\mu+0.00, \sigma 0.96, \text{kurt} +188.4$	+0.01 / +0.04 / +0.49	1.76 (CU)
C4	连续	8,954 分钟	$\mu-0.01, \sigma 1.48, \text{kurt} +393.0$	-0.04 / +0.16 / +0.18	2.00 (M)
C5	连续	4,519 分钟	$\mu+0.01, \sigma 0.96, \text{kurt} +151.4$	-2.03 / -1.43 / -0.72	10.42* (M)
C6	连续	8,879 分钟	$\mu-0.02, \sigma 1.53, \text{kurt} +545.1$	-0.03 / +0.11 / +0.36	2.19 (CU)
C7	连续	9,416 分钟	$\mu+0.00, \sigma 1.10, \text{kurt} +139.2$	+0.32 / +0.15 / +0.30	3.99 (AG)
C8	连续	10,002 分钟	$\mu+0.00, \sigma 1.51, \text{kurt} +56.3$	+1.37 / +1.68 / +1.64	12.85* (M)
C9	连续	7,235 分钟	$\mu+0.01, \sigma 0.66, \text{kurt} +26.1$	-0.24 / -0.46 / -0.81	2.29 (SC)
C10	连续	9,965 分钟	$\mu+0.08, \sigma 1.57, \text{kurt} +55.8$	-0.51 / -0.85 / -0.76	4.81* (AU)
K1	计数	4,536 分钟	$\mu-0.05, \sigma 1.18, \text{kurt} +0.6$	-0.08 / -0.19 / -0.49	2.18 (AG)
K2	连续	8,822 分钟	$\mu+0.07, \sigma 1.28, \text{kurt} +7.2$	-0.09 / -0.27 / -0.05	2.67 (M)
K3	计数	7,422 分钟	$\mu+4.22, \sigma 4.41, \text{kurt} +3.7$	+0.08 / +0.38 / +0.85	1.50 (SC)
K4	连续	9,680 分钟	$\mu-0.02, \sigma 0.61, \text{kurt} +7.4$	+0.04 / +0.28 / +0.28	2.66 (AG)
K5	离散	2,837 次	{0, 1, 2, 3, 4}, 非零 26.70%	+0.12 / +0.06 / +0.51	2.01 (CU)
K6	连续	9,680 分钟	$\mu-0.00, \sigma 0.59, \text{kurt} -0.9$	-0.02 / +0.30 / +0.58	2.26 (M)
K7	连续	9,254 分钟	$\mu+0.08, \sigma 1.25, \text{kurt} +90.4$	+0.06 / +0.24 / +0.56	3.24 (M)
K8	连续	5,621 分钟	$\mu-0.02, \sigma 0.46, \text{kurt} -0.8$	+0.09 / +0.27 / +0.23	2.34 (AG)
K9	连续	9,677 分钟	$\mu+0.10, \sigma 0.11, \text{kurt} +3.8$	-0.29 / -0.52 / -0.97	1.76 (M)
K10	离散	916 次	{-1, 0, 1}, 非零 8.29%	-0.14 / +0.02 / -0.12	1.29 (SC)
X1	离散	452 次	{-1, 0, 1}, 非零 4.08%	-0.75 / -0.70 / -0.68	1.81 (CU)
X2	离散	483 次	{-1, 0, 1}, 非零 4.36%	-0.14 / -0.33 / -0.71	2.48 (CU)
X3	离散	55 次	{-1, 0, 1}, 非零 0.54%	+0.05 / -0.09 / -0.06	2.57 (AU)
X4	离散	54 次	{-1, 0, 1}, 非零 0.52%	+0.10 / -0.29 / -0.16	2.20 (AU)
X5	离散	323 次	{-1, 0, 1}, 非零 3.05%	-0.11 / -0.04 / -0.00	2.91 (AU)
X6	离散	30 次	{-1, 0, 1}, 非零 0.27%	+0.32 / +0.31 / +0.22	2.65 (AU)
X7	离散	215 次	{-1, 0, 1}, 非零 2.01%	-0.10 / -0.12 / +0.07	2.56 (AU)
X8	离散	24 次	{-1, 0, 1}, 非零 0.23%	-0.37 / -0.16 / +0.13	3.04 (M)
X9	离散	199 次	{-1, 0, 1}, 非零 1.90%	-0.07 / +0.07 / -0.06	2.15 (AU)
X10	离散	144 次	{-1, 0, 1}, 非零 1.35%	-0.31 / -0.03 / -0.20	2.68 (CU)

表 12: $|t|$ 最大的 14 个连续信号格的六视界 RankIC ($\times 100$)

信号 · 品种	1'	2'	3'	5'	10'	15'	ICIR ₁₅	t_{15}
C8·M	+1.59	+1.40	+1.24	+1.09	+0.93	+0.48	+0.73	+8.06
C8·CU	+1.41	+1.64	+1.78	+1.85	+1.97	+1.96	+0.61	+6.77
C5·M	-3.31	-3.10	-2.71	-2.36	-2.04	-1.43	-0.21	-2.09
C8·AG	+1.25	+1.26	+1.33	+1.33	+0.60	+0.31	+0.43	+4.72
C8·SC	+1.61	+1.96	+2.30	+2.60	+2.98	+3.28	+0.61	+6.81
C8·AU	+0.97	+1.18	+1.19	+1.54	+1.87	+2.19	+0.77	+8.48
C5·AG	-2.11	-1.82	-1.62	-1.44	-0.86	-1.38	-0.25	-2.60
C5·CU	-1.80	-1.34	-1.41	-0.94	-0.29	+0.12	-0.07	-0.74
C5·SC	-1.69	-1.52	-1.32	-1.00	-0.30	-0.09	-0.23	-2.51
C5·AU	-1.22	-1.39	-1.28	-1.39	-0.79	-0.82	-0.22	-2.44
C10·AU	-0.87	-1.30	-1.42	-1.77	-2.49	-3.15	-0.36	-3.95
C1·CU	-1.11	-0.94	-0.63	-0.18	+1.28	+2.01	+0.02	+0.21
C1·AG	-1.34	-1.38	-1.68	-1.75	-1.32	-1.06	-0.20	-2.08
C7·AG	+0.99	+0.89	+0.66	+0.19	-0.38	-0.68	-0.02	-0.22




图 2: (a) RankIC 的期限结构热图; (b) 15 分钟视界的 ICIR。注意入选的 14 个格全部来自 C 族——即全部含期货侧量价腿。

每类信号按其适当口径检验。连续与计数信号用 IC 的 t ; 离散信号用事件研究的 t , 不用 IC。理由是离散信号取值只有 $\{-1, 0, +1\}$ 且九成以上为 0, 在其上算秩相关会因海量并列而退化, ”触发之后是否真的动了”才是它的适当判据 (§6 的事件研究口径)。合计 1,476 个检验 (连续 IC 840

表 13: 离散信号事件研究 (取 +1; $n \geq 100$ 的格中 $\max |t|$ 前 14)。”至下次”为终止条件视界收益 (括号内为平均持有分钟数), $P_{10'}$ 为 10 分钟内价格变动超 10bp 的比例, ”基准”为同品种无条件同口径比例

信号 · 品种	次/月	1'	2'	3'	5'	10'	15'	至下次	$P_{10'}$	基准	$\max t $
X6-AU	37	+0.91	+1.27	+0.25	-0.35	-1.36	-0.19	-3.48 (32')	39.0%	40.6%	2.65
X2-CU	182	-0.26	-0.48	-0.65	-1.09	-1.73	-1.38	+0.54 (24')	36.9%	38.1%	2.48
X10-AU	125	+0.43	+0.57	+0.46	+0.49	+0.58	+0.87	-0.86 (27')	36.8%	40.6%	2.36
X7-AU	177	+0.35	+0.39	-0.10	+0.01	+0.48	+0.82	-0.15 (20')	37.0%	40.6%	2.27
X5-CU	46	+0.24	+0.93	+0.82	+1.00	+1.77	+1.54	+0.96 (28')	34.3%	38.1%	2.19
X9-AU	162	-0.13	-0.30	-0.55	-0.56	-0.07	-0.06	-0.61 (26')	37.4%	40.6%	2.15
K5-CU	1401	+0.10	+0.18	+0.29	+0.49	+0.82	+1.12	+0.58 (36')	38.9%	38.1%	2.01
X8-AU	18	-1.30	-1.18	-1.68	-1.80	-0.79	-2.09	-3.96 (36')	52.8%	40.6%	1.96
X9-AG	65	+0.38	+0.39	-0.07	+0.29	+3.97	+2.47	-2.66 (35')	73.1%	69.0%	1.88
X5-AU	290	+0.15	+0.09	-0.13	-0.23	-0.22	+0.11	-0.56 (16')	36.7%	40.6%	1.84
X10-AG	44	-1.65	-4.14	-3.93	-4.82	-7.14	-7.77	-9.97 (30')	76.9%	69.0%	1.83
X1-CU	163	-0.32	-0.44	-0.46	-0.39	+0.18	+1.36	-1.44 (25')	37.3%	38.1%	1.81
X9-M	54	+0.12	+0.20	+0.82	+0.49	-0.42	-0.81	-0.78 (23')	38.8%	36.2%	1.78
X4-AU	43	+0.88	+1.69	+0.80	+1.47	+3.32	+3.21	-3.04 (29')	63.6%	40.6%	1.75

离散信号触发后的平均收益路径 ($|t|$ 最大的 6 个格): 全部 636 个事件检验 $\max |t| = 3.04 < \text{Bonferroni 门槛 } 3.95$, 无一通过




图 3: 离散信号触发后的平均收益路径与同品种无条件基准的对照 ($|t|$ 最大的 6 个格)。

个 + 离散事件 636 个), 统一 Bonferroni 门槛 $|t| > 4.15$ 。按族分解:

两句话读法:

1. 只用 Polymarket 数据构造的 23 个信号 (N 族 10 个、K 族 10 个、以及 X 族中不含期货腿的 X5/X7/X10), 在 798 个检验中 $\max |t| = 3.24$, 无一通过门槛。
2. 全部 13 个通过门槛的信号格 (C1、C5、C8、C10 各若干品种) 无一例外来自 C 族, 即无一例外含有期货侧量价腿; 没有任何一个纯 Polymarket 信号格、也没有任何一个离散事件信

表 14: 族级多重检验结论（各族按适当口径：连续用 IC、离散用事件研究；统一门槛 $|t| > 4.15$ 。数据由 `make_concise_table.py` 从 `signal_grid.parquet` 计算）

族	数据来源	检验数	$\max t $	通过门槛
N	仅 Polymarket	300	2.69	0
K	仅 Polymarket	318	3.24	0
X	Polymarket + 期货状态	558	3.04	0
C	Polymarket $\times$ 期货量价	300	12.85	49
仅用 Polymarket 数据的 23 个信号		798	3.24	0

号格通过。C8 经双腿分解与严格增量检验，其强度由期货自身的短期反转承载，Polymarket 腿的分钟级增量已被否定（五品种全部未通过预设确认门槛）。

一处必须交代的口径修正。 若对离散信号误用 IC 口径，X1·SC 与 X6·AG 会显示 $|t| = 4.80$ 与 5.20、看似通过门槛；但改用适当的事件研究口径后二者分别只有 1.10 与 2.46，均不通过。其中 X6·AG 的上行触发仅 6 次，属退化格。这说明在 $\{-1, 0, +1\}$ 上算秩相关确实会产生假阳性，报告采用事件研究口径后，离散侧通过门槛的格数为零。

因此分钟频率上的结论是干净的：显著性全部来自期货侧，没有一点来自 Polymarket 侧。表 13 中离散信号的 $P_{10'}$ 与基准比例也几乎处处相当，与此一致。

6.6 检出力与最小可检测效应

必须回答的一问：这是真的没有，还是 125 天太短看不出来？只报“未通过门槛”是不够的：Bonferroni 是往保守方向的修正，用一个更难拒绝零假设的门槛去支撑“没有信号”，形式上恰好是反的。因此本节给出 **最小可检测效应**（MDE）：在既有样本与既定门槛下，多大的效应会被我们以 80% 的把握检出。凡大于 MDE 的效应，本样本已经排除；凡小于 MDE 的，本样本无法分辨，只能留待未触碰样本裁决。

标准误由已有量精确反解，不引入任何新假设：连续侧 $SE = \text{sd}(\text{IC}^{(d)})/\sqrt{D}$ （即 $t = \text{ICIR}\sqrt{D}$ 的反解）；离散侧 $SE = |\text{条件超额}|/|t|$ （日聚类 t 的反解，限 $n_+ \geq 100$ ）。则

$$\text{MDE} = (z_\alpha + z_\beta) \times SE, \quad z_\alpha = 4.15 \text{ (全族门槛)}, \quad z_\beta = 0.84 \text{ (检出力80\%)}.$$

三点读法：

- 连续侧：**可检出的 RankIC 下限从 $h = 1$ 的 0.019 升到 $h = 15$ 的 0.070。与实测对照——六个视界无一例外，纯 Polymarket 信号实测的最大 $|\text{RankIC}|$ 都低于该视界的 MDE，且大致只有其一半（ $h = 1$: 0.0102 对 0.0192； $h = 5$: 0.0207 对 0.0414； $h = 15$: 0.0392 对 0.0700）。即这些信号的效应量本就落在本样本可分辨的下限以下，“没检出”与“效应确实小于可分辨下限”两种解释在此是一致的。
- 离散侧与成本门槛的对照：** $h = 10$ 时中位格的 MDE 为 **6.9 bp**，低于完整换手成本门槛 16 bp。也就是说，任何在中位格上具备经济可交易性的效应（超过成本），都会被本样本检出——既然没有检出，就可以排除。但必须同时诚实报告：p90 格的 MDE 为 **18.8 bp**，高于成本门

表 15: 最小可检测效应（各格取中位数；离散侧另给 p90 以示分布。数据由 `make_concise_table.py` 从 `signal_grid.parquet` 计算）

<i>h</i>	连续侧（RankIC 单位）		离散侧（bp）		
	SE 中位	MDE	SE 中位	MDE 中位	MDE p90
1	0.00385	0.0192	0.32	1.6	4.8
2	0.00531	0.0265	0.45	2.2	7.7
3	0.00642	0.0320	0.53	2.7	8.4
5	0.00830	0.0414	0.84	4.2	10.2
10	0.01183	0.0590	1.39	6.9	18.8
15	0.01404	0.0700	1.82	9.1	23.3

槛，故正确表述是 ” 中位格可排除”，而非” 全部格可排除”；检出力最弱的那部分格仍存在未被排除的空间。

3. 有效天数不是 125：逐日 IC 的有效交易日中位为 109 天（日内取值恒定或有效行不足 30 的交易日被剔除），正文一律不按 125 天计算检出力。

据此，本文的否定结论应读作：在中位检出力 的格上，成本门槛之上的整个效应区间已被排除；低于 MDE 的效应本样本不可分辨，不主张其为零，留待 2026-12 / 2027-01 的未触碰样本一次性裁决 (§7)。

6.7 规定格式登记表

机器可读源：`docs/signal_summary.json`（纯数字模式：全部量化字段为 `number`、不适用为 `null`、单位在字段名或 `meta.units`）。

表 16: 登记信号主表（IC / ICIR / 取 1 收益 / 符号 IC，均为 1/3/10 分钟三元组）

品种 信号	类型 月频	RankIC	ICIR	取 1 收益 (bp)	符号 IC
SC C8	连续 11.2k 分钟	+0.0161 / +0.0230 / +0.0298	+0.85 / +0.79 / +0.64	-	-
AU C8	连续 11.2k 分钟	+0.0097 / +0.0119 / +0.0187	+0.79 / +0.80 / +0.78	-	-
AG C8	连续 11.2k 分钟	+0.0125 / +0.0133 / +0.0060	+0.89 / +0.72 / +0.48	-	-
CU C8	连续 9.4k 分钟	+0.0141 / +0.0178 / +0.0197	+0.97 / +0.83 / +0.68	-	-
M C8	连续 7.0k 分钟	+0.0159 / +0.0124 / +0.0093	+1.16 / +0.95 / +0.79	-	-
SC E1_up	离散 328 次	-	-	+0.01 / -0.36 / -0.74	+0.0027 / +0.0020 / -0.0007
SC JUMP_SC_day	离散 24 次	-	-	+1.39 / +2.76 / +10.63	+0.0038 / +0.0070 / +0.0057
M JUMP_M_isolated	离散 5 次	-	-	+0.13 / +0.45 / +3.36	+0.0040 / +0.0062 / +0.0044

读法示例：SC 盘中事件跳后 10 分钟条件均值 +10.63 bp，应对照 SC 无条件 10 分钟均值 -0.13 bp 解读；该格为置换单方法支持的探索候选、毛收益低于两倍成本门槛（16 bp 完整换手）。

7 关键结果（模块化摘要）

以下每个模块：一句结论 + 关键数字 + 完整版出处（记法 §*N* = 完整版第 *N* 节，§ 三-*N* = 完整版附录三）。

表 17: 取值统计量（连续：矩统计；离散：valuecount）与非零频率

品种	信号	统计量 / valuecount	非零频率
SC	C8	$\mu=-0.013$, $\text{med}=-0.010$, $\sigma=1.356$, $\text{skew}=-0.04$, $\text{kurt}=+1.53$	98.54%
AU	C8	$\mu=+0.020$, $\text{med}=+0.007$, $\sigma=1.606$, $\text{skew}=+0.33$, $\text{kurt}=+4.28$	98.54%
AG	C8	$\mu=-0.003$, $\text{med}=+0.052$, $\sigma=1.461$, $\text{skew}=-2.15$, $\text{kurt}=+204.41$	98.54%
CU	C8	$\mu=-0.015$, $\text{med}=+0.072$, $\sigma=1.649$, $\text{skew}=+0.98$, $\text{kurt}=+61.45$	98.26%
M	C8	$\mu=+0.018$, $\text{med}=+0.038$, $\sigma=1.544$, $\text{skew}=+0.87$, $\text{kurt}=+9.69$	97.68%
SC	E1_up	-1: 2,015; 0: 63,759; 1: 1,951	5.86%
SC	JUMP_SC_day	-1: 134; 1: 143	0.41%
M	JUMP_M_isolated	-1: 25; 1: 28	0.12%

表 18: 品种全区间基准（离散信号条件均值的对照；剔换月日）

品种	收对收累计	无条件 1' (bp)	3' (bp)	10' (bp)
SC	+8.8%	+0.009	+0.006	-0.126
AU	-14.8%	-0.024	-0.077	-0.298
AG	-22.4%	-0.010	-0.066	-0.339
CU	+2.9%	-0.002	-0.015	-0.024
M	+5.7%	-0.004	-0.027	-0.134

7.1 吸收结构（A 级，全文最强结论）

国内闭市期间积累的事件概率变化在开盘跳空与夜盘被系统性定价。油价主题 $\times$ SC 傍晚细窗相关 0.86 ($n = 37$)、合并缺口 0.743 ($n = 74$)；中东 $\times$ 凌晨闭市段 0.70；循环置换 $p < 0.0005$ ；冲突高峰期内 / 外同号且期外更强 (0.35 / 0.68)。**截面识别**：88 品种按暴露度逐日排序（差分掉当日共同因子），截面 RankIC 0.185（经济先验载荷，HAC $t = 4.0$ ）与 0.261（估计载荷， $t = 5.0$ ），最高与最低五分位开盘前收益差约 100 bp/日，承载品种恰为能源链与贵金属。（§6、§12.12）

7.2 中东增量（A 级）

控制同窗国际基准（USO 等 12 资产）后，唯一稳定显著的配对：中东冲突概率对 SC，严格同窗 $t = 4.94$ ($n = 114$)；经济量级约 96 bp/ σ ；机制指向 INE 交割篮子的中东油种集中。LP-IV（第一阶段 $F = 42$ ）：事件驱动的油价变动传导系数 $\delta = 1.13$ 高于一般变动的 0.89。（§11、§12.8、§12.14）

7.3 反转 = SC-USO 相对收益回归（A 级）

事件日吸收 (+507 bp/ σ) 的 84% 来自 USO 分量；次日反转 (-226 bp) 的 81% 来自 SC 相对 USO 的收益分量，冲突高峰时累计相对偏离一度达 18% 后回归。该分量未经汇率 / 期限 / 油种调整，不等同于严格基差。（§11.3、§12.14）

7.4 否定结果（C/D 级，占结论的大多数）

表 19: 否定结果汇总（每行都是登记在案的完整检验）

命题	证据
分钟级无纯 PM 信号	23 个纯 Polymarket 信号 $\times$ 798 检验, $\max t = 3.24 <$ 门槛 4.15 (本文 §6.5, 新算)
日频方向不可预测	68 项预测检验 FDR 后全负; OOS 增量不为正; 截面预测 IC ≈ 0 (三层互证)
波动水平预测无 OOS 增量	$\Delta R^2 \approx 0$, Clark–West $t \approx 0$
组合不放大信息	中东 $\times$ 油价交互 $t = -2.88$ (冗余); 共现无超额; 确认型组合跨品种一致为负
C8 的 PM 腿无分钟增量	五品种严格增量检验全部未通过 (逐日日内 partial t 0.6–1.8; 安慰剂 p 0.26–0.61; OOS $\Delta R^2 \approx 0$), 退出 alpha 候选
J 族仅单方法探索	SC 盘中跳: 置换 $p < 0.008$ 支持、HAC 一致 wild bootstrap $p = 0.17$ 不支持; 毛收益低于 $2\times$ 成本门槛; M 孤立跳 51 响应不显著 (t 1.41 / 0.87)
聪明钱窗口流无增量	技能钱包仅占主题成交额 2–5%; 锚配对预测全零; 吸收增量 $t \approx 1.0$ –1.3

7.5 数据层新发现：钱包技能真实且持续

对全部逐笔按 taker 钱包核算持有到结算盈亏 (5,831 万钱包 $\times$ 市场组合): 前后半段单位成交盈亏秩相关随活跃度单调升——散户层 0.026、 ≥ 100 市场 0.113、 ≥ 100 万美元 0.158 ($n = 35.8$ 万钱包)。技能存在，但其信息在窗口尺度已被价格聚合。(§12.13)

7.6 结论与投资定位

Polymarket 对中国商品期货的价值形态是**事件风险的实时测量**（开盘前风险敞口、品种排序、尾部旗标——旗标冻结样本初值 lift 3.28、Fisher $p = 0.007$ 、overlay 使 SC 持有回撤 $-53\% \rightarrow -31\%$, 2027 年初未触碰样本裁决），**不是方向 alpha**。实盘配置为零仓位；全部候选已冻结 (freeze/manifest.json)，裁决时点：SC 跳格 2026-12-31 或新增 95 个交易日先到者，R1–R4 与旗标 2027-01-31，各候选仅一次预约定检验。(§12.15–12.16)

8 复现

补充数据腿（零成本，data/intl/）：Brent 与 USDCNH 日频经免费接口；交易所逐合约日结算经公开端点 (.../dailydata/kxYYYYMMDD.dat, INE/SHFE 已核实可用)。

表 20: 复现命令链（全部数字构建时从产物计算，不手抄）

步骤	命令 / 产物
链上采集与统一 tape	<code>crawl_polymarket_chain.py</code> → <code>v3_build_tape.py</code>
期货分钟库	<code>build_cn_futures_db.py</code> (88 品种)
主题注册	<code>select_polymarket_markets.py</code> → <code>cn_registry_v3.parquet</code>
分钟面板与信号库	<code>v3_defense_build.py</code> (40 信号 + 前向收益)
全信号统计网格	<code>v3_signal_grid.py</code> → <code>defense/signal_grid.parquet</code> (200 格 × 129 列)
跳变因子	<code>v3_jump_factors.py</code> / <code>v3_jump_inference.py</code>
截面与钱包	<code>v3_cross_section.py</code> / <code>v3_wallet_skill.py</code>
规定格式登记表	<code>export_signal_summary.py</code> → <code>docs/signal_summary.json</code>
本文图	<code>v3_concise_figures.py</code> → <code>docs/concise/fig/</code>
本文表体	<code>make_concise_table.py</code> → <code>docs/concise/t*.tex</code>
本文编译	<code>xelatex main.tex</code> (两遍)
影子记录	<code>shadow_daily.py</code> → <code>shadow/records.jsonl</code> (追加不回改)
冻结对账	<code>freeze/manifest.json</code> (SHA256 + 终检日期)

8.1 已登记的限制项

1. 期货分钟样本仅 125 个交易日，且由单一事件（中东冲突）主导，全部结论为探索性；无法构造“过去一年”基准。
2. 分析层不保留链上日志主键，行级回溯只在原始层成立 (§3.3)。
3. 撮合时刻不可观测，时间戳为区块时间，滞后量未测 (§3.4)。
4. 铸造匹配型成交未单独标记，是否被中继腿判据完全覆盖未经证明 (§3.7)。
5. `negRisk` 市场在两段中均被排除，2024 年美国大选等旗舰市场不在样本内。
6. `locked` 仅为 $H = L$ 代理，且未参与任何过滤 (§4.5)。
7. 主力连续的换月判定规则由数据方决定，未公开、未核实。

完整版 (151 页): `docs/` 下的 `cn_futures_polymarket_report.html` 与同名 PDF。

本文对应分支 `feat/cn-futures-polymarket`。